MLREML：用于植物和动物育种的平均信息 REML 线性混合模型

用户指南、理论基础及真实数据实例 — 版本 1.0.0

Osval Antonio Montesinos López, Abelardo Montesinos-López, José Crossa, J. Cricelio Montesinos-López

2026 年 10 月

目录

请更新目录：右键单击 → 更新域 → 更新整个目录。

1 引言

1.1 MLREML 是什么

MLREML 是一个 R 软件包，它采用平均信息（Average Information，AI）算法，通过限制性最大似然法（REML）拟合线性混合模型。它专为植物和动物育种中的典型问题而设计：方差和协方差组分的估计、遗传力和遗传相关的估计、遗传值的预测（BLUP、EBV 和 GEBV）、多环境试验分析、田间试验的空间分析、包含系谱和基因组信息的模型、多变量模型以及纵向模型。

该名称结合了组织本软件包的两个核心思想：线性混合模型（mixed linear models）及其 REML 估计。其语法借鉴了该领域的参考程序 ASReml（Gilmour et al., 2015; Butler et al., 2017），因此 ASReml 用户几乎无需额外学习即可阅读和编写 MLREML 模型。然而，MLREML 是独立的开源软件：它不包含任何 ASReml 代码，不依赖于 ASReml，也不需要任何许可证。

本软件包的核心思想与使 ASReml 强大的思想相同。线性混合模型不仅由其包含的效应所定义，还由这些效应和残差的分布与相关方式所定义。因此，MLREML 中的每个随机项都写成方差结构的直积：例如，`us(env):vm(gen, G)` 声明了每个基因型在每个环境中的遗传效应，这些效应在基因型之间按照基因组矩阵 **G** 相关，在环境之间按照由数据估计的非结构化协方差矩阵相关。

MLREML 还通过项 `str()` 提供了直接遗传效应与母体遗传效应之间的协方差（更一般地，共享同一亲缘关系矩阵的多个因子的随机效应之间的协方差）；提供了第二个基于稀疏矩阵混

合模型方程的计算引擎，适用于包含数十万条记录的数据集；并为固定效应的 F 检验提供了 Kenward–Roger 分母自由度。

1.2 本指南的读者对象

本指南面向数量遗传学、植物和动物育种、试验统计学和生物统计学领域的研究人员、教师和研究生。读者需具备 R 和线性模型的基础知识。混合模型的理论在第 2 章中完整介绍，并给出贯穿全文的符号，因此本指南也可用作课程教材。

本文档分为三部分。第一部分（第 1 至 3 章）介绍模型、估计算法和语法。第二部分（第 4 至 12 章）给出使用公开领域真实数据的完整实例：一个燕麦 α-格子试验、一个采用空间分析的小麦试验、一个多环境玉米试验、599 个经标记分型的 CIMMYT 小麦品系、带有系谱的荷斯坦奶牛产奶记录、鸡的生长曲线、睡眠剥夺研究中人的反应时间、一个完全的烟草双列杂交，以及一个无重复的早代小麦试验。第三部分（第 13 至 16 章）涵盖高级用法、一项模拟研究、本软件包与其他程序的数值验证、其局限性以及所有函数的汇总；完整的函数参考见附录。

1.3 安装

本软件包以源文件 `MLREML_1.0.0.tar.gz` 的形式发布，可从 https://github.com/osval78/MLREML 获取。它依赖于软件包 `Matrix`（版本 1.6-0 或更高，随 R 一起提供）和 `Rcpp`，以及 `methods`、`stats`、`graphics` 和 `utils`。本软件包包含 C++ 代码（稀疏引擎所用的稀疏逆矩阵以及近交系数的计算），因此需要使用编译器从源代码安装：Windows 上为 Rtools，macOS 上为 Xcode 命令行工具（`xcode-select --install`），Linux 上为常用的开发工具（例如 Debian 和 Ubuntu 的 `r-base-dev` 软件包）：

```
install.packages("Rcpp")
install.packages("MLREML_1.0.0.tar.gz", repos = NULL, type = "source")
library(MLREML)
```

本指南中的实例使用了以下软件包中的数据：`agridat`（Wright, 2024）、`BGLR`（Pérez and de los Campos, 2014）、`pedigreemm`（Vazquez et al., 2010）和 `lme4`（Bates et al., 2015），并将结果与 `lme4`、`nlme`（Pinheiro and Bates, 2000）和 `pbkrtest`（Halekoh and Højsgaard, 2014）进行比较。使用 MLREML 并不需要其中任何一个软件包：

```
install.packages(c("agridat", "BGLR", "pedigreemm", "lme4", "nlme", "pbkrtest"))
```

为了实现快速的线性代数运算，R 应与优化的 BLAS 库（OpenBLAS、Intel MKL 或 macOS 上的 Accelerate）一起使用。使用稠密引擎时，一次拟合的时间主要由 $n \times n$ 矩阵的 Cholesky 分解决定，与参考 BLAS 相比，优化的 BLAS 可将其速度提高 10 至 30 倍。稀疏引擎同样受益，因为其稀疏分解和稀疏逆矩阵中的稠密块是用 BLAS 和 LAPACK 计算的。

1.4 功能及其与 ASReml 的对应关系

下表汇总了植物和动物育种中常提到的 ASReml 功能，以及在 MLREML 中如何实现这些功能。表中明确说明了在本版本中哪些功能已完全实现、哪些部分实现、哪些尚不可用。

ASReml 功能及其在 MLREML 中的对应实现。

功能（ASReml）	在 MLREML 中	状态
线性混合模型，非平衡数据	`mlreml()`	完整
平均信息（AI）REML	带阻尼的 AI 算法	完整
带标准误的方差组分	`summary()`，AI 矩阵的逆	完整
遗传力、相关、组分的函数	`vpredict()`（delta 方法）	完整
带系谱的动物模型，EBV	`vm(animal, A)`, `Amatrix()`, `Ainverse()`	完整
近交系数	`inbreeding_coef()`（Meuwissen and Luo）	完整
GBLUP	`vm(gen, G)`, `Gmatrix()`, `gblup()`	完整
一步法 GBLUP（H 矩阵）	`Hmatrix()`, `align_G()`, `bend()`	完整
SNP 质量控制	`snp_qc()`	基本
多变量模型，遗传相关	`cbind(y1, y2) ~ trait, us(trait)`	完整
多环境试验（MET），G×E	`diag()`, `us()`, `fa(k)`	完整
异质残差方差	`residual = ~ diag(env):units`	完整
行 × 列空间分析	`residual = ~ ar1(row):ar1(col)`	完整
不规则空间数据	`expc(x)`, `sexp(x, y)`	完整
重复测量，永久环境	`id(animal)` + `vm(animal, A)`, `ar1()`	完整
随机回归	`us(leg(x, k)):id(animal)`, `pol()`	完整
母体效应	附加项 `id(dam)`、`vm(dam, A)`	完整
双列杂交（GCA、SCA、反交）	`mm(p1, p2)`, `id(cross)`	完整

功能（ASReml）	在 MLREML 中	状态
BLUP、PEV、可靠性	`coef(fit, "random")`	完整
预测均值和 SED	`predict(fit, classify = ...)`	完整
递增和条件 Wald 检验	`wald()`	完整（条件检验遵循边际性原则）
模型比较（LRT、AIC、BIC）	`lrt()`, `AIC`, `BIC`	完整
样本变异函数	`variogram()`	完整
直接–母体遗传协方差	`str(animal, dam, K = A)`	完整
稀疏矩阵方法（数百万条记录）	`engine = "sparse"`（混合模型方程）	对 `id`、`vm`、`diag`、`us` 和 `str()` 项完整
Kenward–Roger 自由度	`wald(fit, ddf = "KR")`	完整（稠密引擎）
广义线性混合模型	—	不可用

MLREML 有两个计算引擎。稠密引擎采用基于 **V** 的方法：它精确、简单且易于验证，并且无需专门代码即可支持非常一般的结构，但将其在 8 GB 内存的个人计算机上的舒适使用范围限制在约 5,000–6,000 条记录。稀疏引擎像全国遗传评估所用的程序一样，利用稀疏 Cholesky 分解和系数矩阵的稀疏逆求解混合模型方程；它支持大型数据集中最常用的结构，并能在同一台计算机上拟合包含数十万条记录的动物模型（第 2.12 节和第 15.2 节）。对于只有单个遗传效应的 GBLUP，函数 `gblup()` 提供了一种基于 **G** 谱分解的精确替代方法。第 15 章记录了计算时间和内存使用情况。

1.5 第一个实例

为了展示分析的一般形式，考虑一个模拟试验：30 个基因型在 4 个完全区组中进行评价。模型为

$$y_{ij} = \mu + \beta_j + g_i + e_{ij}, \qquad g_i \sim N\left(0, \sigma_g^2\right), \qquad e_{ij} \sim N(0, \sigma_e^2),$$

其中区组为固定效应，基因型为随机效应。

```
set.seed(1)
d <- data.frame(block = factor(rep(1:4, each = 30)), gen = factor(rep(1:30, 4)))
d$y <- 10 + rnorm(4)[d$block] + rnorm(30, sd = 1.5)[d$gen] + rnorm(120)
fit <- mlreml(y ~ block, random = ~ id(gen), data = d, trace = FALSE)
summary(fit)

## MLREML fit (AI-REML)
## Observations: 120   Fixed-effect columns: 4   Iterations: 6 (converged)
## REML log-likelihood: -192.9292   AIC: 389.86   BIC: 395.37
```

```
##
## Variance parameters:
##                 estimate std.error z.ratio bound
## id(gen)!sigma2   1.9621    0.5686    3.45     P
## R!units!sigma2   0.7992    0.1212    6.60     P
##
## Bound codes: P positive/free, B at boundary, F fixed.
```

输出显示观测数、固定效应列数、迭代次数、限制性对数似然值和信息准则。随后给出每个方差参数及其近似标准误（由平均信息矩阵的逆得到）、z 比值和边界代码。基于基因型均值的广义遗传力及其标准误可通过 `vpredict()` 获得：

```
vpredict(fit, H2 ~ V1 / (V1 + V2 / 4))
```

```
##    estimate std.error
## H2   0.9076   0.02802
```

```
head(coef(fit, "random", "id(gen)"))
```

```
##   level     blup    pev     se reliability
## 1     1  0.14700 0.2407 0.4906      0.8773
## 2     2 -1.03768 0.2407 0.4906      0.8773
## 3     3 -0.29958 0.2407 0.4906      0.8773
## 4     4  1.02779 0.2407 0.4906      0.8773
## 5     5  0.47789 0.2407 0.4906      0.8773
## 6     6 -0.08843 0.2407 0.4906      0.8773
```

第二条指令返回基因型的 BLUP 及其预测误差方差（PEV）、标准误和可靠性 $1 - \mathrm{PEV}/\sigma_g^2$。

2 理论基础

本章介绍 MLREML 所拟合的模型、限制性似然、所实现的平均信息算法，以及本软件包在拟合后计算的量：固定效应的估计量、随机效应的预测量、预测误差方差、预测均值、假设检验和方差参数的函数。

2.1 线性混合模型

设 $\mathbf{y}$ 为 n 个观测值组成的向量。一般线性混合模型为

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \sum_{k=1}^{K} \mathbf{Z}_k \, \mathbf{u}_k + \mathbf{e}, \qquad (2.1)$$

其中 $\boldsymbol{\beta}$ 是 p 个固定效应组成的向量，其设计矩阵为 $\mathbf{X}$（$n \times p$，去除冗余列后为满秩），$\mathbf{u}_k$ 是项 k 的 q_k 个随机效应组成的向量，其设计矩阵为 $\mathbf{Z}_k$，$\mathbf{e}$ 是残差向量。假定

$$\mathbf{u}_k \sim N\big(\mathbf{0}, \mathbf{G}_k(\boldsymbol{\theta})\big), \qquad \mathbf{e} \sim N\big(\mathbf{0}, \mathbf{R}(\boldsymbol{\theta})\big), \qquad \mathrm{Cov}(\mathbf{u}_k, \mathbf{u}_l) = \mathbf{0}, \ \mathrm{Cov}(\mathbf{u}_k, \mathbf{e}) = \mathbf{0},$$

并且矩阵 $\mathbf{G}_k$ 和 $\mathbf{R}$ 依赖于一个方差参数向量 $\boldsymbol{\theta}$（方差、协方差、相关系数、因子载荷）。观测值的边际分布为

$$\mathbf{y} \sim N(\mathbf{X}\boldsymbol{\beta}, \mathbf{V}), \qquad \mathbf{V}(\boldsymbol{\theta}) = \sum_{k=1}^{K} \mathbf{Z}_k \, \mathbf{G}_k \mathbf{Z}_k' + \mathbf{R}. \tag{2.2}$$

模型的全部灵活性在于 $\mathbf{G}_k$ 和 $\mathbf{R}$ 的形式。在传统方差分析中，每个 $\mathbf{G}_k$ 为 $\sigma^2_k \mathbf{I}$，且 $\mathbf{R} = \sigma^2_e \mathbf{I}$。相反，在数量遗传学中，$\mathbf{G}$ 可以是 $\sigma^2_a \mathbf{A}$（系谱）、$\sigma^2_g \mathbf{G}_{\text{genomic}}$，或在多环境试验中为 $\boldsymbol{\Sigma}_E \otimes \mathbf{K}$；而 $\mathbf{R}$ 可以是各环境方差不同的对角矩阵，或具有田间试验的可分离自回归结构。

2.2 作为直积的结构

MLREML 将每个 $\mathbf{G}_k$ 构建为若干小矩阵的直积（Kronecker 积），每个定义该项的因子对应一个小矩阵：

$$\mathbf{G}_k = \sigma^2_k \, \boldsymbol{\Sigma}_{k1} \otimes \boldsymbol{\Sigma}_{k2} \otimes \cdots \otimes \boldsymbol{\Sigma}_{kC}. \tag{2.3}$$

例如，对于有 E 个环境和 N 个基因型的环境内基因型效应，$\mathbf{u}$ 有 EN 个元素，按基因型变化最快的顺序排列，且 $\mathbf{G} = \boldsymbol{\Sigma}_E \otimes \mathbf{K}$。该项的设计矩阵是各因子设计矩阵的面分裂积（按行的 Khatri–Rao 积）：如果 $\mathbf{z}_{c,i}'$ 是因子 c 的设计矩阵 $\mathbf{Z}_c$ 的第 i 行，则 $\mathbf{Z}_k$ 的第 i 行为 $\mathbf{z}_{1,i}' \otimes \mathbf{z}_{2,i}' \otimes \cdots$。

一个简单的代数性质使得无需构建完整的 $\mathbf{Z}_k$ 或 $\mathbf{G}_k$ 即可计算每一项对 $\mathbf{V}$ 的贡献。对于面分裂积，

$$\mathbf{Z}_k(\boldsymbol{\Sigma}_1 \otimes \boldsymbol{\Sigma}_2)\mathbf{Z}_k' = (\mathbf{Z}_1 \boldsymbol{\Sigma}_1 \mathbf{Z}_1') \circ (\mathbf{Z}_2 \boldsymbol{\Sigma}_2 \mathbf{Z}_2'), \tag{2.4}$$

其中 $\circ$ 为 Hadamard（逐元素）积。当因子 c 为分类变量时，$\mathbf{Z}_c$ 每行只有一个 1，$\mathbf{Z}_c \boldsymbol{\Sigma}_c \mathbf{Z}_c'$ 就是按每个观测值的水平索引的矩阵 $\boldsymbol{\Sigma}_c$：其 (i,j) 元素为 $\Sigma_c[\ell_c(i), \ell_c(j)]$，其中 $\ell_c(i)$ 是观测值 i 中因子 c 的水平。因此，一个包含 6,547 头动物的基因组矩阵只在有记录的动物所对应的行和列中被使用，项 `us(env):vm(gen, G)` 向 $\mathbf{V}$ 贡献元素 $\Sigma_E[e_i, e_j]\, K[g_i, g_j]$。恒等式 (2.4) 正是 MLREML 能够自由地将任意结构与任意其他结构组合的原因。

残差以同样的方式处理。默认结构 `units` 是观测值上的单位矩阵。结构 `diag(env):units` 给出 $R_{ij} = \sigma^2_{e(i)} \delta_{ij}$，即各环境具有不同的残差方差。结构 `ar1(row):ar1(col)` 给出

$$R_{ij} = \sigma^2 \, \rho_r^{|r_i - r_j|} \, \rho_c^{|c_i - c_j|}, \tag{2.5}$$

即 Gilmour et al.（1997）的可分离空间模型，其中 r_i 和 c_i 是小区 i 的行和列。由于该矩阵是根据每个观测值的坐标构建的，试验不必是完整的网格：缺失的小区只是不出现而已。

2.3 限制性似然

通过误差对比 $\mathbf{K}'\mathbf{y}$（其中 $\mathbf{K}'\mathbf{X}=\mathbf{0}$）将固定效应从似然中消除，其分布不依赖于 $\boldsymbol{\beta}$（Patterson and Thompson, 1971）。除一个常数外，限制性对数似然为

$$\ell_R(\boldsymbol{\theta}) = -\frac{1}{2}\left[\log|\mathbf{V}| + \log|\mathbf{X}'\mathbf{V}^{-1}\mathbf{X}| + \mathbf{y}'\mathbf{P}\mathbf{y} + (n-p)\log(2\pi)\right], \qquad (2.6)$$

其中投影矩阵为

$$\mathbf{P} = \mathbf{V}^{-1} - \mathbf{V}^{-1}\mathbf{X}(\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-1}\mathbf{X}'\mathbf{V}^{-1}. \qquad (2.7)$$

REML 校正了最大似然法因估计固定效应而产生的偏差；在平衡设计中，当方差分析估计量为正时，REML 估计量与之一致。MLREML 报告的值包含常数 $(n-p)\log(2\pi)$，并与 `lme4` 和 `nlme` 的值相等，这使得程序之间的比较十分方便（第 15 章）。只有当两个模型具有完全相同的固定效应时，它们的 REML 似然才具有可比性。

2.4 平均信息算法

设 $\mathbf{V}_i = \partial\mathbf{V}/\partial\theta_i$。(2.6) 的一阶导数构成得分向量，为

$$s_i = \frac{\partial \ell_R}{\partial \theta_i} = -\frac{1}{2}\left[\operatorname{tr}(\mathbf{P}\mathbf{V}_i) - \mathbf{y}'\mathbf{P}\mathbf{V}_i\mathbf{P}\mathbf{y}\right]. \qquad (2.8)$$

观测信息矩阵包含四个 $n\times n$ 矩阵乘积的迹，计算代价非常高；Fisher 信息包含 $\operatorname{tr}(\mathbf{P}\mathbf{V}_i\mathbf{P}\mathbf{V}_j)$，计算代价同样很高。Gilmour、Thompson 和 Cullis（1995）注意到，当 $\mathbf{V}$ 关于参数为线性时，两者的平均为

$$\mathcal{I}_{A,ij} = \frac{1}{2}\,\mathbf{y}'\mathbf{P}\mathbf{V}_i\mathbf{P}\mathbf{V}_j\mathbf{P}\mathbf{y}, \qquad (2.9)$$

它只需要矩阵–向量乘积：如果 $\mathbf{w}_i = \mathbf{V}_i\mathbf{P}\mathbf{y}$ 且 $\mathbf{W} = [\mathbf{w}_1, \dots, \mathbf{w}_m]$，则 $\mathcal{I}_A = 1/2\,\mathbf{W}'\mathbf{P}\mathbf{W}$。平均信息矩阵是半正定的，并且当 $\mathbf{V}$ 关于 $\boldsymbol{\theta}$ 非线性时（自回归相关、因子载荷），它也是信息矩阵的一种 Gauss–Newton 型近似。更新公式为

$$\boldsymbol{\theta}^{(t+1)} = \boldsymbol{\theta}^{(t)} + \left[\mathcal{I}_A^{(t)}\right]^{-1}\mathbf{s}^{(t)}. \qquad (2.10)$$

2.4.1 在 MLREML 中的实现

在每次迭代中，MLREML 的稠密引擎 (i) 利用恒等式 (2.4) 构建 $\mathbf{V}$；(ii) 计算其 Cholesky 因子 $\mathbf{V} = \mathbf{U}'\mathbf{U}$、$\log|\mathbf{V}| = 2\sum\log u_{ii}$、$\mathbf{V}^{-1}$ 和 $\mathbf{P}$；(iii) 对每个自由参数构造 $\mathbf{V}_i$ —— 同样通过 Hadamard 积，将组分矩阵替换为其导数 —— 并计算 $tr(\mathbf{P}\mathbf{V}_i) = \sum_{jk} P_{jk}\,V_{i,jk}$ 和 $\mathbf{w}_i$；(iv) 得到 $\mathbf{s}$ 和 $\mathcal{I}_A$。稀疏引擎则从混合模型方程得到相同的量（第 2.12 节）。所有结构的导数都是解析的；例如，对于自回归结构，对每个距离 $d>0$（包括小于 1 的距离）有 $\partial\rho^d/\partial\rho = d\rho^{d-1}$，

而对 $d=0$ 为零；对于非结构化矩阵，关于 σ_{ab} 的导数为 $\mathbf{E}_{ab}+\mathbf{E}_{ba}$；对于因子分析模型 $\boldsymbol{\Lambda}\boldsymbol{\Lambda}'+\boldsymbol{\Psi}$，关于载荷 λ_{lm} 的导数为 $\mathbf{e}_l\boldsymbol{\lambda}_m{}'+\boldsymbol{\lambda}_m\mathbf{e}_l{}'$。

纯 Newton 步 (2.10) 可能会离开参数空间（负方差、大于 1 的相关系数、非正定矩阵），或在远离最优点时降低似然值。MLREML 包含三种保护措施：

1. **Levenberg–Marquardt 阻尼。**步长按 $\left(\mathcal{I}_A+\lambda\,\mathrm{diag}(\mathcal{I}_A)\right)^{-1}\mathbf{s}$ 计算。初始时 $\lambda=0$（纯 AI 步）；如果候选值无效或使 ℓ_R 减小，则将 λ 乘以 10。当 λ 很大时，该步趋近于一个短的梯度步，它总能使似然增加。在接受一步之后，减小 λ。
2. **边界约束。**方差保持在一个非常小的正下界之上；cs 的相关系数保持在 $(-1/(L-1)+10^{-4},0.999)$ 之内，因为 $L\times L$ 复合对称矩阵仅在 $\rho>-1/(L-1)$ 时正定；当所有距离均为整数时，自回归相关保持在 $(-0.99,0.999)$ 之内，否则保持在 $(10^{-6},0.999)$ 之内，因为当 $\rho<0$ 且 d 不是整数时 ρ^d 无定义。与 ASReml 一样，终止于边界的参数在输出中以代码 B 标记。位于边界上、且其得分或 Newton 步指向参数空间之外的方差会被保持在边界上并从 AI 系统中移除，其他参数的步长则以条件方式计算（有效集方法）。若改为截断联合步长，则可能使所有参数实际上停滞在一个并非最大值的点上。
3. **半正定投影。**如果一个非结构化矩阵（us）不再是正定的，则将其负特征值替换为一个小的正值，从而将其投影到半正定矩阵锥上。这使得算法能够逼近位于边界上的解（例如接近 1 的遗传相关），这类解在多环境试验中很常见。

当 ℓ_R 的变化小于 `tol`（默认为 10^{-6}）且 Newton 减量 $\mathbf{s}'\mathcal{I}_A^{-1}\mathbf{s}$（计算时不包括保持在边界上的参数）小于 10^{-3}，或者参数的相对变化可以忽略时，即宣告收敛。在后一种情况下，如果 Newton 减量仍然很大（当非结构化矩阵收敛到奇异矩阵时就会出现这种情况），会给出警告，建议检查估计值并考虑采用简化的结构。

初始值。计算固定效应模型的普通最小二乘残差的方差 v_p，并将其平均分配给各随机项和残差。水平特定的方差（结构 diag、us、fa）的初始值为各水平内观测到的残差方差乘以相同比例，这样在性状以不同单位测量的多变量模型中也能得到尺度合适的值。自回归相关的初始值取使水平间最小距离处的相关为 0.5 的值。用户可以通过参数 `start` 给出自己的初始值，并通过 `fix` 固定参数。

标准误。最优点处 $\mathcal{I}_A$ 的逆近似于 $\widehat{\boldsymbol{\theta}}$ 的渐近协方差矩阵，并给出组分表中的标准误。对于位于边界上的参数，这一近似无效，应忽略其标准误。

2.5 固定效应的估计和随机效应的预测

给定 $\widehat{\boldsymbol{\theta}}$，固定效应的广义最小二乘估计量（经验 BLUE）及其方差为

$$\widehat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-1}\mathbf{X}'\mathbf{V}^{-1}\mathbf{y}, \qquad \mathrm{Var}(\widehat{\boldsymbol{\beta}}) = \mathbf{C}_{11} = (\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-1}, \qquad (2.11)$$

每个随机项的最佳线性无偏预测量（经验 BLUP）为

$$\widehat{\mathbf{u}}_k = \mathbf{G}_k\mathbf{Z}_k'\mathbf{V}^{-1}\left(\mathbf{y} - \mathbf{X}\widehat{\boldsymbol{\beta}}\right) = \mathbf{G}_k\mathbf{Z}_k'\mathbf{P}\mathbf{y}. \qquad (2.12)$$

这些表达式是 Henderson（1975）混合模型方程的解，

$$\begin{bmatrix}\mathbf{X}'\mathbf{R}^{-1}\mathbf{X} & \mathbf{X}'\mathbf{R}^{-1}\mathbf{Z} \\ \mathbf{Z}'\mathbf{R}^{-1}\mathbf{X} & \mathbf{Z}'\mathbf{R}^{-1}\mathbf{Z} + \mathbf{G}^{-1}\end{bmatrix}\begin{bmatrix}\widehat{\boldsymbol{\beta}} \\ \widehat{\mathbf{u}}\end{bmatrix} = \begin{bmatrix}\mathbf{X}'\mathbf{R}^{-1}\mathbf{y} \\ \mathbf{Z}'\mathbf{R}^{-1}\mathbf{y}\end{bmatrix},$$

但 MLREML 的稠密引擎直接以 (2.12) 的形式计算它们，无需对 $\mathbf{G}$ 求逆。因此，只要 $\mathbf{V}$ 是正定的，奇异的亲缘关系矩阵（例如标记数少于个体数的基因组矩阵，或遗传上完全相同的品系）就不会造成任何问题。稀疏引擎（第 2.12 节）直接求解方程本身，因而需要 $\mathbf{G}^{-1}$。

当某一项使用的亲缘关系矩阵的水平数多于观测到的水平数时——例如包含无记录祖先的系谱矩阵 $\mathbf{A}$，或未测表型的选择候选个体的基因组矩阵——(2.12) 也会预测这些水平，因为 $\mathbf{G}_k\mathbf{Z}_k'$ 包含了它们与已观测个体之间的协方差。

预测误差方差。 Henderson 方程系数矩阵的逆 $\mathbf{C}$ 给出估计误差和预测误差的联合协方差。用 $\mathbf{V}$ 表示，其各分块为

$$\mathbf{C}_{11} = (\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-1}, \quad \mathbf{C}_{21} = -\mathbf{G}\mathbf{Z}'\mathbf{V}^{-1}\mathbf{X}\mathbf{C}_{11}, \quad \mathbf{C}_{22} = \mathrm{Var}(\widehat{\mathbf{u}} - \mathbf{u}) = \mathbf{G} - \mathbf{G}\mathbf{Z}'\mathbf{P}\mathbf{Z}\mathbf{G}. \qquad (2.13)$$

$\mathbf{C}_{22}$ 的对角线即为每个 BLUP 的 PEV。在动物育种中广泛使用的可靠性为 $r_i^2 = 1 - PEV_i/G_{ii}$，即真实遗传值与预测遗传值之间相关系数的平方。MLREML 的稠密引擎按 $\mathbf{G}\mathbf{Z}'$ 的行块计算 PEV，而不构建 $\mathbf{G}$，因此所需内存与 n 乘以块大小成正比；稀疏引擎则从 $\mathbf{C}$ 的稀疏逆矩阵的对角线获得 PEV（第 2.12 节）。

2.6 预测均值和差值标准误

预测是一个线性组合 $\boldsymbol{\tau} = \mathbf{L}\boldsymbol{\beta} + \mathbf{M}\mathbf{u}$（Welham et al., 2004）。函数 `predict()` 通过在不属于分类的固定因子的各水平上对设计矩阵的行取平均（简单平均），并在协变量的均值处取值来构建 $\mathbf{L}$；$\mathbf{M}$ 选择其因子全部属于分类的随机项的 BLUP，其他随机项因期望为零而被忽略。预测误差方差为

$$\mathrm{Var}(\widehat{\boldsymbol{\tau}} - \boldsymbol{\tau}) = \mathbf{L}\mathbf{C}_{11}\mathbf{L}' + \mathbf{L}\mathbf{C}_{12}\mathbf{M}' + \mathbf{M}\mathbf{C}_{21}\mathbf{L}' + \mathbf{M}\mathbf{C}_{22}\mathbf{M}', \qquad (2.14)$$

两个预测值之差的标准误为 $\mathrm{SED}_{ab} = \sqrt{v_{aa} + v_{bb} - 2v_{ab}}$。平均 SED 是 Cullis、Smith 和 Coombes（2006）广义遗传力 $H_C^2 = 1 - \overline{\mathrm{SED}}^2/\left(2\sigma_g^2\right)$ 的基础，该遗传力在非平衡试验中很有用。

2.7 假设检验

固定效应。假设 $\mathbf{L}\boldsymbol{\beta} = \mathbf{0}$（其中 $q = rank(\mathbf{L})$）的 Wald 统计量为 $W = (\mathbf{L}\hat{\boldsymbol{\beta}})'(\mathbf{L}\mathbf{C}_{11}\mathbf{L}')^{-1}\mathbf{L}\hat{\boldsymbol{\beta}}$，渐近服从 χ^2_q。函数 `wald()` 对固定效应公式中的每一项 T 给出两种版本。*递增*统计量对 T 调整公式中位于其前面的项（序贯检验或"I 型"检验）：若 $\mathbf{U}'\mathbf{U} = \mathbf{C}_{11}^{-1} = \mathbf{X}'\mathbf{V}^{-1}\mathbf{X}$ 为 Cholesky 分解，则 $\mathbf{L}$ 由 $\mathbf{U}$ 中对应于 T 各列的行构成，且 $W_T = \sum_{j\in T}\left(\mathbf{U}\hat{\boldsymbol{\beta}}\right)^2_j$。*条件*统计量对 T 调整所有不包含它的项，与 ASReml 一样遵循边际性原则（"II 型"检验）：在 `y ~ A * B` 中，主效应 `A` 对 `B` 进行调整，但不对 `A:B` 调整，而交互作用对两个主效应都进行调整。其计算方法是先重新排列各列，使 T 位于不包含它的项之后、包含它的项之前，然后按递增统计量计算。若对每一项调整所有其他项（包括包含该项的交互作用），在处理对比下检验的将是 `A` 在 `B` 参考水平上的效应。每个统计量都附有一个 F 检验。默认情况下（`ddf = "auto"`），稠密引擎的拟合采用 Kenward 和 Roger（1997）的方法，该方法针对方差参数的估计对 $\hat{\boldsymbol{\beta}}$ 的协方差矩阵和 F 统计量进行调整，并给出每个检验的分母自由度（第 2.13 节）。使用 `ddf = "residual"` 时（稀疏引擎的拟合则总是如此），$F = W/q$ 采用 $n - p$ 作为分母自由度；该近似在数据量大时是合适的，在小型试验中则偏于宽松。

方差参数。具有相同固定效应的两个嵌套模型通过似然比 $LR = 2\left(\ell_{R,1} - \ell_{R,0}\right)$ 进行比较。在检验单个方差是否为零时，参数位于边界上，零分布为 χ^2_0 与 χ^2_1 的 50:50 混合（Self and Liang, 1987; Stram and Lee, 1994），因此 p 值是 χ^2_1 的一半。函数 `lrt()` 应用了这一校正。非嵌套模型通过 $\text{AIC} = -2\ell_R + 2m$ 和 $\text{BIC} = -2\ell_R + m\log(n-p)$ 进行比较，其中 m 是方差参数的个数。

2.8 方差参数的函数

遗传力、重复力和遗传相关是非线性函数 $f(\boldsymbol{\theta})$。其近似标准误通过 delta 方法得到，

$$\operatorname{Var}\left[f\left(\hat{\boldsymbol{\theta}}\right)\right] \approx \nabla f\left(\hat{\boldsymbol{\theta}}\right)' \mathcal{I}_A^{-1} \nabla f\left(\hat{\boldsymbol{\theta}}\right), \qquad (2.15)$$

这正是 `vpredict()` 所做的，其中梯度通过中心差分计算。参数按组分表中的顺序命名为 `V1`、`V2`、…。

2.9 亲缘关系矩阵

系谱。两个个体之间的加性亲缘关系是其共祖系数的两倍。矩阵 $\mathbf{A}$ 用表格法构建：若 s 和 d 是 i 的亲本，则对于 $j < i$ 有 $A_{ji} = 1/2\left(A_{js} + A_{jd}\right)$，且 $A_{ii} = 1 + 1/2\,A_{sd}$，其中 $F_i = 1/2\,A_{sd}$ 是近交系数。其逆矩阵直接利用考虑近交的 Henderson（1976）规则构建（Quaas, 1976）：令 $b_i = [1/2 - 1/4\,(F_s + F_d)]^{-1}$（未知亲本使用 $F = -1$），将 b_i 加到元素 (i,i)，将 $-b_i/2$ 加到 (i,s)、(s,i)、(i,d)、(d,i)，将 $b_i/4$ 加到 (s,s)、(d,d)、(s,d)、(d,s)。系数 F 用 Meuwissen 和 Luo（1992）的算法计算。

基因组。以 0/1/2 编码的基因型矩阵 $\mathbf{M}$ 和等位基因频率 p_j 为基础，VanRaden（2008）定义了 $\mathbf{W}=\mathbf{M}-2\mathbf{p}'$ 和 $\mathbf{G}=\mathbf{WW}'/\left[2\sum_j p_j\left(1-p_j\right)\right]$。标准化的替代方法是将 $\mathbf{W}$ 的每一列除以 $\sqrt{2p_j\left(1-p_j\right)}$，并将乘积除以标记数。使用 $\sigma_g^2\mathbf{G}$ 的 GBLUP 等价于对标记的岭回归（Meuwissen et al., 2001; VanRaden, 2008）。

一步法。当只有部分个体被基因分型时，Legarra et al.（2009）将系谱和基因组信息合并为

$$\mathbf{H}=\mathbf{A}+\begin{bmatrix}\mathbf{A}_{12}\mathbf{A}_{22}^{-1}\\ \mathbf{I}\end{bmatrix}(\mathbf{G}-\mathbf{A}_{22})[\mathbf{A}_{22}^{-1}\mathbf{A}_{21}\quad\mathbf{I}],\qquad \mathbf{H}^{-1}=\mathbf{A}^{-1}+\begin{bmatrix}\mathbf{0} & \mathbf{0}\\ \mathbf{0} & \tau\mathbf{G}^{-1}-\omega\mathbf{A}_{22}^{-1}\end{bmatrix},\qquad (2.16)$$

其中下标 2 对应已基因分型的个体。为了使 $\mathbf{G}$ 和 $\mathbf{A}_{22}$ 处于同一尺度，将 $\mathbf{G}$ 对齐为 $\alpha+\beta\mathbf{G}$，使其对角线均值和所有元素均值与 $\mathbf{A}_{22}$ 的相应均值一致（Christensen et al., 2012），并与一小部分 $\mathbf{A}_{22}$ 混合以保证其可逆。

2.10 计算成本

稠密引擎每次迭代的主要步骤是 $\mathbf{V}$ 的分解和求逆，其时间成本为 $O(n^3)$，内存成本为 $O(n^2)$。每个参数为其迹和向量 $\mathbf{w}_i$ 增加 $O(n^2)$ 次运算。BLUP 及其 PEV 的预测成本为 $O(qn^2)$，内存为 $O(n\times\text{block})$。稀疏引擎的成本为混合模型方程系数矩阵的稀疏 Cholesky 分解及其稀疏逆的成本，两者均与 $\sum_i|S_i|^2$ 成正比，其中 $|S_i|$ 是 Cholesky 因子第 i 列对角线以下的非零元素个数，另外每个参数还需用该因子求解一次；其内存与因子的非零元素个数成正比（第 2.12 节）。第 15 章给出了实测时间。

2.11 多个因子的相关效应：直接–母体模型

在许多物种中，个体的表型既取决于其自身的基因（直接遗传效应），也取决于其母亲的基因，后者通过母亲提供的母体环境表现出来：泌乳量、母性能力、子宫容量（母体遗传效应）。同一动物的这两种效应通常是相关的，Willham（1963）的模型将它们联合处理：

$$\mathbf{y}=\mathbf{X}\boldsymbol{\beta}+\mathbf{Z}_d\mathbf{a}_d+\mathbf{Z}_m\mathbf{a}_m+\cdots+\mathbf{e},\qquad Var\begin{pmatrix}\mathbf{a}_d\\ \mathbf{a}_m\end{pmatrix}=\begin{pmatrix}\sigma_d^2 & \sigma_{dm}\\ \sigma_{dm} & \sigma_m^2\end{pmatrix}\otimes\mathbf{A}=\boldsymbol{\Sigma}\otimes\mathbf{A},\qquad (2.17)$$

其中 $\mathbf{a}_d$ 和 $\mathbf{a}_m$ 包含系谱中所有动物的直接育种值和母体育种值，$\mathbf{Z}_d$ 将每条记录与产生该记录的动物相连，$\mathbf{Z}_m$ 将其与该动物的母亲相连。两个向量由相同的动物索引，但一条记录获得的是一个动物的直接值和另一个动物的母体值，因此该项不能写成组分的直积，恒等式 (2.4) 不适用。它对 $\mathbf{V}$ 的贡献是三个矩阵之和，

$$\mathbf{Z}(\boldsymbol{\Sigma}\otimes\mathbf{A})\mathbf{Z}'=\sigma_d^2\,\mathbf{Z}_d\mathbf{A}\mathbf{Z}_d'+\sigma_m^2\,\mathbf{Z}_m\mathbf{A}\mathbf{Z}_m'+\sigma_{dm}(\mathbf{Z}_d\mathbf{A}\mathbf{Z}_m'+\mathbf{Z}_m\mathbf{A}\mathbf{Z}_d'),\qquad \mathbf{Z}=[\mathbf{Z}_d,\mathbf{Z}_m],\qquad (2.18)$$

它关于三个参数是线性的；其导数 $\mathbf{V}_i$ 就是 (2.18) 中的三个矩阵。$\mathbf{Z}_d\mathbf{A}\mathbf{Z}_m{}'$ 的 (i,j) 元素是记录 i 的动物与记录 j 的母亲之间的亲缘关系。母亲未知的记录在 $\mathbf{Z}_m$ 中对应一行零：它们有助于直接效应的估计，并保留在分析中。

MLREML 用项 `str(f1, f2, ..., K = K, cov = "us")` 拟合该模型，它将 (2.17) 推广到 $m \geq 2$ 个因子，这些因子的水平是同一矩阵 $\mathbf{K}$ 的行：$\mathbf{u} = (\mathbf{u}_1{}', \ldots, \mathbf{u}_m{}')'$、$\mathbf{Z} = [\mathbf{Z}_1, \ldots, \mathbf{Z}_m]$ 且 $Var(\mathbf{u}) = \boldsymbol{\Sigma} \otimes \mathbf{K}$，其中 $\boldsymbol{\Sigma}$ 为非结构化（`cov = "us"`，$m(m+1)/2$ 个参数）或对角（`cov = "diag"`）。效应 a 的 BLUP 及其预测误差方差由 (2.12) 和 (2.13) 得到：

$$\hat{\mathbf{u}}_a = \sum_{b=1}^{m} \Sigma_{ab}\ \mathbf{K}\mathbf{Z}_b{}'\mathbf{P}\mathbf{y}, \qquad PEV_{a,l} = \Sigma_{aa}K_{ll} - \mathbf{g}_{a,l}{}'\mathbf{P}\mathbf{g}_{a,l}, \qquad \mathbf{g}_{a,l}{}' = \sum_{b=1}^{m} \Sigma_{ab}\ \mathbf{k}_l{}'\mathbf{Z}_b{}', \tag{2.19}$$

其中 $\mathbf{k}_l{}'$ 是 $\mathbf{K}$ 的第 l 行。除直接遗传力 $h^2_d = \sigma^2_d/\sigma^2_P$ 和直接–母体遗传相关 $r_{dm} = \sigma_{dm}/(\sigma_d\sigma_m)$ 外，Willham（1972）的总遗传力 $h^2_T = (\sigma^2_d + 1.5\sigma_{dm} + 0.5\sigma^2_m)/\sigma^2_P$ 衡量对表型选择的响应。只有当系谱将母亲与其自身或亲属的记录联系起来时，母体遗传方差才可识别，而且 σ_{dm} 的估计值往往为负且不精确（Meyer, 1992）；如有必要，可将母体永久环境效应作为单独的项 `id(dam)` 加入。

2.12 稀疏引擎：基于混合模型方程的 REML

前面各节的方法处理 $n \times n$ 矩阵 $\mathbf{V}$，精确而通用，但其成本随 n^3 增长。全国遗传评估所用的程序（ASReml、DMU、WOMBAT、BLUPF90）则使用 Henderson 混合模型方程，其系数矩阵是稀疏的。MLREML 包含了这第二个**稀疏引擎**。设 $\mathbf{T} = [\mathbf{X}, \mathbf{Z}]$、$\mathbf{Z} = [\mathbf{Z}_1, \ldots, \mathbf{Z}_K]$ 和 $\mathbf{G} = \mathrm{blockdiag}(\mathbf{G}_1, \ldots, \mathbf{G}_K)$。方程的系数矩阵为

$$\mathbf{C} = \mathbf{T}'\mathbf{R}^{-1}\mathbf{T} + \begin{bmatrix} \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{G}^{-1} \end{bmatrix}, \qquad \mathbf{C}\begin{bmatrix} \hat{\boldsymbol{\beta}} \\ \hat{\mathbf{u}} \end{bmatrix} = \mathbf{T}'\mathbf{R}^{-1}\mathbf{y}. \tag{2.20}$$

由于 $|\mathbf{V}||\mathbf{X}'\mathbf{V}^{-1}\mathbf{X}| = |\mathbf{R}||\mathbf{G}||\mathbf{C}|$，限制性对数似然 (2.6) 可以不借助 $\mathbf{V}$ 写出：

$$\ell_R = -\frac{1}{2}\left[\log|\mathbf{R}| + \log|\mathbf{G}| + \log|\mathbf{C}| + \mathbf{y}'\mathbf{P}\mathbf{y} + (n-p)\log(2\pi)\right], \qquad \mathbf{y}'\mathbf{P}\mathbf{y} = \mathbf{y}'\mathbf{R}^{-1}\mathbf{y} - \left[\hat{\boldsymbol{\beta}}', \hat{\mathbf{u}}'\right]\mathbf{T}'\mathbf{R}^{-1}\mathbf{y}. \tag{2.21}$$

ℓ_R 的值与稠密引擎的值相同。令 $\hat{\mathbf{e}} = \mathbf{y} - \mathbf{T}\left[\hat{\boldsymbol{\beta}}', \hat{\mathbf{u}}'\right]'$，得分 (2.8) 变为

$$s_i = -\frac{1}{2}\left[tr(\mathbf{R}^{-1}\mathbf{R}_i) + tr(\mathbf{G}^{-1}\mathbf{G}_i) + tr(\mathbf{C}^{-1}\mathbf{C}_i) + \hat{\mathbf{e}}'\frac{\partial\mathbf{R}^{-1}}{\partial\theta_i}\hat{\mathbf{e}} + \hat{\mathbf{u}}'\frac{\partial\mathbf{G}^{-1}}{\partial\theta_i}\hat{\mathbf{u}}\right], \tag{2.22}$$

其中 $\mathbf{R}_i = \partial\mathbf{R}/\partial\theta_i$、$\mathbf{G}_i = \partial\mathbf{G}/\partial\theta_i$ 和 $\mathbf{C}_i = \partial\mathbf{C}/\partial\theta_i$，对于 $\mathbf{G}$ 的参数为 $\mathrm{blockdiag}(\mathbf{0}, \partial\mathbf{G}^{-1}/\partial\theta_i)$，对于 $\mathbf{R}$ 的参数为 $\mathbf{T}'(\partial\mathbf{R}^{-1}/\partial\theta_i)\mathbf{T}$。

稀疏逆。迹 $tr(\mathbf{C}^{-1}\mathbf{C}_i)$ 只需要 $\mathbf{C}^{-1}$ 在 $\mathbf{C}_i$ 非零位置上的元素，这些位置全部位于 $\mathbf{C}$ 的 Cholesky 因子的模式之中。设经过减少填充的行列置换后 $\mathbf{C} = \mathbf{L}\mathbf{L}'$，并设 S_i 为 $\mathbf{L}$ 第 i 列对角线以下非

零元素所在的行。$\mathbf{C}^{-1}$ 在 **L** 模式中的元素 Z_{ji} 按列从最后一列到第一列，利用 Takahashi et al.（1973）以及 Erisman 和 Tinney（1975）的递推公式求得，Misztal 和 Perez-Enciso（1993）将其用于动物育种：

$$Z_{ji} = -\sum_{k \in S_i} \frac{L_{ki}}{L_{ii}} Z_{kj} \quad (j \in S_i), \qquad Z_{ii} = \frac{1}{L_{ii}^2} - \sum_{k \in S_i} \frac{L_{ki}}{L_{ii}} Z_{ki}. \qquad (2.23)$$

右侧只需要 **L** 模式中的元素，因为该模式是封闭的：若 k 和 j 属于 S_i，则元素 (k, j) 属于该模式。其成本与 $\sum_i |S_i|^2$ 成正比，与分解本身的量级相同，内存与 **L** 相同。随机效应块的对角线给出预测误差方差，固定效应块给出 $Var(\widehat{\boldsymbol{\beta}})$，无需额外成本。

平均信息。由于 $\mathbf{Py} = \mathbf{R}^{-1}\hat{\mathbf{e}}$ 且 $\mathbf{Z}'\mathbf{Py} = \mathbf{G}^{-1}\hat{\mathbf{u}}$，(2.9) 中的工作变量 $\mathbf{w}_i = \mathbf{V}_i\mathbf{Py}$ 无需 **V** 即可计算：对于 **G** 的参数为 $\mathbf{w}_i = \mathbf{Z}\mathbf{G}_i\mathbf{G}^{-1}\hat{\mathbf{u}}$，对于 **R** 的参数为 $\mathbf{w}_i = \mathbf{R}_i\mathbf{R}^{-1}\hat{\mathbf{e}}$。由于 $\mathbf{P} = \mathbf{R}^{-1} - \mathbf{R}^{-1}\mathbf{T}\mathbf{C}^{-1}\mathbf{T}'\mathbf{R}^{-1}$，

$$\mathcal{J}_{A,ij} = \frac{1}{2}\mathbf{w}_i'\mathbf{P}\mathbf{w}_j = \frac{1}{2}\left(\mathbf{w}_i'\mathbf{R}^{-1}\mathbf{w}_j - \mathbf{t}_i'\mathbf{C}^{-1}\mathbf{t}_j\right), \qquad \mathbf{t}_i = \mathbf{T}'\mathbf{R}^{-1}\mathbf{w}_i, \qquad (2.24)$$

每个参数只需用 **C** 的因子求解一次（Johnson and Thompson, 1995; Gilmour et al., 1995）。

结构。对于项 $\mathbf{G}_k = \mathbf{K}_1 \otimes \boldsymbol{\Sigma} \otimes \mathbf{K}_2$，其中 $\boldsymbol{\Sigma}$ 是唯一带参数的矩阵（对于没有方差结构的项为 σ^2），$\mathbf{K}_1$、$\mathbf{K}_2$ 为单位矩阵或亲缘关系矩阵，有 $\mathbf{G}_k^{-1} = \mathbf{K}_1^{-1} \otimes \boldsymbol{\Sigma}^{-1} \otimes \mathbf{K}_2^{-1}$；对于阶数为 a 和 b 的矩阵，$\log|\mathbf{G}_k|$ 可由 $\log|\mathbf{A} \otimes \mathbf{B}| = b\log|\mathbf{A}| + a\log|\mathbf{B}|$ 得到；而 $\mathbf{G}_i\mathbf{G}^{-1}\hat{\mathbf{u}} = (\mathbf{I} \otimes \boldsymbol{\Sigma}_i\boldsymbol{\Sigma}^{-1} \otimes \mathbf{I})\hat{\mathbf{u}}$ 只涉及小矩阵 $\boldsymbol{\Sigma}$。亲缘关系矩阵只需通过其逆矩阵使用，因此可以直接提供用 Henderson 规则构建的 $\mathbf{A}^{-1}$（第 2.9 节）。`str()` 项为 $\boldsymbol{\Sigma} \otimes \mathbf{K}$，其中 $\mathbf{Z} = [\mathbf{Z}_1, \ldots, \mathbf{Z}_m]$。残差矩阵为块对角矩阵，每条记录一个块：$\sigma_e^2\mathbf{I}$（`units`）、$diag\left(\sigma_{e(i)}^2\right)$（`diag(f):units`），或在多变量模型中为每条记录中观测到的性状所对应的 $\boldsymbol{\Sigma}_e$ 子矩阵（`us(trait):units`）。

实现。**C** 以固定模式（所有可能非零位置的并集）组装，因此减少填充的排序和 CHOLMOD（Chen et al., 2008，在 R 中通过 `Matrix` 软件包提供）的符号分解只需计算一次，每次迭代只重复数值分解。递推公式 (2.23) 用 C++ 编写，采用每列与其行所对应各列的有序归并，无需搜索。阻尼步长的候选点只需要分解，因为 $\log|\mathbf{C}| = 2\sum_i \log L_{ii}$。预测均值使用 $Var(\hat{\boldsymbol{\tau}} - \boldsymbol{\tau}) = [\mathbf{L}, \mathbf{M}]\mathbf{C}^{-1}[\mathbf{L}, \mathbf{M}]'$，它与 (2.14) 等价，通过 **C** 的因子求解得到。

稀疏引擎支持由 `id`、`vm`、`diag` 和 `us` 组分构成的随机项（使用因子、`pol()`、`leg()` 或 `mm()` 基）、`str()` 项，以及残差结构 `units`、`diag(f):units` 和 `us(trait):units`。带相关参数的结构（`cs`、`ar1`、`expc`、`sexp`）和 `fa` 用稠密引擎拟合。在默认设置 `engine = "auto"` 下，当数据超过 5,000 条记录且模型受支持时，MLREML 使用稀疏引擎，否则使用稠密引擎。两个引擎给出的似然、估计值、BLUP 和预测误差方差在舍入误差范围内相同（第 15.1 节）。由

于稀疏引擎需要 $\mathbf{G}^{-1}$，亲缘关系矩阵必须是正定的；奇异的基因组矩阵必须进行弯曲或混合（第 13.7 节），或用稠密引擎拟合。

2.13 Kenward–Roger 自由度

(2.11) 中的协方差矩阵 $\boldsymbol{\Phi} = \left(\mathbf{X}'\widehat{\mathbf{V}}^{-1}\mathbf{X}\right)^{-1}$ 将方差参数视为已知。在小型试验中，它低估了 $\widehat{\boldsymbol{\beta}}$ 的方差，而使用 $n-p$ 个分母自由度的 F 检验会过于频繁地拒绝真实假设。Kenward 和 Roger（1997）提出了一个调整后的协方差矩阵，

$$\boldsymbol{\Phi}_A = \boldsymbol{\Phi} + 2\boldsymbol{\Phi}\left\{\sum_{i,j} W_{ij}\left(\mathbf{Q}_{ij} - \mathbf{P}_i\boldsymbol{\Phi}\mathbf{P}_j - \frac{1}{4}\mathbf{R}_{ij}\right)\right\}\boldsymbol{\Phi}, \qquad (2.25)$$

其中 $\mathbf{P}_i = -\mathbf{X}'\mathbf{V}^{-1}\mathbf{V}_i\mathbf{V}^{-1}\mathbf{X}$、$\mathbf{Q}_{ij} = \mathbf{X}'\mathbf{V}^{-1}\mathbf{V}_i\mathbf{V}^{-1}\mathbf{V}_j\mathbf{V}^{-1}\mathbf{X}$、$\mathbf{R}_{ij} = \mathbf{X}'\mathbf{V}^{-1}\mathbf{V}_{ij}\mathbf{V}^{-1}\mathbf{X}$、$\mathbf{V}_{ij} = \partial^2\mathbf{V}/\,\partial\theta_i\,\partial\theta_j$，$\mathbf{W}$ 为期望信息矩阵的逆，其元素为 $\frac{1}{2}tr\left(\mathbf{P}\mathbf{V}_i\mathbf{P}\mathbf{V}_j\right)$。对于 $q = rank(\mathbf{L})$ 的假设 $\mathbf{L}\boldsymbol{\beta} = \mathbf{0}$，他们使用统计量

$$F = \frac{\lambda}{q}\left(\mathbf{L}\widehat{\boldsymbol{\beta}}\right)'\left(\mathbf{L}\boldsymbol{\Phi}_A\mathbf{L}'\right)^{-1}\mathbf{L}\widehat{\boldsymbol{\beta}}, \qquad (2.26)$$

并选择尺度 λ 和分母自由度 m，使 F 的均值和方差与 $F(q,m)$ 分布的均值和方差近似一致。令 $\boldsymbol{\Theta} = \mathbf{L}'(\mathbf{L}\boldsymbol{\Phi}\mathbf{L}')^{-1}\mathbf{L}$，

$$A_1 = \sum_{i,j} W_{ij}\; tr(\boldsymbol{\Theta}\boldsymbol{\Phi}\mathbf{P}_i\boldsymbol{\Phi})tr\left(\boldsymbol{\Theta}\boldsymbol{\Phi}\mathbf{P}_j\boldsymbol{\Phi}\right), \qquad A_2 = \sum_{i,j} W_{ij}\; tr\left(\boldsymbol{\Theta}\boldsymbol{\Phi}\mathbf{P}_i\boldsymbol{\Phi}\boldsymbol{\Theta}\boldsymbol{\Phi}\mathbf{P}_j\boldsymbol{\Phi}\right),$$

$$B = \frac{A_1 + 6A_2}{2q}, \quad g = \frac{(q+1)A_1 - (q+4)A_2}{(q+2)A_2}, \quad c_1 = \frac{g}{3q + 2(1-g)}, \quad c_2 = \frac{q-g}{3q+2(1-g)}, \quad c_3 = \frac{q+2-g}{3q+2(1-g)},$$

$$E^* = \left(1 - \frac{A_2}{q}\right)^{-1}, \quad V^* = \frac{2}{q}\frac{1 + c_1B}{(1-c_2B)^2(1-c_3B)}, \quad \rho = \frac{V^*}{2E^{*2}}, \quad m = 4 + \frac{q+2}{q\rho - 1}, \quad \lambda = \frac{m}{E^*(m-2)}. \qquad (2.27)$$

在 F 检验精确成立的平衡设计中，该方法能重现它：$\lambda = 1$，且 m 等于经典自由度（例如裂区设计中主区误差的自由度）。

MLREML 对 `wald()` 的每个递增和条件检验计算 (2.25)–(2.27)（第 2.7 节）；每个检验的矩阵 $\mathbf{L}$ 由计算 Wald 统计量所用的 Cholesky 因子的相应行给出。除位于参数空间边界上的参数（视为已知）外，所有自由方差参数都包括在内。对于关于参数为线性的结构（`id`、`vm`、`diag`、`us`、`str()`），二阶导数 $\mathbf{V}_{ij}$ 为零；对于其他结构（`cs`、`ar1`、`expc`、`sexp`、`fa` 的载荷，以及两个带参数组分的乘积，例如 `ar1(row):ar1(col)` 与其尺度），以解析方式纳入。该调整使用 $n \times n$ 导数矩阵，适用于以 `store = TRUE` 保存的稠密引擎拟合；当期望信息需要超

过 2 GB 内存时，改用平均信息矩阵。对于面向大型数据集（此时调整可以忽略）的稀疏引擎，`wald()` 使用 $n - p$ 自由度。结果与 `pbkrtest` 软件包（Halekoh and Højsgaard, 2014）在五位或更多有效数字上一致（第 15.1 节）。

3 模型语法

3.1 函数 `mlreml()`

一般调用形式为

```
fit <- mlreml(fixed, random = NULL, residual = NULL, data,
              start = NULL, fix = NULL, maxit = 50, tol = 1e-6,
              pev = TRUE, trace = TRUE, store = TRUE,
              engine = c("auto", "dense", "sparse"))
```

`mlreml()` 的参数。

参数	含义
`fixed`	用于响应变量和固定效应的双侧公式，采用 R 的常规语法（`y ~ rep + gen`）。
`random`	包含随机项的单侧公式（`~ gen + rep:block`）。
`residual`	包含单个残差结构项的单侧公式。默认为 `~ units`。
`data`	数据框。响应变量或预测变量缺失的行将被删除，但 `str()` 项中因子的缺失值除外（第 2.11 节）。
`start`	方差参数初始值的命名向量。
`fix`	固定在其初始值上的参数名称。
`maxit`, `tol`	最大迭代次数和 ℓ_R 变化的容差。
`pev`	计算 BLUP 的预测误差方差。
`trace`	显示迭代历史。
`store`	保留 `predict()` 以及 `wald()` 的 Kenward–Roger 调整所需的矩阵；`FALSE` 可节省内存。
`engine`	计算引擎：`"dense"`（方差矩阵 $\mathbf{V}$）、`"sparse"`（混合模型方程）或 `"auto"`（当记录超过 5,000 条且模型受支持时使用稀疏引擎，否则使用稠密引擎）。参见第 2.12 节。

固定效应的处理方式与 `lm()` 相同：因子生成处理对比，交互作用用 `:` 或 `*` 书写，线性相关的列会被自动删除（即 ASReml 中的 “aliased” 效应）。

3.2 随机项

每个随机项是由冒号分隔的若干**组分**的乘积。每个组分由作用于一个**基**的**结构**构成。基定义了每个观测值所属的水平，结构定义了该基的效应的协方差（或相关）矩阵。

3.2.1 基

组分的基。

基	描述
`f`	数据中的因子或分类变量。若为数值型，则其不同取值（排序后）即为各水平。
`pol(x, k)`	含截距的 k 阶原始多项式：列为 $1, x, \ldots, x^k$。
`leg(x, k)`	将 x 重新缩放到 $[-1,1]$ 后的 k 阶标准化 Legendre 多项式，与动物育种中的随机回归模型相同。
`mm(f1, f2, ...)`	多成员因子：每个观测值同时属于 `f1` 和 `f2` 的水平。用于两个亲本的一般配合力。
`units`	观测单元（每条记录一个水平；在多变量模型中，每条原始记录一个水平）。

3.2.2 结构

下表列出了可用的结构、它们为具有 L 个水平的组分生成的矩阵及其参数个数。**相关**结构没有自身的尺度；**方差**结构则有。

方差结构。

结构	$L \times L$ 矩阵	参数	类型
`id(f)` 或 `f`	$\mathbf{I}_L$	0	相关
`vm(f, K)`	已知矩阵 $\mathbf{K}$（A、G、H、亲缘矩阵）	0	相关
`cs(f)`	$(1-\rho)\mathbf{I} + \rho\mathbf{J}$	1	相关
`ar1(f)`	$\rho^{\lvert x_a - x_b \rvert}$（若水平为数字，则为实际距离）	1	相关
`expc(x)`	$\rho^{\lvert x_a - x_b \rvert}$，$x$ 为不规则连续值	1	相

结构	$L \times L$ 矩阵	参数	类型
`sexp(x, y)`	$\rho^{d_{ab}}$，d 为平面上的欧氏距离	1	关相关
`diag(f)`	$\mathrm{diag}(\sigma_1^2, \ldots, \sigma_L^2)$	L	方差
`us(f)`	非结构化矩阵	$L(L+1)/2$	方差
`fa(f, k)`	$\mathbf{\Lambda\Lambda}' + \mathbf{\Psi}$，$\mathbf{\Lambda}$ 的大小为 $L \times k$	$Lk + L$（减去 $k(k-1)/2$ 个零）	方差

仅由相关组分构成的项会获得一个尺度参数 σ^2。一个项最多只能有一个方差组分，由它承载尺度；例如，在 `us(env):vm(gen, G)` 中，`us` 矩阵是数据尺度上环境间的遗传协方差，`vm` 提供基因型间的相关。同一项中的两个方差组分是不可识别的（将其中一个乘以 c 并将另一个除以 c 不会改变模型），MLREML 会给出错误信息并拒绝此类项。

在 `fa(f, k)` 中，当 $k > 1$ 时，$\mathbf{\Lambda}$ 对角线以上的载荷被固定为零，以消除旋转不确定性。估计得到的载荷可在事后进行旋转以便解释；`vc_matrix()` 还会返回主成分旋转后的解。

相关项。项 `str(f1, f2, ..., K = K, cov = "us")` 不是组分的乘积而是组分的和（第 2.11 节）：它为每个因子 `f1`、`f2`、…定义一个随机效应，这些因子的水平是矩阵 `K` 的行，且 $Var(\mathbf{u}) = \mathbf{\Sigma} \otimes \mathbf{K}$，其中 $\mathbf{\Sigma}$ 为非结构化（`cov = "us"`，默认）或对角（`cov = "diag"`）。因子的取值必须属于 `rownames(K)`；缺失值（`NA`、`""` 或 `"0"`）表示该记录不从该因子获得效应，但记录本身保留。若省略 `K`，则使用单位矩阵。参数的命名方式与 `us()` 相同：例如，`str(animal, dam, K = A)!dam:animal` 是直接–母体协方差。

3.2.3 项的示例

随机项示例。

项	模型
`~ gen`	独立的基因型，一个方差。
`~ rep:block`	重复内的不完全区组。
`~ vm(animal, A)`	动物模型：$\mathbf{a} \sim N(\mathbf{0}, \sigma_a^2 \mathbf{A})$。
`~ vm(animal, Ai),Ai <- Ainverse(ped)`	同一模型，$\mathbf{A}$ 由其稀疏逆矩阵给出。

项	模型
`~ vm(animal, A) + animal`	重复力模型：遗传值加永久环境效应。
`~ str(animal, dam, K = A)`	直接和母体遗传效应及其协方差，$\boldsymbol{\Sigma} \otimes \mathbf{A}$。
`~ str(animal, dam, K = A) + id(dam)`	同上，并加入母体永久环境效应。
`~ vm(gen, G)`	GBLUP。
`~ env:gen`	同质 G×E 交互作用（复合对称）。
`~ diag(env):id(gen)`	每个环境具有不同的遗传方差，无协方差。
`~ us(env):vm(gen, G)`	环境间具有非结构化遗传协方差的基因组 MET。
`~ fa(env, 2):id(gen)`	采用双因子因子分析模型的 MET。
`~ us(trait):vm(animal, A)`	性状间的加性遗传协方差矩阵。
`~ us(leg(dim, 2)):vm(animal, A)`	2 阶遗传随机回归。
`~ mm(p1, p2) + cross`	双列杂交：亲本的 GCA 和杂交组合的 SCA。
`~ units`	空间模型中的*块金*效应（附加的独立误差）。

传给 `vm()` 和 `str()` 的矩阵在创建固定效应公式的环境中查找（通常是工作空间）。它们必须具有包含该因子所有水平的行名；也可以包含额外的水平。亲缘关系矩阵也可以通过其逆矩阵给出，只要它带有属性 `INVERSE = TRUE`（`Ainverse()` 的结果即是如此）：稀疏引擎直接使用它，稠密引擎则对其求逆。

3.3 残差结构

`residual` 参数接受一个采用相同语法的单个项。最常用的结构有：

残差结构。

残差	$\mathbf{R}$
`~ units`	$\sigma_e^2\mathbf{I}$（默认）
`~ diag(env):units`	每个环境具有不同的残差方差
`~ ar1(row):ar1(col)`	可分离空间模型 (2.5)
`~ diag(env):ar1(row):ar1(col)`	按环境的空间模型，各环境方差不同、相关系数共同
`~ ar1(time):id(animal)`	每个个体内的自相关重复测量
`~ expc(time):id(animal)`	同上，时间间隔不规则
`~ sexp(x, y)`	具有不规则坐标的各向同性空间模型

残差	R
`~ us(trait):units`	同一记录中性状间的残差协方差（多变量模型默认）

当残差为空间结构时，通常会添加一个随机项 `units` 来表示独立的测量误差。

3.4 多变量模型

如果 `fixed` 的左侧为 `cbind(y1, y2, ...)`，MLREML 会将数据堆叠为长格式，创建每个性状一个水平的因子 `trait`，以及标识每条原始记录的基 `units`。固定效应公式用 `trait` 来书写：

```
mlreml(cbind(weight, height) ~ trait + trait:sex,
       random = ~ us(trait):vm(animal, A),
       residual = ~ us(trait):units, data = mydata)
```

存在部分性状缺失的记录仍会保留其已观测的性状，这是多变量 REML 分析的优势之一。

3.5 参数名称、初始值和约束

每个参数命名为 `term!component_level`；残差参数以 `R!` 开头。例如，`us(env):vm(gen, G)!env_E2:E1` 是环境 E2 与 E1 之间的遗传协方差，`R!diag(env):units!env_E1` 是 E1 的残差方差。这些名称用于 `start` 和 `fix`。若要将残差方差固定为 1 并估计其余参数：

```
fit0 <- mlreml(y ~ 1, random = ~ gen, data = d, trace = FALSE)
fit1 <- mlreml(y ~ 1, random = ~ gen, data = d,
               start = c("R!units!sigma2" = 1), fix = "R!units!sigma2")
```

固定所有参数后，就可以在已知组分（例如已发表的组分或在另一数据集中估计的组分）下计算似然和 BLUP。

3.6 拟合对象

`mlreml()` 返回一个类为 `"mlreml"` 的列表。其主要元素有：

`mlreml` 对象的元素。

元素	内容
`varcomp`	方差参数表：估计值、标准误、z 比值、边界代码。
`theta`, `vcov_theta`	参数向量及其近似协方差（$\mathcal{I}_A^{-1}$）。
`beta`, `vcov_beta`	固定效应及其协方差矩阵（使用稀疏引擎且固定效应超过 1,000 个时，为包含方差的对角矩阵；`wald()` 在需要时计算完整矩阵）。
`blups`	每个随机项对应一个数据框的列表：水平、BLUP、PEV、标准误和可靠性

元素	内容
	（对于 `str()` 项，还包括列 `effect`）。
`fitted`, `residuals`	拟合值（$\mathbf{X}\hat{\boldsymbol{\beta}} + \mathbf{Z}\hat{\mathbf{u}}$）和条件残差。
`loglik`, `AIC`, `BIC`	限制性似然和信息准则。
`history`, `converged`	迭代历史和收敛标志。
`data`	所用数据（若为多变量模型则为长格式）。
`engine`	所用引擎，`"dense"` 或 `"sparse"`。
`sparse`	仅限稀疏引擎：方程个数（`N`）、Cholesky 因子的非零元素个数（`nnzL`），以及在 `store = TRUE` 时因子本身，供 `predict()` 和 `wald()` 使用。

可用的方法有 `summary()`、`print()`、`coef()`（固定或随机）、`fitted()`、`residuals()`、`vcov()`、`logLik()`、`AIC()`、`BIC()`、`plot()` 和 `predict()`。函数 `wald()`、`vpredict()`、`lrt()`、`vc_matrix()` 和 `variogram()` 用于完成推断。

4 实例 1：α-格子设计的燕麦试验

4.1 数据

`agridat` 软件包中的数据集 `john.alpha` 来自 John 和 Williams（1995）。它包含 24 个燕麦品种，采用 α 设计进行评价，共 3 次重复，每次重复分为 6 个各含 4 个小区的不完全区组。响应变量为产量（t/ha）。这是区组间信息恢复的经典实例：由于每个区组只包含 24 个品种中的 4 个，不在同一区组中出现的品种之间的比较取决于区组方差。

```
library(agridat)
data(john.alpha)
d <- john.alpha
str(d)
```

```
## 'data.frame':    72 obs. of  7 variables:
##  $ plot : int  1 2 3 4 5 6 7 8 9 10 ...
##  $ rep  : Factor w/ 3 levels "R1","R2","R3": 1 1 1 1 1 1 1 1 1 1 ...
##  $ block: Factor w/ 6 levels "B1","B2","B3",..: 1 1 1 1 2 2 2 2 3 3 ...
##  $ gen  : Factor w/ 24 levels "G01","G02","G03",..: 11 4 5 22 21 10 20 2 23
14 ...
##  $ yield: num  4.12 4.45 5.88 4.58 4.65 ...
##  $ row  : int  1 2 3 4 5 6 7 8 9 10 ...
##  $ col  : int  1 1 1 1 1 1 1 1 1 1 ...
```

```
with(d, table(rep, block))[, 1:6]
```

```
##     block
## rep  B1 B2 B3 B4 B5 B6
##   R1  4  4  4  4  4  4
##   R2  4  4  4  4  4  4
##   R3  4  4  4  4  4  4
```

4.2 品种作为固定效应：调整均值

当目的是比较品种时，将品种视为固定效应，区组视为随机效应。模型为

$$y_{ijk} = \mu + r_j + \tau_i + b_{k(j)} + e_{ijk}, \qquad b_{k(j)} \sim N(0, \sigma_b^2), \qquad e_{ijk} \sim N(0, \sigma_e^2).$$

```
fit_f <- mlreml(yield ~ rep + gen, random = ~ rep:block, data = d, trace = FALS
E)
summary(fit_f)
```

```
## MLREML fit (AI-REML)
## Observations: 72   Fixed-effect columns: 26   Iterations: 5 (converged)
## REML log-likelihood: -32.4492   AIC: 68.90   BIC: 72.56
##
## Variance parameters:
##                  estimate std.error z.ratio bound
## rep:block!sigma2  0.06195   0.03656    1.69     P
## R!units!sigma2    0.08522   0.02185    3.90     P
##
## Bound codes: P positive/free, B at boundary, F fixed.
```

```
wald(fit_f)
```

```
##          term df wald.inc    F.inc ddf.inc     p.inc wald.con    F.con ddf.c
on
## 1 (Intercept)  1  4338.49 4338.495   11.52 3.307e-16  4338.49 4338.495   11.
52
## 2         rep  2    18.42    9.212   11.52 4.078e-03    18.42    9.212   11.
52
## 3         gen 23   125.30    5.363   35.50 4.495e-06   125.30    5.363   35.
50
##       p.con   p.chisq
## 1 3.307e-16 0.000e+00
## 2 4.078e-03 9.981e-05
## 3 4.495e-06 4.588e-16
```

gen 的条件 Wald 检验检验的是在调整重复后所有品种均相等的假设。由于只有 72 个小区和 26 个固定效应列，残差自由度 46 高估了关于品种的信息，因为其中一部分信息来自不完全区组之间的比较。Kenward–Roger 方法给出 gen 的分母自由度为 35.5，rep 为 11.5（其信息主要来自 18 个不完全区组），并略微减小了 gen 的 F 统计量（5.363 而非 5.448）。χ^2 检验（p.chisq）的 p 值忽略了这种不确定性，因而过小。截距的条件统计量等于其递增统计量，因为每一项都包含截距。

品种的调整均值及其差值标准误通过 predict() 获得：

```
pf <- predict(fit_f, classify = "gen")
head(pf$pvals[order(-pf$pvals$predicted.value), ], 8)
```

```
##    gen predicted.value std.error
## 1  G01           5.108    0.1955
## 5  G05           5.037    0.1955
## 15 G15           4.969    0.1955
## 19 G19           4.840    0.1955
## 21 G21           4.795    0.1955
## 14 G14           4.776    0.1955
## 13 G13           4.758    0.1955
## 12 G12           4.755    0.1955
```

```
pf$avsed
```

```
## [1] 0.2647
```

```
range(pf$sed[upper.tri(pf$sed)])
```

```
## [1] 0.2574 0.2699
```

SED 并不恒定：共享区组的两个品种比从未同时出现的两个品种比较得更精确。这正是完全区组分析会忽略的信息。5 % 水平下的近似最小显著差数为 $t_{0.975,\mathrm{df}} \times \overline{\mathrm{SED}}$：

```
df_error <- nrow(d) - fit_f$p
qt(0.975, df_error) * pf$avsed
```

```
## [1] 0.5329
```

4.3 品种作为随机效应：BLUP 和遗传力

在育种计划中，品种是来自某一群体的样本，目的是预测其遗传值。将品种设为随机效应可获得 BLUP，它按照不确定性的大小将均值向总均值收缩。

```
fit_r <- mlreml(yield ~ rep, random = ~ gen + rep:block, data = d, trace = FALS
E)
summary(fit_r)
```

```
## MLREML fit (AI-REML)
## Observations: 72   Fixed-effect columns: 3   Iterations: 4 (converged)
## REML log-likelihood: -46.5969   AIC: 99.19   BIC: 105.90
##
## Variance parameters:
##                  estimate std.error z.ratio bound
## gen!sigma2        0.14290   0.05208    2.74     P
## rep:block!sigma2  0.07022   0.03734    1.88     P
## R!units!sigma2    0.08162   0.02029    4.02     P
##
## Bound codes: P positive/free, B at boundary, F fixed.
```

```
pr <- predict(fit_r, classify = "gen")
head(pr$pvals, 4)
```

```
##   gen predicted.value std.error
## 1 G01           4.981    0.1766
## 2 G02           4.484    0.1766
## 3 G03           3.695    0.1766
## 4 G04           4.486    0.1766
```

基于品种均值的广义遗传力可以用 $r = 3$ 次重复的经典公式计算，也可以用 Cullis et al.（2006）的广义遗传力计算，后者使用 BLUP 的平均 SED，适用于非平衡设计：

```
vpredict(fit_r, H2_classical ~ V1 / (V1 + V3 / 3))
```

```
##              estimate std.error
## H2_classical   0.8401   0.06254
```

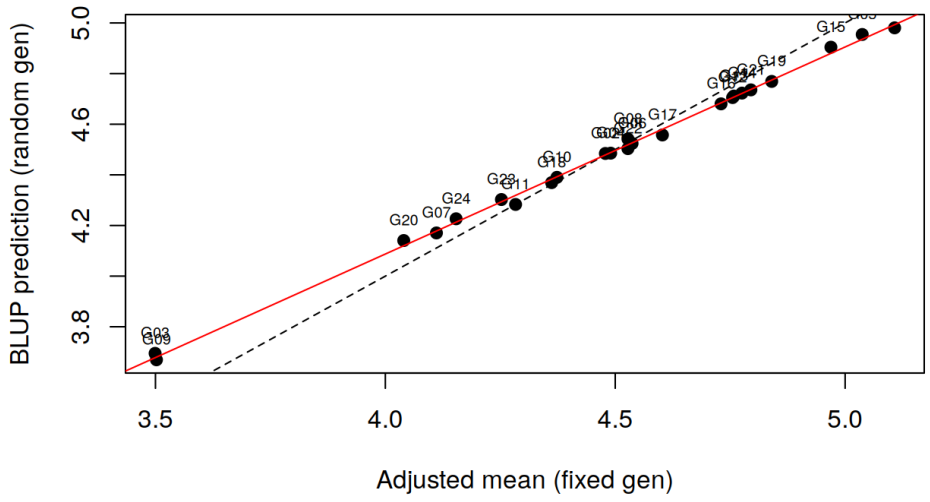
```
sg2 <- fit_r$theta[1]
H2_cullis <- 1 - pr$avsed^2 / (2 * sg2)
H2_cullis
```

```
## gen!sigma2
##     0.8092
```

4.4 调整均值与 BLUP 的比较

下图比较了调整均值（固定品种）与 BLUP（随机品种）。斜率小于 1 体现了 BLUP 的收缩。

```
plot(pf$pvals$predicted.value, pr$pvals$predicted.value, pch = 19,
     xlab = "Adjusted mean (fixed gen)", ylab = "BLUP prediction (random gen)")
abline(0, 1, lty = 2)
abline(lm(pr$pvals$predicted.value ~ pf$pvals$predicted.value), col = "red")
text(pf$pvals$predicted.value, pr$pvals$predicted.value, pf$pvals$gen, pos = 3,
 cex = 0.6)
```



燕麦试验中调整均值（固定品种）与 BLUP 预测值（随机品种）的对比。

品种的排名几乎相同，但 BLUP 更接近均值。在非平衡设计中，BLUP 还可能改变排名，因为信息较少的品种被收缩得更多。

4.5 不完全区组设计是否值得?

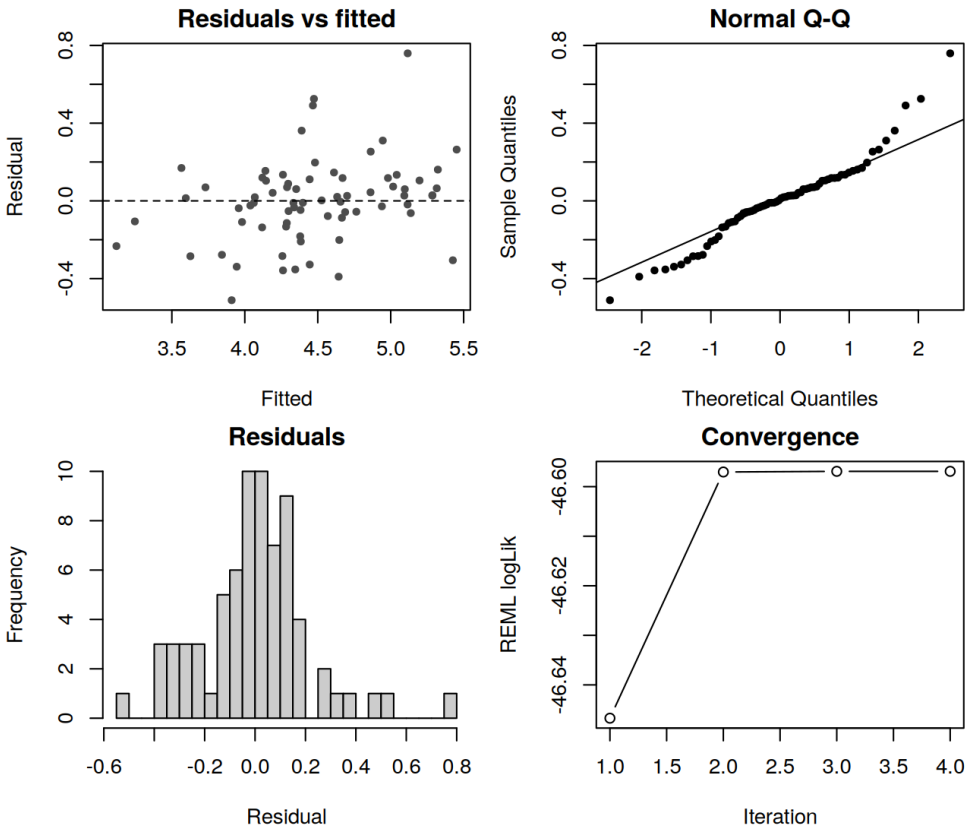
为了判断不完全区组是否捕获了变异，用似然比检验比较包含和不包含 rep:block 的模型。两个模型具有相同的固定效应，因此其 REML 似然具有可比性；又由于检验的是位于边界上的方差，因此使用 50:50 混合分布。

```
fit_r0 <- mlreml(yield ~ rep, random = ~ gen, data = d, trace = FALSE)
lrt(fit_r0, fit_r)

##   df LR.statistic  p.value  AIC0  AIC1  BIC0  BIC1
## 1  1        8.606 0.001675 105.8 99.19 110.3 105.9
```

4.6 诊断

```
plot(fit_r)
```



随机品种模型的诊断图。

条件残差与拟合值之间没有趋势，也没有明显偏离正态性。右下图显示了 AI 算法的收敛过程，在这个简单模型中只需很少的迭代次数。

4.7 用 lme4 进行验证

```
library(lme4)
l <- lmer(yield ~ rep + (1 | gen) + (1 | rep:block), data = d)
data.frame(MLREML = unname(fit_r$theta),
           lme4 = as.data.frame(VarCorr(l))$vcov,
           row.names = c("gen", "rep:block", "residual"))
```

```
##              MLREML    lme4
## gen        0.14290 0.14290
## rep:block 0.07022 0.07022
## residual  0.08162 0.08162
```

```
c(MLREML = fit_r$loglik, lme4 = as.numeric(logLik(l)))
```

```
## MLREML   lme4
##  -46.6  -46.6
```

两个程序的似然值在小数点后六位上一致。

5 实例 2：小麦试验的空间分析

5.1 数据

数据 gilmour.serpentine 来自 Gilmour、Cullis 和 Verbyla（1997）的论文，该论文确立了采用可分离自回归结构的空间分析作为澳大利亚作物试验的标准做法。数据包括 108 个小麦品种，采用 3 次重复的随机完全区组设计，布置在 22 行 × 15 列的网格上（330 个小区）。响应变量为产量。

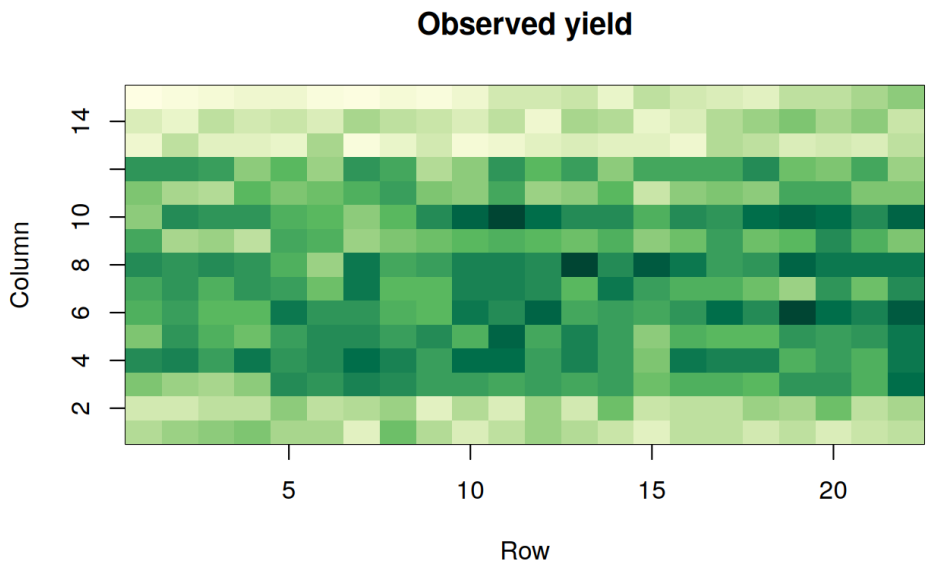
```
data(gilmour.serpentine)
d <- gilmour.serpentine
str(d)
```

```
## 'data.frame':    330 obs. of  5 variables:
##  $ col  : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ row  : int  1 2 3 4 5 6 7 8 9 10 ...
##  $ rep  : Factor w/ 3 levels "R1","R2","R3": 1 1 1 1 1 1 1 1 1 1 ...
##  $ gen  : Factor w/ 107 levels "(WWH*MM)*WR*",..: 4 10 15 17 21 32 33 34 72
74 ...
##  $ yield: int  483 526 557 564 498 510 344 600 466 370 ...
```

```
c(rows = length(unique(d$row)), columns = length(unique(d$col)))
```

```
##    rows columns
##      22      15
```

```
Ym <- tapply(d$yield, list(d$row, d$col), mean)
image(1:22, 1:15, Ym, col = hcl.colors(30, "YlGn", rev = TRUE),
      xlab = "Row", ylab = "Column", main = "Observed yield")
```



试验网格（行 × 列）上的观测产量。颜色越深表示产量越高。

上图已经提示存在沿行方向的肥力梯度以及完全重复无法吸收的局部变异。

5.2 完全区组模型

```
m1 <- mlreml(yield ~ rep, random = ~ gen, data = d, trace = FALSE)
summary(m1)$varcomp
```

```
##                 estimate std.error z.ratio bound
## gen!sigma2          1934     947.3   2.042     P
## R!units!sigma2     13329    1263.6  10.548     P
```

5.3 AR1 × AR1 空间模型

按照 Gilmour et al.（1997）的方法，将残差建模为行和列方向上的可分离自回归过程加上独立误差（*块金*），在 MLREML 中即为随机项 `units`：

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}_g\mathbf{g} + \boldsymbol{\eta} + \boldsymbol{\xi}, \qquad \boldsymbol{\xi} \sim N\left(\mathbf{0}, \sigma^2_{\xi}\,\boldsymbol{\Sigma}_r(\rho_r) \otimes \boldsymbol{\Sigma}_c(\rho_c)\right), \qquad \boldsymbol{\eta} \sim N\left(\mathbf{0}, \sigma^2_{\eta}\mathbf{I}\right).$$

```
m2 <- mlreml(yield ~ rep, random = ~ gen + units,
             residual = ~ ar1(row):ar1(col), data = d, trace = FALSE)
summary(m2)
```

```
## MLREML fit (AI-REML)
## Observations: 330   Fixed-effect columns: 3   Iterations: 16 (converged)
## REML log-likelihood: -1853.6433   AIC: 3717.29   BIC: 3736.24
##
## Variance parameters:
##                                estimate std.error z.ratio bound
## gen!sigma2                   2.583e+03 4.764e+02    5.42     P
## units!sigma2                 1.702e+03 2.356e+02    7.22     P
## R!ar1(row):ar1(col)!sigma2   3.954e+04 2.093e+04    1.89     P
## R!ar1(row):ar1(col)!row_cor 9.903e-01 5.309e-03  186.55     P
## R!ar1(row):ar1(col)!col_cor 8.202e-01 6.620e-02   12.39     P
```

```
##
## Bound codes: P positive/free, B at boundary, F fixed.
```

两个模型具有相同的固定效应，因此可以用 AIC 和 BIC 进行比较：

```
data.frame(model = c("complete blocks", "AR1 x AR1 + nugget"),
           logLik = c(m1$loglik, m2$loglik), AIC = c(m1$AIC, m2$AIC), BIC = c(m
1$BIC, m2$BIC))
```

```
##                 model logLik  AIC  BIC
## 1    complete blocks  -2043 4091 4099
## 2 AR1 x AR1 + nugget  -1854 3717 3736
```

相邻行之间的相关非常高，表明沿行方向存在平滑趋势，而列之间的相关较低。AIC 的改进幅度很大。

5.4 全局趋势

当变异函数显示半方差持续增加时，Gilmour et al.（1997）建议将线性趋势作为固定效应加入模型。将数值协变量 `row` 纳入固定部分，并用 Wald 检验进行检验：

```
m3 <- mlreml(yield ~ rep + row, random = ~ gen + units,
             residual = ~ ar1(row):ar1(col), data = d, trace = FALSE)
summary(m3)$varcomp
```

```
##                               estimate std.error z.ratio bound
## gen!sigma2                   2.581e+03 4.761e+02   5.421     P
## units!sigma2                 1.697e+03 2.351e+02   7.218     P
## R!ar1(row):ar1(col)!sigma2  4.194e+04 2.267e+04   1.850     P
## R!ar1(row):ar1(col)!row_cor 9.905e-01 5.225e-03 189.573     P
## R!ar1(row):ar1(col)!col_cor 8.303e-01 6.455e-02  12.863     P
```

```
wald(m3)
```

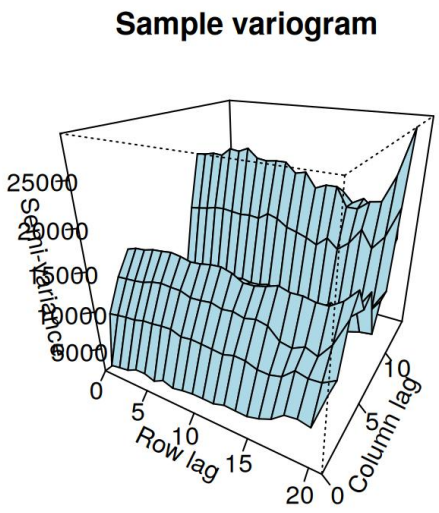
```
##          term df wald.inc   F.inc ddf.inc   p.inc wald.con   F.con ddf.con
 p.con
## 1 (Intercept)  1  16.7395 20.0048   3.443 0.01547  16.7395 20.0048   3.443 0.
01547
## 2         rep  2   1.8132  0.7871  11.472 0.47829   1.8166  0.7886  11.472 0.
47766
## 3         row  1   0.6921  0.5961   9.759 0.45838   0.6921  0.5961   9.759 0.
45838
##     p.chisq
## 1 4.288e-05
## 2 4.032e-01
## 3 4.055e-01
```

在本试验中，线性趋势不显著（$p = 0.46$，采用 Kenward–Roger 方法，该检验的分母自由度仅为 9.8）：行间相关接近 1 的自回归已经表示了该梯度。模型 `m2` 和 `m3` 的固定效应不同，因此其 REML 似然不可比较，判断依据为 Wald 检验。下面保留线性项只是为了说明其用法；使用 `m2` 得到的结果实际上相同。

5.5 样本变异函数

空间残差的变异函数是最有用的诊断工具。对于完全区组模型，它由条件残差计算得到；随距离增加的变异函数表明存在未建模的空间相关。

```
v1 <- variogram(m1, "row", "col")
```



完全区组模型残差的样本变异函数。

```
head(v1[order(v1$row.lag, v1$col.lag), ], 6)
```

```
##     row.lag col.lag gamma npairs
## 22        0       1  8657    308
## 44        0       2 12548    286
## 66        0       3 15256    264
## 88        0       4 10720    242
## 110       0       5 11402    220
## 132       0       6  9477    198
```

完全区组模型的半方差随行和列的滞后距离增加，并且在试验范围内没有趋于平稳；这正是 AR1 × AR1 模型所表示的空间相关。

5.6 精度的提高

更好模型的实际效果是对品种进行更精确的比较。为了比较精度，拟合固定品种模型并计算平均 SED：

```
m1f <- mlreml(yield ~ rep + gen, data = d, trace = FALSE)
m3f <- mlreml(yield ~ rep + row + gen, random = ~ units,
              residual = ~ ar1(row):ar1(col), data = d, trace = FALSE)
c(SED_blocks = predict(m1f, "gen")$avsed, SED_spatial = predict(m3f, "gen")$avs
ed)
```

```
##  SED_blocks SED_spatial
##       93.66       38.81
```

空间分析减小了比较的误差，这相当于在不增加试验成本的情况下用更多重复来评价品种。广义遗传力也相应提高：

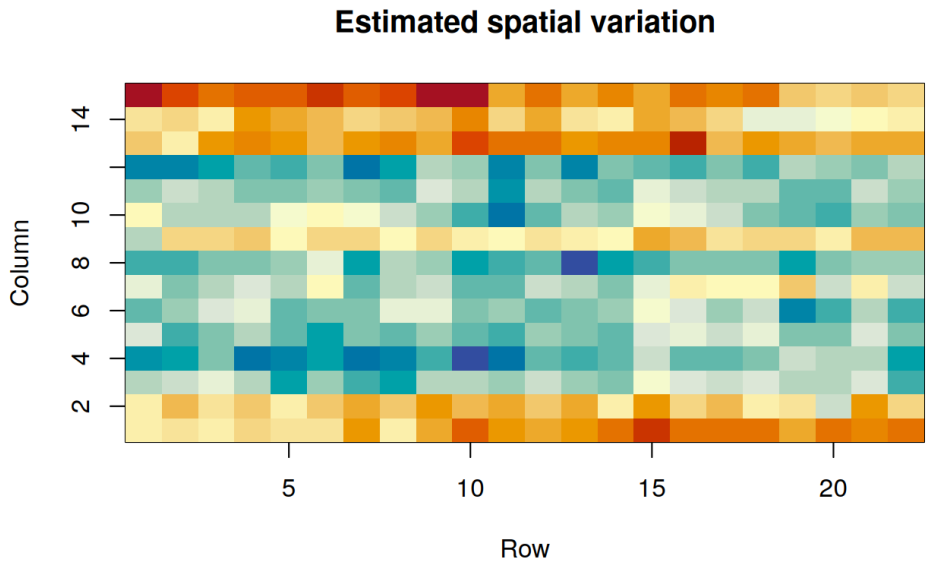
```
H2 <- function(fit) 1 - predict(fit, "gen")$avsed^2 / (2 * fit$theta[1])
c(blocks = H2(m1), spatial = H2(m3))

##  blocks.gen!sigma2 spatial.gen!sigma2
##             0.3080             0.7698
```

5.7 估计的空间趋势

模型预测的空间组分是数据与固定部分加遗传效应之差。下图在网格上展示了这一组分。

```
gb <- coef(m3, "random", "gen")
geff <- gb$blup[match(as.character(m3$data$gen), gb$level)]
spatial <- m3$y - m3$fixed_fitted - geff
Em <- tapply(spatial, list(m3$data$row, m3$data$col), mean)
image(1:22, 1:15, Em, col = hcl.colors(30, "RdYlBu"), xlab = "Row", ylab = "Col
umn",
      main = "Estimated spatial variation")
```



仅含遗传效应和固定效应的模型的残差（空间组分的估计）。

5.8 不规则间距数据

当单元不在规则网格上时（林分中的树木、GPS 定位的小区、缺株），结构 `sexp(x, y)` 用实际欧氏距离定义各向同性指数相关 $\rho^{d_{ij}}$。作为示例，我们使用 1,600 棵花旗松的材积数据（Johnson, 1998，见 `agridat`），从中随机抽取 450 棵树以获得不规则的空间格局。

```
data(johnson.douglasfir)
set.seed(11)
df <- johnson.douglasfir[sample(nrow(johnson.douglasfir), 450), ]
df$lv <- log(df$volume + 1)
f_iid <- mlreml(lv ~ 1, data = df, trace = FALSE)
f_exp <- mlreml(lv ~ 1, random = ~ units, residual = ~ sexp(row, col), data = d
f, trace = FALSE)
summary(f_exp)$varcomp
```

```
##                                      estimate std.error z.ratio bound
## units!sigma2                           5.8841    2.4044  2.4473     P
## R!sexp(row, col)!sigma2                0.8822    2.3803  0.3706     P
## R!sexp(row, col)!sexp(row,col)_cor     0.3581    0.6771  0.5289     P
```

```
lrt(f_iid, f_exp, boundary = FALSE)
```

```
##   df LR.statistic p.value AIC0 AIC1 BIC0 BIC1
## 1  2        1.031  0.5971 2141 2144 2145 2156
```

单位距离的相关以及似然的改进表明，由于竞争和微生境的作用，相邻树木的材积相似。距离为 d 的两棵树之间的相关为 $\hat{\rho}^d$；例如，在 1、3 和 5 个位置的距离上：

```
rho <- f_exp$theta[grep("_cor$", names(f_exp$theta))]
unname(rho^c(1, 3, 5))
```

```
## [1] 0.358088 0.045917 0.005888
```

6 实例 3：多环境试验和因子分析模型

6.1 数据

数据集 `besag.met`（Besag and Higdon, 1999；见 `agridat`）包含 64 个玉米品种在 6 个地点（*县*）的产量，每个地点有 3 次重复，每次重复分为 8 个各含 8 个小区的不完全区组：共 1,152 个小区。这是育种计划中典型的多环境试验（MET）。

```
data(besag.met)
d <- besag.met
str(d)
```

```
## 'data.frame':    1188 obs. of  7 variables:
##  $ county: Factor w/ 6 levels "C1","C2","C3",..: 1 1 1 1 1 1 1 1 1 1 ...
##  $ row   : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ col   : int  1 2 3 4 5 6 7 8 9 10 ...
##  $ rep   : Factor w/ 3 levels "R1","R2","R3": 1 1 1 1 1 1 1 1 1 1 ...
##  $ block : Factor w/ 8 levels "B1","B2","B3",..: 2 2 2 2 2 2 2 2 5 5 ...
##  $ yield : num  170 130 129 131 132 ...
##  $ gen   : Factor w/ 64 levels "G01","G02","G03",..: 42 58 26 10 34 50 2 18
45 61 ...
```

```
round(tapply(d$yield, d$county, mean), 1)
```

```
## C1 C2 C3 C4 C5 C6
## NA NA NA NA NA NA
```

```
round(tapply(d$yield, d$county, sd), 1)
```

```
## C1 C2 C3 C4 C5 C6
## NA NA NA NA NA NA
```

各地点的均值和标准差差异很大，预示着遗传方差和残差方差是异质的。

6.2 模型序列

参考的 MET 分析方法（Smith, Cullis and Thompson, 2001; 2005）对每个环境中的遗传效应 $\mathbf{u} = (\mathbf{u}_1', \ldots, \mathbf{u}_E')'$ 建模为

$$\mathrm{Var}(\mathbf{u}) = \mathbf{\Sigma}_E \otimes \mathbf{I}_N,$$

并比较环境间遗传协方差 $E \times E$ 矩阵 $\mathbf{\Sigma}_E$ 的不同结构。所有结构共享相同的固定效应（地点均值）、设计（地点内的重复和区组）以及每个地点特定的残差方差。

环境间遗传协方差的结构。

模型	$\mathbf{\Sigma}_E$	遗传参数
对角	$\mathrm{diag}(\sigma^2_{g1}, \ldots, \sigma^2_{gE})$	E
FA(1)	$\boldsymbol{\lambda}\boldsymbol{\lambda}' + \mathbf{\Psi}$	$2E$
FA(2)	$\mathbf{\Lambda}\mathbf{\Lambda}' + \mathbf{\Psi}$	$3E - 1$
非结构化 完全		$E(E+1)/2$

对角模型假设环境间没有遗传相关，而这在实际中从不成立。非结构化模型是最一般的模型，但当环境较多时，其参数过多，往往难以估计。因子分析模型是折中的选择：用少数几个因子即可描述大部分遗传协方差，并使基因型 × 环境交互作用易于解释。

```
f_diag <- mlreml(yield ~ county, random = ~ county:rep + county:rep:block + dia
g(county):id(gen),
                 residual = ~ diag(county):units, data = d, trace = FALSE)
f_fa1 <- mlreml(yield ~ county, random = ~ county:rep + county:rep:block + fa(c
ounty, 1):id(gen),
                residual = ~ diag(county):units, data = d, trace = FALSE, maxit
 = 100)
f_fa2 <- mlreml(yield ~ county, random = ~ county:rep + county:rep:block + fa(c
ounty, 2):id(gen),
                residual = ~ diag(county):units, data = d, trace = FALSE, maxit
 = 200)
f_us <- mlreml(yield ~ county, random = ~ county:rep + county:rep:block + us(co
unty):id(gen),
               residual = ~ diag(county):units, data = d, trace = FALSE, maxit
= 100)
cmp <- data.frame(model = c("diag", "FA(1)", "FA(2)", "US"),
                  parameters = sapply(list(f_diag, f_fa1, f_fa2, f_us), functio
n(f) sum(f$free)),
                  logLik = sapply(list(f_diag, f_fa1, f_fa2, f_us), `[[`, "logl
ik"),
```

```
                  AIC = sapply(list(f_diag, f_fa1, f_fa2, f_us), `[[`, "AIC"),
                  BIC = sapply(list(f_diag, f_fa1, f_fa2, f_us), `[[`, "BIC"),
                  converged = sapply(list(f_diag, f_fa1, f_fa2, f_us), `[[`, "c
onverged"))
cmp
```

```
##   model parameters logLik  AIC  BIC converged
## 1  diag         14  -4849 9726 9796      TRUE
## 2 FA(1)         20  -4814 9668 9769      TRUE
## 3 FA(2)         25  -4812 9675 9801      TRUE
## 4    US         29  -4812 9681 9827      TRUE
```

对角模型显然最差：忽略地点间的遗传相关，相对于 FA(1) 损失了 34.9 个对数似然单位，而仅多了 6 个参数。根据 AIC，最佳模型为 FA(1)。从 FA(1) 到 FA(2) 再到非结构化模型，似然值逐步增加——由于模型是嵌套的，这是必然的——但相对于所增加的参数个数，增幅很小。似然在第二个因子的方向上非常平坦，这是 MET 分析中的常见情况，在 ASReml 中也会出现。FA(2) 模型有若干特殊方差位于边界上；借助对边界的有效集处理（第 2.4.1 节），它们不会使联合 AI 步停滞，模型能够收敛。FA(2) 的对数似然位于 FA(1) 和非结构化模型之间，不改变模型的选择。

FA(1) 与非结构化模型（两者具有相同的固定效应）之间的 LRT 为：

```
lrt(f_fa1, f_us, boundary = FALSE)
```

```
##   df LR.statistic p.value AIC0 AIC1 BIC0 BIC1
## 1  9        4.712  0.8587 9668 9681 9769 9827
```

6.3 FA(1) 模型的解释

`vc_matrix()` 返回估计的遗传协方差矩阵、其相关矩阵、载荷、特殊方差以及各环境遗传方差中由因子解释的百分比。

```
vfa <- vc_matrix(f_fa1, "fa(county, 1):id(gen)")
round(vfa$cor, 2)
```

```
##      C1   C2   C3   C4   C5   C6
## C1 1.00 0.86 0.68 0.86 0.86 0.40
## C2 0.86 1.00 0.79 1.00 1.00 0.46
## C3 0.68 0.79 1.00 0.79 0.79 0.36
## C4 0.86 1.00 0.79 1.00 1.00 0.46
## C5 0.86 1.00 0.79 1.00 1.00 0.46
## C6 0.40 0.46 0.36 0.46 0.46 1.00
```

```
data.frame(loading = round(vfa$loadings[, 1], 2), psi = signif(vfa$psi, 3),
           pct_explained = round(vfa$pct_variance, 1))
```

```
##    loading      psi pct_explained
## C1    6.49 1.46e+01          74.3
## C2    5.15 8.44e-07         100.0
## C3    7.57 3.47e+01          62.3
## C4    5.34 7.30e-07         100.0
```

```
## C5    8.90 6.70e-07          100.0
## C6    2.35 2.05e+01           21.3
```

```
summary(f_fa1)$varcomp[grepl("fa1|var_", rownames(summary(f_fa1)$varcomp)), ]
```

```
##                                        estimate std.error   z.ratio bound
## fa(county, 1):id(gen)!county_fa1_C1 6.491e+00     1.366 4.752e+00     P
## fa(county, 1):id(gen)!county_fa1_C2 5.149e+00     1.319 3.904e+00     P
## fa(county, 1):id(gen)!county_fa1_C3 7.569e+00     1.567 4.830e+00     P
## fa(county, 1):id(gen)!county_fa1_C4 5.345e+00     1.419 3.765e+00     P
## fa(county, 1):id(gen)!county_fa1_C5 8.898e+00     1.392 6.391e+00     P
## fa(county, 1):id(gen)!county_fa1_C6 2.355e+00     1.710 1.377e+00     P
## fa(county, 1):id(gen)!county_var_C1 1.458e+01    16.469 8.855e-01     P
## fa(county, 1):id(gen)!county_var_C2 8.438e-07    16.874 5.001e-08     B
## fa(county, 1):id(gen)!county_var_C3 3.472e+01    21.181 1.639e+00     P
## fa(county, 1):id(gen)!county_var_C4 7.300e-07    19.599 3.725e-08     B
## fa(county, 1):id(gen)!county_var_C5 6.700e-07    16.851 3.976e-08     B
## fa(county, 1):id(gen)!county_var_C6 2.053e+01    29.724 6.907e-01     P
```

有几个特殊方差 ψ 位于边界上（代码 B）。在这些地点，公共因子解释了全部遗传方差，它们之间估计的遗传相关为 1。这一结果在重复次数较少的试验中很常见，并不表示拟合错误；它表示数据无法将特殊方差与零区分开。位于边界上的参数的标准误无效。

```
vus <- vc_matrix(f_us, "us(county):id(gen)")
op <- par(mfrow = c(1, 2), mar = c(3, 3, 2, 1))
for (M in list(US = vus$cor, FA1 = vfa$cor)) {
  image(1:6, 1:6, M[, 6:1], zlim = c(-1, 1), col = hcl.colors(21, "RdBu"),
        axes = FALSE, xlab = "", ylab = "")
  axis(1, 1:6, rownames(M), cex.axis = 0.7); axis(2, 1:6, rev(rownames(M)), cex.
axis = 0.7, las = 1)
  text(rep(1:6, 6), rep(6:1, each = 6), sprintf("%.2f", M), cex = 0.6)
}
```



用非结构化模型（左）和 FA(1)（右）估计的地点间遗传相关。

```
par(op)
```

6.4 按环境的预测和总体表现

每个品种在每个地点的预测值结合了地点的固定均值和该品种在该地点的 BLUP。分类 `county:gen` 包含因子分析项，因为该项的两个因子都在分类中：

```
pr <- predict(f_fa1, classify = "county:gen", sed = FALSE)
P <- with(pr$pvals, tapply(predicted.value, list(gen, county), mean))
round(head(P[order(-rowMeans(P)), ], 10), 1)
```

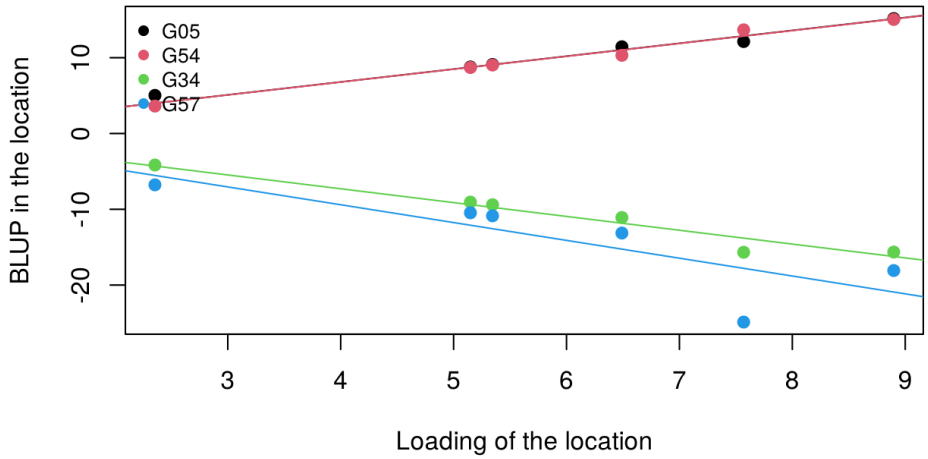
```
##        C1   C2    C3    C4    C5   C6
## G05 160.6 64.8 100.0 153.7 130.6 92.7
## G54 159.5 64.8 101.6 153.7 130.5 91.3
## G45 157.4 63.1 100.1 151.9 127.5 89.8
## G55 158.7 62.6 101.1 151.4 126.8 88.8
## G61 155.7 61.4 101.0 150.1 124.6 91.6
## G32 157.1 61.8 100.2 150.6 125.4 88.5
## G51 157.3 62.0  96.1 150.8 125.7 91.2
## G30 155.4 60.9  98.0 149.7 123.8 89.1
## G22 155.0 61.2  94.0 149.9 124.2 91.0
## G52 155.8 60.6  96.1 149.4 123.3 89.8
```

在载荷为正的 FA(1) 模型中，总体表现的一个自然度量是每个品种的因子得分乘以平均载荷（Smith and Cullis, 2018）。由于 $\mathbf{u}_i = \boldsymbol{\lambda} f_i + \boldsymbol{\delta}_i$，可以根据每个品种的 BLUP 用最小二乘法估计得分：

```
U <- matrix(coef(f_fa1, "random", "fa(county, 1):id(gen)")$blup, ncol = 6,
            dimnames = list(levels(d$gen), levels(d$county)))
lam <- vfa$loadings[, 1]
score <- drop(U %*% lam / sum(lam^2))
OP <- mean(lam) * score
head(sort(OP, decreasing = TRUE), 10)
```

```
##    G05    G54    G55    G45    G32    G61    G51    G30    G09    G52
## 10.149 10.131  8.381  8.330  7.407  7.220  6.954  6.159  5.860  5.709
```

```
top <- names(sort(OP, decreasing = TRUE))[c(1, 2, 63, 64)]
plot(range(lam), range(U[top, ]), type = "n", xlab = "Loading of the location",
     ylab = "BLUP in the location")
for (k in seq_along(top)) {
  points(lam, U[top[k], ], pch = 19, col = k)
  abline(0, score[top[k]], col = k)
}
legend("topleft", top, col = seq_along(top), pch = 19, bty = "n", cex = 0.8)
```



潜回归图：四个品种在各地点的 BLUP 对该地点载荷的散点图。各直线的斜率等于各品种的得分。

斜率大且为正的品种在载荷高的地点表现更优；点在直线周围的分散程度是交互作用中未被公共因子解释的部分。

6.5 MET 分析的建议

1. 从异质的残差方差和遗传方差（`diag`）开始，以检查基础模型的拟合情况。
2. 拟合 FA(1)，并在 AIC 或 LRT 支持、且某些环境中被解释的遗传方差百分比较低时增加因子个数。
3. 仅在环境较少时使用 `us`；当环境超过 8–10 个时，它往往无法收敛或收敛到奇异矩阵。
4. 检查位于边界上的参数，并在算法未收敛时增大 `maxit`；似然尚未收敛的 FA 模型仍可能具有稳定的预测值，这可以通过比较各次迭代之间的 BLUP 来检查。

7 实例 4：599 个小麦品系的基因组预测（GBLUP）

7.1 数据

`BGLR` 软件包中的数据集 `wheat`（Crossa et al., 2010; Pérez and de los Campos, 2014）包含 599 个 CIMMYT 小麦品系，这些品系用 1,279 个 DArT 标记（编码为 0/1）进行了基因分型，还包含它们的系谱亲缘关系矩阵以及在四个环境（E1 至 E4）中评价的籽粒产量。它是比较基因组选择方法时使用最广泛的数据集之一。

```
library(BGLR)
data(wheat)
ids <- paste0("L", 1:599)
```

```r
M <- wheat.X; rownames(M) <- ids
A <- wheat.A; dimnames(A) <- list(ids, ids)
Y <- wheat.Y; rownames(Y) <- ids
dim(M); table(M)

## [1]  599 1279

## M
##      0      1
## 336588 429533

round(cor(Y), 2)

##       1     2     4     5
## 1  1.00 -0.02 -0.19 -0.12
## 2 -0.02  1.00  0.66  0.41
## 4 -0.19  0.66  1.00  0.39
## 5 -0.12  0.41  0.39  1.00
```

7.2 质量控制和基因组矩阵

DArT 标记是显性标记，编码为 0/1。为构建 **G**，我们将其重新编码为 0/2（这些品系是自交系，因此每个位点都是纯合的），并进行质量控制：

```r
qc <- snp_qc(2 * M, maf = 0.05, callrate = 0.9)
qc$report

##   markers_in removed_callrate removed_maf markers_out individuals_in individ
uals_out
## 1       1279                0          96        1183            599
     599

G <- Gmatrix(qc$M, method = "VanRaden")
summary(diag(G))

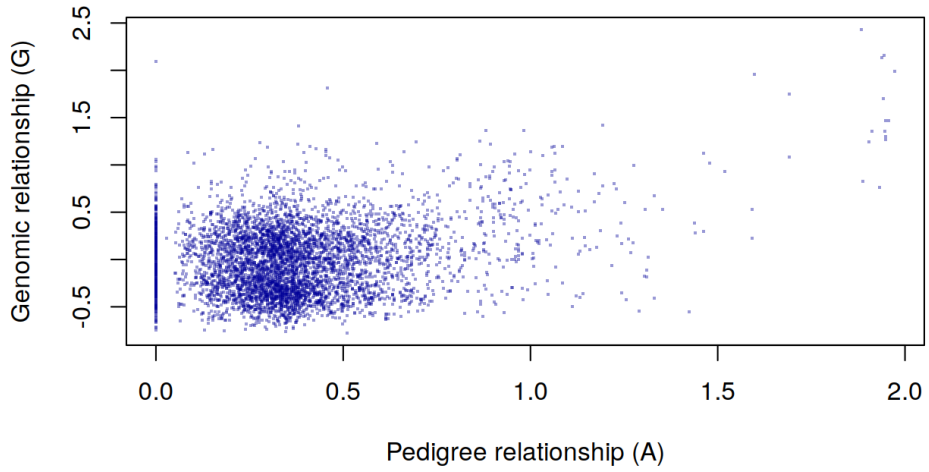
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    1.34    1.77    2.00    2.00    2.23    2.88

summary(diag(A))

##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    1.56    1.98    1.99    1.98    2.00    2.00
```

A 的对角线接近 2，这与自交系的预期一致（$1+F$，其中 $F \approx 1$）。**G** 的对角线均值也为 2，但在品系间的变化要大得多（从 1.3 到 2.9）：它衡量的是相对于已基因分型群体的实际近交程度，而系谱只给出其期望值。矩阵之间尺度的差异不影响预测，因为这种差异会被遗传方差吸收，但它确实影响对 σ_g^2 的解释。两个矩阵之间的关系如下所示：

```r
up <- upper.tri(A)
set.seed(1); s <- sample(which(up), 5000)
plot(A[s], G[s], pch = ".", cex = 2, col = rgb(0, 0, 0.6, 0.4),
     xlab = "Pedigree relationship (A)", ylab = "Genomic relationship (G)")
```



系谱亲缘关系与基因组亲缘关系的对比（非对角元素）。

```
cor(A[up], G[up])
```

```
## [1] 0.2469
```

中等程度的相关反映出：系谱预测的是期望亲缘关系，而标记衡量的是实际亲缘关系，后者由于孟德尔分离而在期望值周围变动。

7.3 单环境 GBLUP

环境 E1 的 GBLUP 模型为 $\mathbf{y} = \mathbf{1}\mu + \mathbf{g} + \mathbf{e}$，$\mathbf{g} \sim N(\mathbf{0}, \sigma_g^2 \mathbf{G})$。分别用通用引擎和函数 `gblup()` 进行拟合，后者利用 $\mathbf{G}$ 的谱分解，将 REML 化为一维优化问题。

```
G <- G + diag(1e-4, nrow(G))      # small numerical regularisation
d1 <- data.frame(gen = ids, y = Y[, 1])
t_general <- system.time(f1 <- mlreml(y ~ 1, random = ~ vm(gen, G), data = d1,
trace = FALSE))
y1 <- setNames(Y[, 1], ids)
t_spectral <- system.time(g1 <- gblup(y1, G))
summary(f1)$varcomp
```

```
##                    estimate std.error z.ratio bound
## vm(gen, G)!sigma2   0.2942   0.05462   5.387     P
## R!units!sigma2      0.5551   0.04607  12.049     P
```

```
g1$varcomp
```

```
## sigma2_g sigma2_e       h2
##   0.2942   0.5551   0.3464
```

```
c(general = t_general[3], spectral = t_spectral[3])
```

```
##  general.elapsed spectral.elapsed
##            0.209            0.061
```

```
c(logLik_general = f1$loglik, logLik_spectral = g1$loglik)
```

```
##  logLik_general logLik_spectral
##          -794.5          -794.5
```

```
cor(f1$blups[[1]]$blup, g1$gebv[f1$blups[[1]]$level])
```

```
## [1] 1
```

两种实现给出相同的似然和相同的 GEBV。估计的基因组遗传力为 0.35。已测表型品系的 GEBV 可靠性可直接获得：

```
summary(f1$blups[[1]]$reliability)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   0.603   0.717   0.754   0.763   0.809   0.964
```

7.4 预测未测表型的品系

基因组选择的目的是预测没有表型的候选个体。如果去掉 120 个品系的表型，`vm()` 仍然可以预测它们，因为它们包含在 **G** 中；只需从数据中删除它们的记录即可：

```
set.seed(2024)
test <- sample(ids, 120)
f_tr <- mlreml(y ~ 1, random = ~ vm(gen, G), data = subset(d1, !gen %in% test),
 trace = FALSE)
b <- f_tr$blups[[1]]
pred <- b$blup[match(test, b$level)]
c(correlation = cor(pred, Y[test, 1]),
  mean_reliability_test = mean(b$reliability[match(test, b$level)]))
```

```
##           correlation mean_reliability_test
##                0.5457                0.6374
```

7.5 交叉验证：系谱、标记以及两者结合

函数 `cv_gblup()` 重复进行随机的 k 折划分。我们比较系谱（**A**）、标记（**G**）以及同时包含两个矩阵的模型的预测能力；在 MLREML 中，后者写成作用于同一因子的两个随机项。

```
Ar <- A + diag(1e-4, nrow(A))
cvA <- cv_gblup(y1, Ar, folds = 5, reps = 4, seed = 3)
cvG <- cv_gblup(y1, G, folds = 5, reps = 4, seed = 3)
data.frame(matrix = c("A (pedigree)", "G (markers)"),
           mean_r = c(mean(cvA$cor), mean(cvG$cor)),
           sd_r = c(sd(cvA$cor), sd(cvG$cor)))
```

```
##         matrix mean_r   sd_r
## 1 A (pedigree) 0.4157 0.0615
## 2  G (markers) 0.4909 0.0551
```

```
f_AG <- mlreml(y ~ 1, random = ~ vm(gen, Ar) + vm(gen, G), data = d1, trace = F
ALSE)
summary(f_AG)$varcomp
```

```
##                     estimate std.error z.ratio bound
## vm(gen, Ar)!sigma2   0.1127   0.04147   2.717     P
```

```
## vm(gen, G)!sigma2    0.2351   0.05213   4.510     P
## R!units!sigma2       0.4519   0.05102   8.856     P
```

对双核模型使用相同的划分：

```
set.seed(3); fold <- sample(rep(1:5, length.out = 599))
r_AG <- sapply(1:5, function(k) {
  tr <- d1[fold != k, ]
  f <- mlreml(y ~ 1, random = ~ vm(gen, Ar) + vm(gen, G), data = tr, trace = FA
LSE, pev = FALSE)
  te <- ids[fold == k]
  p <- f$blups[[1]]$blup[match(te, f$blups[[1]]$level)] + f$blups[[2]]$blup[mat
ch(te, f$blups[[2]]$level)]
  cor(p, Y[te, 1])
})
mean(r_AG)

## [1] 0.5161
```

7.6 多环境 GBLUP

利用四个环境，我们拟合一个基因组 MET 模型，其中每个品系在每个环境中的遗传效应的协方差为 $\boldsymbol{\Sigma}_E \otimes \mathbf{G}$（Burgueño et al., 2012），并使用环境特定的残差方差：

```
dl <- data.frame(gen = rep(ids, 4), env = factor(rep(paste0("E", 1:4), each = 5
99)), y = as.vector(Y))
t_met <- system.time(
  fm <- mlreml(y ~ env, random = ~ us(env):vm(gen, G), residual = ~ diag(env):u
nits,
               data = dl, trace = FALSE, maxit = 100))
t_met[3]

## elapsed
##   65.96

summary(fm)

## MLREML fit (AI-REML)
## Observations: 2396   Fixed-effect columns: 4   Iterations: 15 (converged)
## REML log-likelihood: -3054.2139   AIC: 6136.43   BIC: 6217.35
##
## Variance parameters:
##                                estimate std.error z.ratio bound
## us(env):vm(gen, G)!env_E1:E1  0.29972   0.05433    5.52     P
## us(env):vm(gen, G)!env_E2:E1 -0.07022   0.04270   -1.64     P
## us(env):vm(gen, G)!env_E2:E2  0.57991   0.07460    7.77     P
## us(env):vm(gen, G)!env_E3:E1 -0.10855   0.04109   -2.64     P
## us(env):vm(gen, G)!env_E3:E2  0.52893   0.06206    8.52     P
## us(env):vm(gen, G)!env_E3:E3  0.49306   0.06739    7.32     P
## us(env):vm(gen, G)!env_E4:E1 -0.12528   0.03693   -3.39     P
## us(env):vm(gen, G)!env_E4:E2  0.34978   0.04934    7.09     P
## us(env):vm(gen, G)!env_E4:E3  0.35240   0.04828    7.30     P
## us(env):vm(gen, G)!env_E4:E4  0.34639   0.05632    6.15     P
## R!diag(env):units!env_E1      0.55463   0.04568   12.14     P
## R!diag(env):units!env_E2      0.41498   0.03492   11.88     P
## R!diag(env):units!env_E3      0.50242   0.03863   13.01     P
```

```
## R!diag(env):units!env_E4      0.56067   0.04425   12.67     P
##
## Bound codes: P positive/free, B at boundary, F fixed.
```

```
round(vc_matrix(fm, "us(env):vm(gen, G)")$cor, 2)
```

```
##       E1    E2    E3    E4
## E1  1.00 -0.17 -0.28 -0.39
## E2 -0.17  1.00  0.99  0.78
## E3 -0.28  0.99  1.00  0.85
## E4 -0.39  0.78  0.85  1.00
```

环境间的遗传相关比表型相关更为极端：E2、E3 和 E4 彼此强相关，而 E1 与其他环境的遗传相关为负。MET 模型正是利用这种结构，根据一个品系在其他环境中的数据来预测其在某一环境中的表现（Burgueño et al., 2012 的 CV2 方案）。

```
set.seed(5)
hidden <- sample(ids, 120)
dtr <- dl[!(dl$env == "E1" & dl$gen %in% hidden), ]
fm_tr <- mlreml(y ~ env, random = ~ us(env):vm(gen, G), residual = ~ diag(env):
units,
                data = dtr, trace = FALSE, maxit = 100, pev = FALSE)
b <- fm_tr$blups[[1]]
p_met <- b$blup[match(paste0("E1:", hidden), b$level)]
y_e1 <- y1; y_e1[hidden] <- NA
p_uni <- gblup(y_e1, G)$gebv[hidden]
c(single_environment = cor(p_uni, Y[hidden, 1]), multi_environment = cor(p_met,
 Y[hidden, 1]))
```

```
## single_environment  multi_environment
##             0.3651             0.3438
```

在本例中，多环境模型并没有优于单环境模型（0.344 对 0.365）。在 CV2 方案中，MET 模型利用同一品系在其他环境中的记录，但 E1 与 E2–E4 的遗传相关很弱且为负，因此这些记录对 E1 提供的信息很少，不足以弥补估计更多参数的代价。当环境之间呈正相关时，MET 模型在 CV2 中的增益通常很大（Burgueño et al., 2012）；这一结果说明其益处取决于 $\boldsymbol{\Sigma}_E$ 的结构。

7.7 实用说明

- `gblup()` 便于处理具有同质残差的单一遗传效应，它也是 `cv_gblup()` 的基础；对于 599 个品系，只需不到一秒。当个体数达到数千个时，其成本主要由谱分解决定（第 15 章）。
- 对于包含更多项、异质残差、多个环境或多个性状的模型，需要使用带 `vm()` 的 `mlreml()`。
- 个体数多于标记数的矩阵 **G** 是奇异的；MLREML 不对其求逆，但为了数值稳定性，建议像上面那样在对角线上加一个小常数。

8 实例 5：奶牛中带系谱的动物模型

8.1 数据

pedigreemm 软件包（Vazquez et al., 2010）包含 milk，其中有 57 个牛群中 1,359 头荷斯坦奶牛的 3,397 条泌乳记录，以及 pedCowsR，即这些奶牛及其祖先的系谱（6,547 头动物）。每条记录包含 305 天产奶量、乳脂量和乳蛋白量以及胎次（1 至 5）。

```
library(pedigreemm)
data(milk)
milk$animal <- as.character(milk$id)
milk$milk_t <- milk$milk / 1000    # tonnes
milk$fat_h <- milk$fat / 100       # hundreds of kg
milk$lact <- factor(milk$lact)
table(table(milk$animal))

##
##   1   2   3   4   5
## 337 405 314 207  96
```

8.2 准备系谱

pedigree_prepare() 对未知亲本重新编码，将未作为个体出现的亲本作为奠基者加入，检测错误，并对系谱排序，使亲本位于其后代之前。

```
p <- pedCowsR
ped <- data.frame(id = p@label, sire = p@label[p@sire], dam = p@label[p@dam])
pp <- pedigree_prepare(ped)
head(pp)

##   id sire  dam sire_i dam_i gen
## 1  1 <NA> <NA>      0     0   0
## 2  2 <NA> <NA>      0     0   0
## 3  3 <NA> <NA>      0     0   0
## 4  4 <NA> <NA>      0     0   0
## 5  5 <NA> <NA>      0     0   0
## 6  6 <NA> <NA>      0     0   0

table(generation = pp$gen)

## generation
##    0    1    2    3    4    5    6    7
## 2420 1208  777  612  757  562  173   38

c(animals = nrow(pp), with_sire = sum(pp$sire_i > 0), with_dam = sum(pp$dam_i >
 0))

##   animals with_sire  with_dam
##      6547      2645      3454

t_A <- system.time(A <- Amatrix(pp))
Fi <- inbreeding_coef(pp)
t_A[3]
```

```
## elapsed
##   0.622
```

```
summary(Fi[Fi > 0])
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## 0.00049 0.00781 0.01562 0.03744 0.03125 0.25000
```

```
sum(Fi > 0)
```

```
## [1] 31
```

```
all.equal(unname(diag(A) - 1), unname(Fi))
```

```
## [1] TRUE
```

```
Ai <- Ainverse(pp)
c(dim = nrow(Ai), non_zeros = length(Ai@x), density = length(Ai@x) / nrow(Ai)^2)
```

```
##       dim non_zeros   density
## 6.547e+03 1.460e+04 3.405e-04
```

6,547 头动物的稠密 **A** 矩阵约占 340 MB。其逆矩阵直接用 Henderson 规则构建，非常稀疏。用 Meuwissen 和 Luo 算法计算的近交系数与 **A** 的对角线一致。

8.3 头胎泌乳的动物模型

头胎产奶量的动物模型（Henderson, 1984）为

$$y_{ij} = \mu + h_j + a_i + e_{ij}, \qquad \mathbf{a} \sim N(\mathbf{0}, \sigma_a^2 \mathbf{A}), \qquad \mathbf{h} \sim N(\mathbf{0}, \sigma_h^2 \mathbf{I}),$$

其中 h_j 是牛群效应，由于若干牛群的奶牛数量很少，此处将其设为随机效应。

```
m1 <- subset(milk, lact == 1)
t_m1 <- system.time(
  a1 <- mlreml(milk_t ~ 1, random = ~ id(herd) + vm(animal, A), data = m1, trac
e = FALSE))
t_m1[3]
```

```
## elapsed
##   2.171
```

```
summary(a1)
```

```
## MLREML fit (AI-REML)
## Observations: 1314   Fixed-effect columns: 1   Iterations: 6 (converged)
## REML log-likelihood: -3605.4877   AIC: 7216.98   BIC: 7232.52
##
## Variance parameters:
##                       estimate std.error z.ratio bound
## id(herd)!sigma2         5.6462    1.3650    4.14     P
## vm(animal, A)!sigma2    0.6750    0.8654    0.78     P
## R!units!sigma2         12.3830    0.9616   12.88     P
##
## Bound codes: P positive/free, B at boundary, F fixed.
```

```
vpredict(a1, h2 ~ V2 / (V1 + V2 + V3))
```

```
##    estimate std.error
## h2  0.03609   0.04629
```

估计的遗传力较低，其标准误较大，因为每头奶牛只有一条记录，且系谱中有表型的奶牛之间亲缘关系较少。系谱中全部 6,547 头动物的育种值（EBV）都可以得到预测，包括公牛和无记录的祖先：

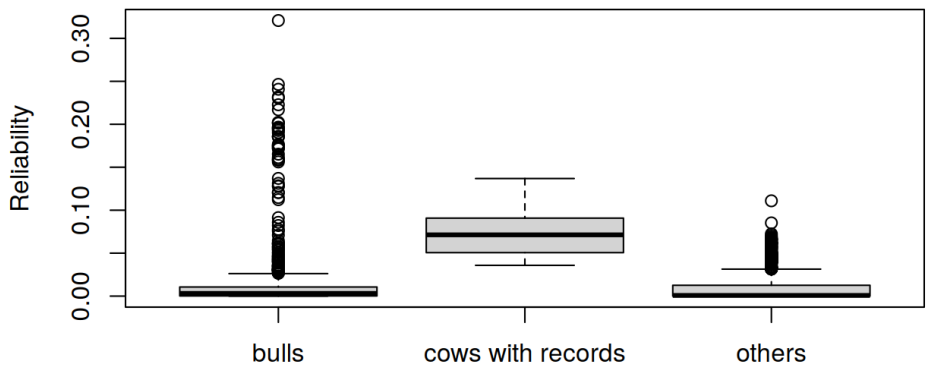
```
ebv <- coef(a1, "random", "vm(animal, A)")
nrow(ebv)

## [1] 6547

bulls <- unique(pp$sire[pp$sire_i > 0])
ebv_bulls <- ebv[ebv$level %in% bulls, ]
head(ebv_bulls[order(-ebv_bulls$blup), ], 8)

##      level   blup    pev     se reliability
## 4742  3749 0.7434 0.5434 0.7372     0.19497
## 5020  1630 0.5761 0.5125 0.7159     0.24076
## 4603  2896 0.5031 0.5393 0.7343     0.20114
## 4743  3754 0.4531 0.5426 0.7366     0.19616
## 5069  2833 0.4063 0.5496 0.7413     0.18586
## 3953  2863 0.2970 0.5449 0.7382     0.19282
## 3655  1424 0.2847 0.6334 0.7959     0.06166
## 4432  1679 0.2505 0.5194 0.7207     0.23050

group <- ifelse(ebv$level %in% m1$animal, "cows with records",
                ifelse(ebv$level %in% bulls, "bulls", "others"))
boxplot(reliability ~ group, data = cbind(ebv, group), ylab = "Reliability", xl
ab = "")
```



有记录奶牛、公牛以及系谱中其余动物的 EBV 可靠性。

尽管公牛自身没有记录，它们的可靠性却高于只有一条记录的奶牛，因为其 EBV 汇集了所有女儿的信息。不过，由于遗传力如此之低，所有可靠性都不高。

8.4 包含所有胎次的重复力模型

当每头奶牛有多个胎次时，遗传值 a_i 与永久环境 p_i 被区分开来，后者为一头奶牛的所有记录所共有，但不可遗传：

$$y_{ijk} = \mu + \ell_k + h_j + a_i + p_i + e_{ijk}, \qquad \mathbf{p} \sim N\left(\mathbf{0}, \sigma_p^2 \mathbf{I}\right).$$

在 MLREML 中，永久环境只是使用同一动物变量和单位矩阵结构的第二个项：

```
t_rep <- system.time(
  a2 <- mlreml(milk_t ~ lact, random = ~ id(herd) + vm(animal, A) + id(animal),
               data = milk, trace = FALSE))
t_rep[3]
```

```
## elapsed
##   24.67
```

```
summary(a2)$varcomp
```

```
##                       estimate std.error z.ratio bound
## id(herd)!sigma2         4.4460    1.0408   4.272     P
## vm(animal, A)!sigma2    0.7982    0.7329   1.089     P
## id(animal)!sigma2       4.7206    0.7970   5.923     P
## R!units!sigma2         10.3955    0.3236  32.121     P
```

```
vpredict(a2, h2 ~ V2 / (V1 + V2 + V3 + V4))
```

```
##    estimate std.error
## h2   0.0392   0.03597
```

```
vpredict(a2, repeatability ~ (V2 + V3) / (V1 + V2 + V3 + V4))
```

```
##                estimate std.error
## repeatability    0.2711   0.02212
```

```
wald(a2)
```

```
##          term df wald.inc   F.inc ddf.inc     p.inc wald.con   F.con ddf.con
## 1 (Intercept)  1   6258.1 6201.56   52.88 1.702e-56   6258.1 6201.56   52.88
## 2        lact  4    157.8   39.39 2425.07 5.312e-32    157.8   39.39 2425.07
##       p.con   p.chisq
## 1 1.702e-56 0.000e+00
## 2 5.312e-32 4.409e-33
```

重复力，即同一头奶牛两个胎次之间的相关，远大于遗传力：胎次间相似性的很大一部分源于永久环境。由于每个动物有更多记录，遗传力的估计比单胎次分析更为精确。

8.5 母体效应

系谱标识了每头奶牛的母亲。母体永久环境效应（母亲提供的环境，为同母姐妹所共享）以母亲因子作为随机项加入：

```
m1$dam <- pp$dam[match(m1$animal, pp$id)]
m1m <- subset(m1, !is.na(dam))
```

```
a3 <- mlreml(milk_t ~ 1, random = ~ id(herd) + vm(animal, A) + id(dam), data =
m1m, trace = FALSE)
a3b <- mlreml(milk_t ~ 1, random = ~ id(herd) + vm(animal, A), data = m1m, trac
e = FALSE)
summary(a3)$varcomp
```

```
##                         estimate std.error   z.ratio bound
## id(herd)!sigma2      6.464e+00     1.669 3.872e+00     P
## vm(animal, A)!sigma2 1.457e+00     1.284 1.135e+00     P
## id(dam)!sigma2       1.723e-07     2.568 6.709e-08     B
## R!units!sigma2       1.100e+01     2.676 4.110e+00     P
```

```
lrt(a3b, a3)
```

```
##   df LR.statistic p.value AIC0 AIC1 BIC0 BIC1
## 1  1   -1.341e-07     0.5 4957 4959 4972 4978
```

母体方差位于边界上（代码 B）：没有证据表明这些奶牛的产奶量存在母体环境效应。似然比统计量在数值精度内为零。

与直接遗传效应相关的母体遗传效应用项 `str()` 拟合，见第 8.7 节。

8.6 产奶量和乳脂量的双变量分析

为了估计头胎产奶量和乳脂量之间的遗传相关，我们拟合一个双变量动物模型，牛群效应、遗传效应和残差效应均采用非结构化协方差矩阵：

$$\operatorname{Var}\begin{pmatrix}\mathbf{a}_M\\ \mathbf{a}_F\end{pmatrix} = \begin{pmatrix}\sigma^2_{a_M} & \sigma_{a_{MF}}\\ \sigma_{a_{MF}} & \sigma^2_{a_F}\end{pmatrix} \otimes \mathbf{A}.$$

```
rm(a2, a3, a3b, Ai, ebv); invisible(gc())
t_biv <- system.time(
  bv <- mlreml(cbind(milk_t, fat_h) ~ trait,
               random = ~ us(trait):id(herd) + us(trait):vm(animal, A),
               residual = ~ us(trait):units, data = m1, trace = FALSE))
t_biv[3]
```

```
## elapsed
##   37.63
```

```
summary(bv)$varcomp
```

```
##                                              estimate std.error z.ratio bound
## us(trait):id(herd)!trait_milk_t:milk_t         5.5995    1.3545  4.1339     P
## us(trait):id(herd)!trait_fat_h:milk_t          1.6135    0.4267  3.7812     P
## us(trait):id(herd)!trait_fat_h:fat_h           0.6589    0.1601  4.1150     P
## us(trait):vm(animal, A)!trait_milk_t:milk_t    0.6726    0.8661  0.7765     P
## us(trait):vm(animal, A)!trait_fat_h:milk_t     0.1022    0.2785  0.3669     P
## us(trait):vm(animal, A)!trait_fat_h:fat_h      0.2399    0.1358  1.7667     P
## R!us(trait):units!trait_milk_t:milk_t         12.3885    0.9624 12.8725     P
## R!us(trait):units!trait_fat_h:milk_t           3.1642    0.3041 10.4068     P
## R!us(trait):units!trait_fat_h:fat_h            1.4939    0.1396 10.7042     P
```

```
vpredict(bv, rg ~ V5 / sqrt(V4 * V6))
```

```
##    estimate std.error
## rg   0.2544     0.538
```

```
vpredict(bv, re ~ V8 / sqrt(V7 * V9))
```

```
##    estimate std.error
## re   0.7355   0.03364
```

```
vpredict(bv, h2_milk ~ V4 / (V1 + V4 + V7))
```

```
##         estimate std.error
## h2_milk  0.03604   0.04644
```

```
vpredict(bv, h2_fat ~ V6 / (V3 + V6 + V9))
```

```
##        estimate std.error
## h2_fat   0.1003   0.05661
```

```
round(vc_matrix(bv, "us(trait):vm(animal, A)")$cor, 3)
```

```
##        milk_t fat_h
## milk_t  1.000 0.254
## fat_h   0.254 1.000
```

```
round(vc_matrix(bv, "residual")$cor, 3)
```

```
##        milk_t fat_h
## milk_t  1.000 0.736
## fat_h   0.736 1.000
```

参数按表中顺序命名为 V1 至 V9：牛群（V1–V3）、遗传（V4–V6）和残差（V7–V9）协方差。产奶量与乳脂量之间的残差相关很高且估计精确；遗传相关的标准误较大，这在只有 1314 头奶牛的情况下是意料之中的。

8.7 直接和母体遗传效应

对于生命早期表达的性状（初生重和断奶重、窝产仔数、存活率）以及母亲后代的某些性状，动物的表型取决于其自身的基因以及其母亲的母性能力，而后者也部分是遗传的。直接遗传效应与母体遗传效应通常呈负相关（Willham, 1963; Meyer, 1992）。模型 (2.17) 用项 `str(animal, dam, K = A)` 拟合（第 2.11 节），通常同时加入母体永久环境效应 `id(dam)`。由于第 8.1 节的产奶记录中只有很少的母亲拥有自身记录（见本节末尾），因此先用一个真实参数已知的模拟群体来说明估计方法。

以下函数从 300 个奠基者出发模拟六个世代、每代 600 头动物，每代从最近两个世代的雄性中选出 25 头公畜；直接和母体育种值满足 $\sigma_d^2 = 0.40$、$\sigma_m^2 = 0.20$ 和 $\sigma_{dm} = -0.10$（遗传相关 −0.35）；母体永久环境方差为 0.10；残差方差为 0.50；以及 30 个当作固定效应处理的同期组。奠基者之后出生的每头动物都有一条记录，因此大多数母亲都有自身记录。

```
sim_maternal <- function(seed = 2026, nf = 300, ngen = 6, noff = 600,
                         S = matrix(c(0.40, -0.10, -0.10, 0.20), 2), s2pe = 0.1
0, s2e = 0.50) {
```

```
  set.seed(seed)
  ped <- data.frame(id = paste0("F", 1:nf), sire = NA, dam = NA,
                    sex = rep(c("M", "F"), length.out = nf), gen = 0)
  for (g in 1:ngen) {                                  # sires and dams from the l
ast two generations
    cand <- ped[ped$gen >= g - 2, ]
    sires <- sample(cand$id[cand$sex == "M"], 25)
    ped <- rbind(ped, data.frame(id = paste0("G", g, "_", 1:noff),
                                 sire = sample(sires, noff, TRUE),
                                 dam = sample(cand$id[cand$sex == "F"], noff, T
RUE),
                                 sex = sample(c("M", "F"), noff, TRUE), gen =
g))
  }
  A <- Amatrix(ped[, 1:3])
  U <- t(chol(A)) %*% matrix(rnorm(2 * nrow(A)), ncol = 2) %*% chol(S)   # (dir
ect, maternal)
  rownames(U) <- rownames(A)
  d <- ped[ped$gen > 0, ]
  d$cg <- factor(paste(d$gen, sample(1:5, nrow(d), TRUE), sep = "_"))   # conte
mporary groups
  pe <- setNames(rnorm(nrow(A), sd = sqrt(s2pe)), rownames(A))
  d$y <- 10 + rnorm(nlevels(d$cg))[d$cg] + U[d$id, 1] + U[d$dam, 2] + pe[d$dam]
 +
        rnorm(nrow(d), sd = sqrt(s2e))
  list(data = d, ped = ped, A = A, U = U)
}
sm <- sim_maternal()
dsm <- sm$data; Asim <- sm$A
c(records = nrow(dsm), animals = nrow(sm$A), dams = length(unique(dsm$dam)),
  dams_with_own_record = sum(unique(dsm$dam) %in% dsm$id))
```

```
##              records              animals                 dams dams_with_own
_record
##                 3600                 3900                 1407
   1257
```

分别用稠密引擎（使用矩阵 $\mathbf{A}$）和稀疏引擎（使用其逆矩阵）拟合该模型：

```
t_d <- system.time(
  dm_d <- mlreml(y ~ cg, random = ~ str(id, dam, K = Asim) + id(dam), data = ds
m,
                 trace = FALSE, engine = "dense"))
Aisim <- Ainverse(sm$ped)
t_s <- system.time(
  dm_s <- mlreml(y ~ cg, random = ~ str(id, dam, K = Aisim) + id(dam), data = d
sm,
                 trace = FALSE, engine = "sparse"))
c(dense = t_d[3], sparse = t_s[3], logLik_difference = dm_d$loglik - dm_s$logli
k)
```

```
##     dense.elapsed    sparse.elapsed logLik_difference
##         3.352e+01         1.592e+00        -5.401e-09
```

```
cbind(true = c(0.40, -0.10, 0.20, 0.10, 0.50), summary(dm_d)$varcomp[, c("estim
ate", "std.error")])
```

```
##                                  true estimate std.error
## str(id, dam, K = Asim)!id:id      0.4  0.40027   0.06655
## str(id, dam, K = Asim)!dam:id    -0.1 -0.12404   0.04039
## str(id, dam, K = Asim)!dam:dam    0.2  0.27205   0.04846
## id(dam)!sigma2                    0.1  0.04608   0.02658
## R!units!sigma2                    0.5  0.51821   0.03935
```

两个引擎达到相同的最大值，即使只有 3,600 条记录，稀疏引擎也快得多。所有估计值都在真实值的约两个标准误范围之内。众所周知，母体效应的估计精度低于直接效应，而且母体永久环境方差与母体遗传方差部分混杂。

```
vc_matrix(dm_d, "str(id, dam, K = Asim)")$cor
```

```
##          id     dam
## id   1.0000 -0.3759
## dam -0.3759  1.0000
```

```
vpredict(dm_d, h2_direct ~ V1 / (V1 + V2 + V3 + V4 + V5))
```

```
##           estimate std.error
## h2_direct   0.3598   0.05505
```

```
vpredict(dm_d, h2_total ~ (V1 + 1.5 * V2 + 0.5 * V3) / (V1 + V2 + V3 + V4 + V5))
```

```
##          estimate std.error
## h2_total   0.3148   0.03447
```

`vc_matrix()` 返回 $\hat{\boldsymbol{\Sigma}}$ 及其相关矩阵。决定表型选择响应的 Willham（1972）总遗传力小于直接遗传力，因为直接–母体协方差为负。

```
ebv <- coef(dm_d, "random", "str(id, dam, K = Asim)")
ebv[ebv$level %in% c("G6_1", "G6_2"), ]
```

```
##      effect level    blup    pev     se reliability
## 3330     id  G6_1 -0.3304 0.2288 0.4784      0.4305
## 3681     id  G6_2 -0.1133 0.2282 0.4777      0.4381
## 7230    dam  G6_1  0.2735 0.2311 0.4807      0.1539
## 7581    dam  G6_2  0.1242 0.2306 0.4802      0.1646
```

```
c(r_direct = cor(ebv$blup[ebv$effect == "id"], sm$U[ebv$level[ebv$effect == "id
"], 1]),
  r_maternal = cor(ebv$blup[ebv$effect == "dam"], sm$U[ebv$level[ebv$effect ==
"dam"], 2]))
```

```
##   r_direct r_maternal
##     0.6712     0.5159
```

```
dm_0 <- mlreml(y ~ cg, random = ~ str(id, dam, K = Asim, cov = "diag") + id(da
m), data = dsm,
               trace = FALSE)
lrt(dm_0, dm_d, boundary = FALSE)
```

```
##   df LR.statistic  p.value  AIC0  AIC1  BIC0  BIC1
## 1  1        14.69 0.000127 10047 10034 10072 10065
```

每头动物都获得一个直接（effect = "id"）育种值和一个母体（effect = "dam"）育种值，包括雄性，其母体值在其女儿身上表现出来。与模拟真实值的相关表明，母体值的预测准确性较低。带 cov = "diag" 的模型将直接–母体协方差固定为零；由于零协方差不在参数空间的边界上，似然比检验使用 boundary = FALSE，并拒绝 $\sigma_{dm} = 0$。

应用于产奶数据。第 8.3 节的 1,314 条头胎记录中，907 条有已知母亲，但只有 14 头母亲拥有自身的头胎记录。没有母亲的记录，母体遗传效应只能通过母系半同胞及其亲属之间的亲缘关系来识别，直接–母体协方差无法估计：使用 str(animal, dam, K = A) 时，估计的相关趋于 −1，算法在 50 次迭代内不收敛。不含协方差的模型只需几次迭代即可收敛，且母体遗传方差位于边界上：

```
c(records = nrow(m1), with_dam = sum(!is.na(m1$dam)),
  dams_with_own_record = sum(unique(na.omit(m1$dam)) %in% m1$animal))
```

```
##              records             with_dam dams_with_own_record
##                 1314                  907                   14
```

```
a5 <- mlreml(milk_t ~ 1, random = ~ id(herd) + str(animal, dam, K = A, cov = "d
iag"),
             data = m1, trace = FALSE)
summary(a5)$varcomp
```

```
##                                              estimate std.error   z.ratio b
ound
## id(herd)!sigma2                             5.646e+00    1.3654 4.135e+00
   P
## str(animal, dam, K = A, cov = "diag")!animal 6.751e-01    0.8682 7.775e-01
   P
## str(animal, dam, K = A, cov = "diag")!dam    6.103e-08    0.9978 6.117e-08
   B
## R!units!sigma2                              1.238e+01    1.1259 1.100e+01
   P
```

```
lrt(a1, a5)
```

```
##   df LR.statistic p.value AIC0 AIC1 BIC0 BIC1
## 1  1   -1.944e-07     0.5 7217 7219 7233 7240
```

与第 8.5 节的母体环境效应一样，这些数据中没有证据表明头胎产奶量存在母体遗传方差：其对数似然与第 8.3 节模型的对数似然相同。

8.8 大型数据集：稀疏引擎

本章的实例只有几千条记录，在这种规模下稠密引擎仍然可行。稀疏引擎（第 2.12 节）则求解混合模型方程，其优势随数据规模迅速增大。用两个引擎重新拟合第 8.4 节的重复力模型；稀疏引擎接收由 Ainverse() 构建的 **A** 的逆矩阵，该矩阵带有属性 INVERSE = TRUE：

```
Ai <- Ainverse(pp)
t_dense <- system.time(
  a2d <- mlreml(milk_t ~ lact, random = ~ id(herd) + vm(animal, A) + id(animal),
```

```
                data = milk, trace = FALSE, engine = "dense"))
t_sparse <- system.time(
  a2s <- mlreml(milk_t ~ lact, random = ~ id(herd) + vm(animal, Ai) + id(anima
l),
                data = milk, trace = FALSE, engine = "sparse"))
c(dense = t_dense[3], sparse = t_sparse[3])

##  dense.elapsed sparse.elapsed
##         25.720          0.526

summary(a2s)

## MLREML fit (AI-REML, sparse engine)
## Observations: 3397   Fixed-effect columns: 5   Iterations: 7 (converged)
## REML log-likelihood: -9400.8394   AIC: 18809.68   BIC: 18834.20
##
## Variance parameters:
##                          estimate std.error z.ratio bound
## id(herd)!sigma2           4.4460    1.0410    4.27     P
## vm(animal, Ai)!sigma2     0.7982    0.7329    1.09     P
## id(animal)!sigma2         4.7206    0.7970    5.92     P
## R!units!sigma2           10.3960    0.3236   32.12     P
##
## Bound codes: P positive/free, B at boundary, F fixed.
```

输出与第 8.4 节相同，稀疏引擎所需时间远不到一秒，而稠密引擎约需半分钟。由于迭代沿着略有不同的数值路径进行，两个引擎之间的差异在收敛容差的量级上：

```
e_d <- coef(a2d, "random", "vm(animal, A)"); e_s <- coef(a2s, "random", "vm(ani
mal, Ai)")
c(logLik = a2d$loglik - a2s$loglik, theta = max(abs(a2d$theta - a2s$theta)),
  ebv = max(abs(e_d$blup - e_s$blup)), pev = max(abs(e_d$pev - e_s$pev)),
  se_beta = max(abs(sqrt(diag(vcov(a2d))) - sqrt(diag(vcov(a2s))))))

##    logLik     theta       ebv       pev   se_beta
## 2.910e-10 1.573e-08 1.576e-08 1.891e-08 3.790e-11

a2s$sparse[c("N", "nnzL")]

## $N
## [1] 7968
##
## $nnzL
## [1] 106055
```

该模型的混合模型方程有 7,968 个未知数：5 个固定效应、57 个牛群、系谱中 6,547 头动物的遗传值以及 1,359 头有记录奶牛的永久环境效应。第 8.6 节的双变量模型（牛群、遗传和残差效应均采用非结构化协方差矩阵，且有只观测到一个性状的记录）也可用稀疏引擎拟合：

```
t_bs <- system.time(
  bvs <- mlreml(cbind(milk_t, fat_h) ~ trait,
                random = ~ us(trait):id(herd) + us(trait):vm(animal, Ai),
                residual = ~ us(trait):units, data = m1, trace = FALSE, engine
= "sparse"))
t_bs[3]
```

```
## elapsed
##   1.655
```

```
c(logLik_dense = bv$loglik, difference = bv$loglik - bvs$loglik)
```

```
## logLik_dense   difference
##   -5.445e+03    1.237e-08
```

```
vpredict(bvs, rg ~ V5 / sqrt(V4 * V6))
```

```
##    estimate std.error
## rg   0.2544     0.538
```

稀疏拟合只需不到两秒（第 8.6 节中稠密引擎需 37.6 秒），并达到相同的对数似然。第 15.2 节展示了稀疏引擎可处理的数据集规模，模拟数据最多达两百万条记录。

9 实例 6：包含已基因分型和未基因分型个体的一步法 GBLUP

9.1 背景

在实践中，并非每个具有系谱和表型的个体都经过基因分型。一步法 GBLUP（Legarra et al., 2009; Christensen and Lund, 2010）通过方程 (2.16) 中的矩阵 $\mathbf{H}$，在一次分析中同时使用所有个体的系谱和已分型个体的标记。未分型个体可以从其已分型亲属的标记中获益。

为了用真实数据进行说明，我们再次使用 BGLR 中的 599 个小麦品系（它们同时具有系谱和标记），并模拟常见的情形：只有 360 个品系（60 %）被视为已基因分型。这样就可以将系谱预测（A-BLUP）和一步法预测（H-BLUP）与未分型品系的真实表型进行比较。

```
data(wheat)
ids <- paste0("L", 1:599)
Aw <- wheat.A; dimnames(Aw) <- list(ids, ids)
Mw <- 2 * wheat.X; rownames(Mw) <- ids
yw <- setNames(wheat.Y[, 1], ids)
set.seed(7)
genotyped <- sample(ids, 360)
Gg <- Gmatrix(Mw[genotyped, ], method = "VanRaden")
```

9.2 将 G 与系谱对齐并构建 H

在合并矩阵之前，将 $\mathbf{G}$ 与 $\mathbf{A}_{22}$（已分型品系的系谱分块）对齐，并与 5 % 的 $\mathbf{A}_{22}$ 混合：

```
A22 <- Aw[genotyped, genotyped]
Gal <- align_G(Gg, A22)
c(alpha = attr(Gal, "alpha"), beta = attr(Gal, "beta"))
```

```
##  alpha   beta
## 0.3799 0.7989
```

```r
rbind(G_original = c(diag = mean(diag(Gg)), all = mean(Gg)),
      G_aligned = c(mean(diag(Gal)), mean(Gal)),
      A22 = c(mean(diag(A22)), mean(A22)))
```

```
##             diag       all
## G_original 2.000 3.550e-17
## G_aligned  1.978 3.799e-01
## A22        1.978 3.799e-01
```

```r
H <- Hmatrix(Aw, Gg, blend = 0.05, align = TRUE)
range(eigen(H, symmetric = TRUE, only.values = TRUE)$values)
```

```
## [1] 9.786e-04 2.197e+02
```

对齐之后，$\mathbf{G}$ 的对角线均值和所有元素均值与 $\mathbf{A}_{22}$ 的一致。得到的 $\mathbf{H}$ 是正定的。如果不是，`bend()` 会对其进行校正。

基于混合模型方程的程序所使用的逆矩阵 $\mathbf{H}^{-1}$ 可通过 `inverse = TRUE` 获得；数值检验表明它确实是 $\mathbf{H}$ 的逆：

```r
Hi <- Hmatrix(Aw, Gg, blend = 0.05, align = TRUE, inverse = TRUE)
max(abs(Hi %*% H - diag(599)))
```

```
## [1] 1.669e-11
```

9.3 通过验证进行比较

随机去掉 120 个品系（包括已分型和未分型）的表型，分别用 A-BLUP 和 H-BLUP 进行预测，并对两组分别计算预测值与真实表型的相关。该过程重复五次。

```r
Ar <- Aw + diag(1e-3, 599); Hr <- H + diag(1e-3, 599)
res <- do.call(rbind, lapply(1:5, function(r) {
  set.seed(100 + r)
  test <- sample(ids, 120)
  ytr <- yw; ytr[test] <- NA
  pA <- gblup(ytr, Ar)$gebv
  pH <- gblup(ytr, Hr)$gebv
  ng <- setdiff(test, genotyped); gg <- intersect(test, genotyped)
  data.frame(rep = r, A_non_genot = cor(pA[ng], yw[ng]), H_non_genot = cor(pH[n
g], yw[ng]),
             A_genot = cor(pA[gg], yw[gg]), H_genot = cor(pH[gg], yw[gg]))
}))
round(res, 3)
```

```
##   rep A_non_genot H_non_genot A_genot H_genot
## 1   1       0.424       0.402   0.349   0.412
## 2   2       0.362       0.315   0.226   0.465
## 3   3       0.341       0.353   0.488   0.500
## 4   4       0.344       0.283   0.461   0.415
## 5   5       0.584       0.636   0.387   0.537
```

```r
round(colMeans(res[, -1]), 3)
```

```
## A_non_genot H_non_genot     A_genot     H_genot
##       0.411       0.398       0.382       0.466
```

H-BLUP 相对于系谱的增益集中在已分型品系上，因为它们的实际亲缘关系是已知的。对于未分型品系，H-BLUP 和 A-BLUP 的平均预测能力相近，各次重复中的差异有正有负。理论上，未分型个体可以获益，因为它们与已分型个体之间的协方差通过 $\mathbf{A}_{12}\mathbf{A}_{22}^{-1}$ 得到了更新，但这种益处取决于它们与已分型个体的亲缘关系有多近；在这些系谱已能很好地描述亲缘关系的小麦品系中，并未观察到这种益处。这是文献中的常见结果：一步法对未分型个体的优势通常很小。

9.4 使用通用引擎的一步法

上面为了速度使用了 `gblup()`，但 $\mathbf{H}$ 可以通过 `vm()` 用于任何 `mlreml()` 模型，例如具有异质残差方差的模型或多环境模型：

```
dss <- data.frame(gen = ids, y = yw)
fss <- mlreml(y ~ 1, random = ~ vm(gen, Hr), data = dss, trace = FALSE)
summary(fss)$varcomp

##                     estimate std.error z.ratio bound
## vm(gen, Hr)!sigma2   0.3648   0.06446   5.659     P
## R!units!sigma2       0.5186   0.05096  10.176     P

vpredict(fss, h2 ~ V1 / (V1 + V2))

##    estimate std.error
## h2   0.4129   0.05974
```

9.5 建议

- 检查 $\mathbf{G}$ 的标识符是否都在系谱中，以及系谱向上追溯是否完整。
- 将 $\mathbf{G}$ 与 $\mathbf{A}_{22}$ 对齐（`align = TRUE`），并与一小部分 $\mathbf{A}_{22}$（5–10 %）混合。
- 在系谱较浅的群体中，可以调整 $\mathbf{H}^{-1}$ 的参数 τ 和 ω 以减少预测偏差（Misztal et al., 2014）。

10 实例 7：重复测量和随机回归

许多性状在同一个体上被测量多次：不同年龄的体重、整个泌乳期的产奶量、生长季中的株高、连续刈割的产量。将这些观测值视为独立的会低估标准误，并浪费每个个体轨迹的信息。MLREML 提供了两种互补的方法：对个体内残差的相关建模（残差结构），以及用随机系数对个体轨迹建模（随机回归）。

10.1 残差相关：儿童的生长

`Orthodont` 数据（Potthoff and Roy, 1964；见 `nlme`）记录了 27 名男孩和女孩在 8、10、12 和 14 岁时从垂体到翼上颌裂的距离。针对每个儿童四条记录的协方差矩阵，比较了几种结构。

```
library(nlme)
ort <- as.data.frame(Orthodont)
ort$Subject <- factor(as.character(ort$Subject))
ort$agef <- ort$age
o1 <- mlreml(distance ~ age * Sex, random = ~ Subject, data = ort, trace = FALS
E)
o2 <- mlreml(distance ~ age * Sex, residual = ~ ar1(agef):id(Subject), data = o
rt, trace = FALSE)
o3 <- mlreml(distance ~ age * Sex, random = ~ Subject, residual = ~ ar1(agef):i
d(Subject),
             data = ort, trace = FALSE)
o4 <- mlreml(distance ~ age * Sex, random = ~ Subject, residual = ~ diag(Sex):u
nits,
             data = ort, trace = FALSE)
o5 <- mlreml(distance ~ age * Sex, residual = ~ us(agef):id(Subject), data = or
t, trace = FALSE)
data.frame(model = c("random intercept (compound symmetry)", "AR1",
                     "intercept + AR1", "intercept + residual by sex", "unstruc
tured"),
           parameters = sapply(list(o1, o2, o3, o4, o5), function(f) sum(f$fre
e)),
           logLik = sapply(list(o1, o2, o3, o4, o5), `[[`, "loglik"),
           AIC = sapply(list(o1, o2, o3, o4, o5), `[[`, "AIC"))
```

```
##                                   model parameters logLik   AIC
## 1 random intercept (compound symmetry)          2 -216.9 437.8
## 2                                   AR1          2 -222.3 448.6
## 3                        intercept + AR1          3 -216.9 439.8
## 4          intercept + residual by sex          3 -207.6 421.2
## 5                           unstructured         10 -212.3 444.5
```

在 `ar1(agef)` 中，年龄是数值型的，因此 MLREML 使用测量之间的实际距离：相隔 Δ 年的两条记录之间的相关为 ρ^{Δ}。因此，与 `expc()` 一样，同一结构也适用于不规则间隔的测量。AIC 更支持每个性别具有特定残差方差的模型：女孩的个体内变异远小于男孩。

```
summary(o4)
```

```
## MLREML fit (AI-REML)
## Observations: 108   Fixed-effect columns: 4   Iterations: 7 (converged)
## REML log-likelihood: -207.6102   AIC: 421.22   BIC: 429.15
##
## Variance parameters:
##                                estimate std.error z.ratio bound
## Subject!sigma2                   3.4135    1.0870    3.14     P
## R!diag(Sex):units!Sex_Male       2.7883    0.5711    4.88     P
## R!diag(Sex):units!Sex_Female     0.6104    0.1528    3.99     P
```

```
##
## Bound codes: P positive/free, B at boundary, F fixed.
```

10.2 线性随机回归：睡眠剥夺

sleepstudy 数据（Belenky et al., 2003；见 lme4）记录了 18 个人在 10 天睡眠剥夺期间的平均反应时间。每个人都有自己的直线，其随机截距和斜率相关：

$$y_{ij} = (\beta_0 + b_{0i}) + (\beta_1 + b_{1i})\, t_j + e_{ij}, \qquad \begin{pmatrix} b_{0i} \\ b_{1i} \end{pmatrix} \sim N\left(\mathbf{0}, \begin{pmatrix} \sigma_0^2 & \sigma_{01} \\ \sigma_{01} & \sigma_1^2 \end{pmatrix}\right).$$

在 MLREML 中，基 pol(Days, 1) 生成列 $(1, t)$，结构 us 生成它们的协方差矩阵；完整的项为 us(pol(Days, 1)):id(Subject)。

```
data(sleepstudy, package = "lme4")
rr <- mlreml(Reaction ~ Days, random = ~ us(pol(Days, 1)):id(Subject), data = s
leepstudy,
             trace = FALSE)
summary(rr)
```

```
## MLREML fit (AI-REML)
## Observations: 180   Fixed-effect columns: 2   Iterations: 4 (converged)
## REML log-likelihood: -871.8141   AIC: 1751.63   BIC: 1764.36
##
## Variance parameters:
##                                                 estimate std.error z.ratio bou
nd
## us(pol(Days, 1)):id(Subject)!pol(Days, 1)_0:0  612.090    288.80    2.12
 P
## us(pol(Days, 1)):id(Subject)!pol(Days, 1)_1:0    9.604     46.68    0.21
 P
## us(pol(Days, 1)):id(Subject)!pol(Days, 1)_1:1   35.072     14.78    2.37
 P
## R!units!sigma2                                 654.940     77.19    8.49
 P
##
## Bound codes: P positive/free, B at boundary, F fixed.
```

```
vpredict(rr, cor_int_slope ~ V2 / sqrt(V1 * V3))
```

```
##                estimate std.error
## cor_int_slope  0.06555     0.325
```

每个人系数的 BLUP 可用于重建其直线。一个项的水平遵循其组分的顺序，最后一个组分变化最快。在 us(pol(Days, 1)):id(Subject) 中，第一个组分是多项式基，第二个是人，因此前 18 个 BLUP 是 18 个人的截距，接下来的 18 个是他们的斜率。系数矩阵按列构成：

```
b <- coef(rr, "random")[[1]]
head(b$level, 3)
```

```
## [1] "0:308" "0:309" "0:310"
```

```
subj <- levels(factor(sleepstudy$Subject))
```

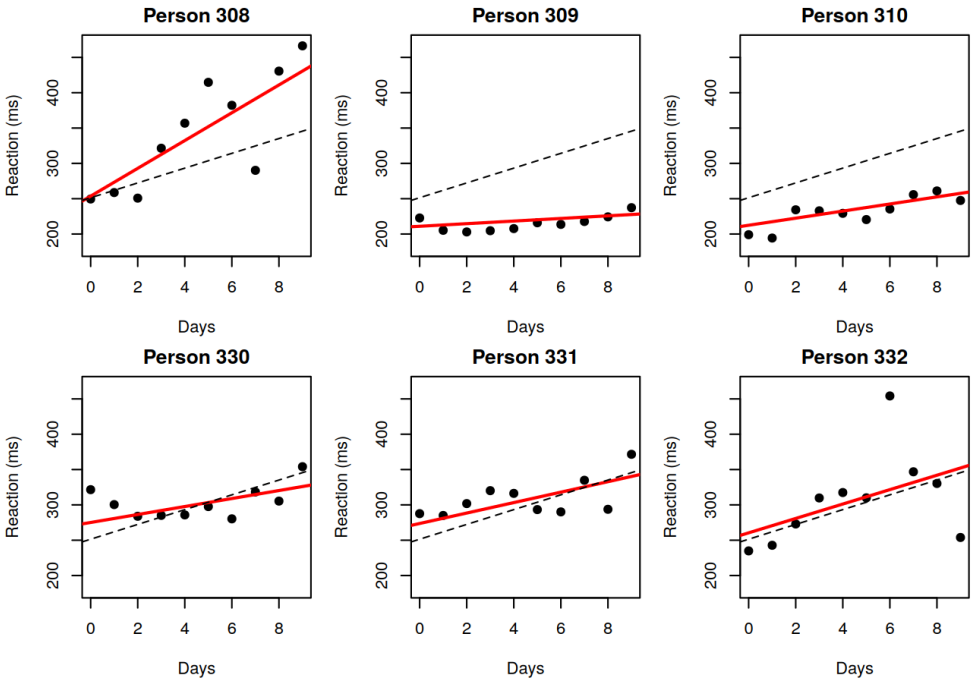
```
B <- matrix(b$blup, ncol = 2, dimnames = list(subj, c("intercept", "slope")))
head(B)
```

```
##     intercept   slope
## 308     2.259  9.1990
## 309   -40.399 -8.6197
## 310   -38.960 -5.4489
## 330    23.691 -4.8143
## 331    22.260 -3.0699
## 332     9.040 -0.2722
```

```
head(lme4::ranef(lme4::lmer(Reaction ~ Days + (Days | Subject), sleepstudy))$Su
bject)
```

```
##     (Intercept)    Days
## 308       2.259  9.1990
## 309     -40.399 -8.6197
## 310     -38.960 -5.4489
## 330      23.691 -4.8144
## 331      22.260 -3.0699
## 332       9.040 -0.2722
```

```
op <- par(mfrow = c(2, 3), mar = c(4, 4, 2, 1))
for (s in subj[1:6]) {
  ds <- subset(sleepstudy, Subject == s)
  plot(ds$Days, ds$Reaction, pch = 19, ylim = c(180, 470), main = paste("Person
", s),
       xlab = "Days", ylab = "Reaction (ms)")
  abline(rr$beta[1] + B[s, 1], rr$beta[2] + B[s, 2], col = "red", lwd = 2)
  abline(rr$beta, lty = 2)
}
```



观测的反应时间（点）、预测的个体直线（红色）和平均直线（虚线）。

```
par(op)
```

10.3 使用 Legendre 多项式的随机回归：生长曲线

在动物育种中，轨迹用 Legendre 多项式建模（Kirkpatrick et al., 1990; Schaeffer, 2004），它们在 $[-1,1]$ 上正交，与原始多项式相比能给出条件更好的协方差矩阵。`ChickWeight` 数据（Crowder and Hand, 1990）包含 50 只饲喂四种日粮的雏鸡从出生到第 21 天测得的体重。

```
cw <- as.data.frame(ChickWeight)
cw$Chick <- factor(as.character(cw$Chick))
ck1 <- mlreml(weight ~ Diet + Diet:Time, random = ~ us(leg(Time, 1)):id(Chick),
              residual = ~ diag(Time):units, data = cw, trace = FALSE)
ck2 <- mlreml(weight ~ Diet + Diet:Time, random = ~ us(leg(Time, 2)):id(Chick),
              residual = ~ diag(Time):units, data = cw, trace = FALSE)
lrt(ck1, ck2, boundary = FALSE)

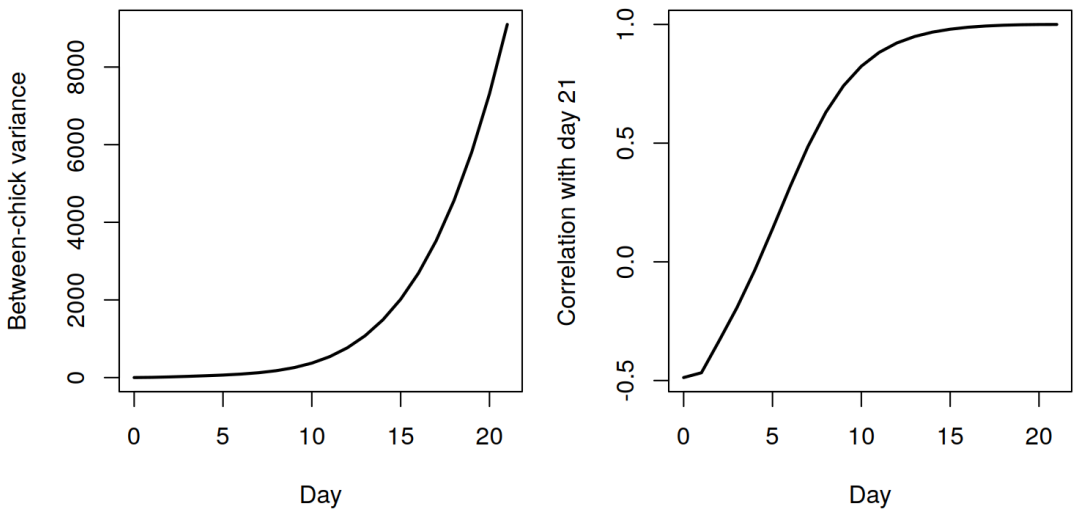
##   df LR.statistic   p.value AIC0 AIC1 BIC0 BIC1
## 1  3        445.3 3.436e-96 4538 4099 4603 4177

summary(ck2)$varcomp[1:6, ]

##                                                 estimate std.error z.ratio bound
## us(leg(Time, 2)):id(Chick)!leg(Time, 2)_0:0   1665.1    367.06   4.536     P
## us(leg(Time, 2)):id(Chick)!leg(Time, 2)_1:0   1542.1    340.91   4.523     P
## us(leg(Time, 2)):id(Chick)!leg(Time, 2)_1:1   1526.5    325.35   4.692     P
## us(leg(Time, 2)):id(Chick)!leg(Time, 2)_2:0    442.1    105.07   4.208     P
## us(leg(Time, 2)):id(Chick)!leg(Time, 2)_2:1    484.7    104.72   4.629     P
## us(leg(Time, 2)):id(Chick)!leg(Time, 2)_2:2    175.1     36.42   4.808     P
```

二次模型明显更好。两个年龄 t 和 t' 的体重之间的协方差函数为 $\boldsymbol{\phi}(t)'\mathbf{K}\boldsymbol{\phi}(t')$，其中 $\boldsymbol{\phi}(t)$ 是在 t 处取值的 Legendre 多项式向量，$\mathbf{K}$ 是系数的协方差矩阵。由此可以得到每个年龄的雏鸡间方差以及年龄之间的相关：

```
Kc <- vc_matrix(ck2, "us(leg(Time, 2)):id(Chick)")$cov
tt <- 0:21
Phi <- MLREML:::.legendre(c(tt, range(cw$Time)), 2)[seq_along(tt), ]
Cfun <- Phi %*% Kc %*% t(Phi)
op <- par(mfrow = c(1, 2), mar = c(4, 4, 1, 1))
plot(tt, diag(Cfun), type = "l", lwd = 2, xlab = "Day", ylab = "Between-chick v
ariance")
plot(tt, cov2cor(Cfun)[, 22], type = "l", lwd = 2, xlab = "Day", ylab = "Correl
ation with day 21")
```



随机回归估计的雏鸡间方差（左）以及各年龄体重与第 21 天体重的相关（右）。

```
par(op)
```

若有系谱，将同一项中的 `id(Chick)` 换成 `vm(animal, A)`，即可得到加性遗传协方差函数，由此可以获得各年龄的遗传力以及年龄之间的遗传相关。动物育种中完整的随机回归模型通常包含一个遗传项和一个永久环境项：

```
mlreml(weight ~ group + leg(age, 3),
       random = ~ us(leg(age, 2)):vm(animal, A) + us(leg(age, 2)):id(animal),
       residual = ~ diag(age_class):units, data = records)
```

11 实例 8：双列杂交分析

11.1 数据

数据集 `hayman.tobacco`（Hayman, 1954；见 `agridat`）是 8 个烟草品种（*Nicotiana rustica*）的完全双列杂交：包括自交和反交在内的 64 个母本与父本组合，在 2 年中每年 2 个区组进行评价。响应变量为开花天数。

```
data(hayman.tobacco)
dt <- hayman.tobacco
dt$year_f <- factor(dt$year)
str(dt)
```

```
## 'data.frame':    256 obs. of  6 variables:
##  $ year  : int  1951 1951 1951 1951 1951 1951 1951 1951 1951 1951 ...
##  $ block : Factor w/ 2 levels "B1","B2": 1 1 1 1 1 1 1 1 2 2 ...
##  $ male  : Factor w/ 8 levels "G1","G2","G3",..: 1 2 3 4 5 6 7 8 1 2 ...
##  $ female: Factor w/ 8 levels "G1","G2","G3",..: 1 1 1 1 1 1 1 1 1 1 ...
##  $ day   : num  27.6 13.6 24.6 31.8 15 18.2 17.4 15.2 30.2 14.2 ...
##  $ year_f: Factor w/ 2 levels "1951","1952": 1 1 1 1 1 1 1 1 1 1 ...
```

```
with(dt, table(female, male))[1:4, 1:4]
```

```
##       male
## female G1 G2 G3 G4
##     G1  4  4  4  4
##     G2  4  4  4  4
##     G3  4  4  4  4
##     G4  4  4  4  4
```

11.2 模型

在双列杂交中，母本 i 与父本 j 杂交组合的值分解为（Griffing, 1956; Cockerham and Weir, 1977）：

$$y_{ijk} = \mu + \text{environment}_k + g_i + g_j + s_{ij} + m_i + r_{ij} + e_{ijk},$$

其中 g 是每个亲本的一般配合力（GCA），无论其作为母本还是父本都相同；$s_{ij} = s_{ji}$ 是该亲本对的特殊配合力（SCA），与杂交方向无关；m_i 是母本的一般母体效应；r_{ij} 是有序组合的特殊反交效应。当亲本为随机效应时，每种效应都有其自身的方差。

技术上的难点在于 GCA：每个观测值都有同一因子的**两个**效应。在 MLREML 中，这一问题通过多成员基 `mm(female, male)` 解决，其设计矩阵在每个亲本对应的列中为 1（自交为 2）。SCA 使用表示无序杂交组合的因子，反交效应使用表示有序杂交组合的因子。

```
dt$cross <- factor(with(dt, paste(pmin(as.character(female), as.character(mal
e)),
                                  pmax(as.character(female), as.character(mal
e)), sep = "x")))
dt$cross_ord <- factor(paste(dt$female, dt$male, sep = ">"))
c(unordered_crosses = nlevels(dt$cross), ordered_crosses = nlevels(dt$cross_or
d))
```

```
## unordered_crosses   ordered_crosses
##                36                64
```

```
di <- mlreml(day ~ year_f + year_f:block,
             random = ~ mm(female, male) + cross + female + cross_ord,
             data = dt, trace = FALSE)
summary(di)
```

```
## MLREML fit (AI-REML)
## Observations: 256   Fixed-effect columns: 4   Iterations: 7 (converged)
## REML log-likelihood: -676.2058   AIC: 1362.41   BIC: 1380.06
##
## Variance parameters:
##                           estimate std.error z.ratio bound
## mm(female, male)!sigma2   9.0600    5.1950    1.74     P
## cross!sigma2              3.8401    1.6140    2.38     P
## female!sigma2             0.4936    0.6835    0.72     P
## cross_ord!sigma2          0.7941    0.9461    0.84     P
## R!units!sigma2            8.3574    0.8597    9.72     P
##
## Bound codes: P positive/free, B at boundary, F fixed.
```

11.3 解释

GCA 方差是各遗传方差中最大的，表明开花天数的大部分遗传变异是加性的，能够以可预测的方式传递给后代。SCA 方差反映了每个组合特有的非加性效应（显性和上位性）。母体效应和反交效应较小。

在通常的假设下（亲本间无亲缘关系、无上位性），对于非近交的二倍体群体有 $\sigma^2_A = 4\sigma^2_{GCA}$，对于完全近交的亲本（烟草品种即属此情况）有 $2\sigma^2_{GCA}$；遗传方差中加性部分所占比例用 `vpredict()` 估计：

```
vpredict(di, prop_GCA ~ 2 * V1 / (2 * V1 + V2 + V3 + V4))
```

```
##          estimate std.error
## prop_GCA   0.7794    0.1137
```

```
vpredict(di, Baker ~ 2 * V1 / (2 * V1 + V2))
```

```
##       estimate std.error
## Baker   0.8251    0.1033
```

Baker 比率（1978）$2\sigma^2_{GCA}/(2\sigma^2_{GCA} + \sigma^2_{SCA})$ 接近 1，表明根据亲本的 GCA 来预测杂交组合将是准确的。

11.4 预测的配合力

```
gca <- coef(di, "random", "mm(female, male)")
gca[order(gca$blup), c("level", "blup", "se", "reliability")]
```

```
##   level    blup   se reliability
## 7    G7 -3.9663 1.29      0.8163
## 8    G8 -2.0061 1.29      0.8163
## 2    G2 -1.6694 1.29      0.8163
## 5    G5 -1.3773 1.29      0.8163
## 6    G6  0.2339 1.29      0.8163
## 4    G4  0.5217 1.29      0.8163
## 1    G1  3.7705 1.29      0.8163
## 3    G3  4.4929 1.29      0.8163
```

由于响应变量是开花天数，GCA 为负的亲本传递早熟性。未评价的杂交组合 $i \times j$ 的预测值通过将均值、两个 GCA 以及（在可得时）SCA 和母体效应相加得到：

```
sca <- coef(di, "random", "cross")
g <- setNames(gca$blup, gca$level); s <- setNames(sca$blup, sca$level)
mu <- mean(di$fixed_fitted)
pred_cross <- function(p1, p2) {
  k <- paste(min(p1, p2), max(p1, p2), sep = "x")
  unname(mu + g[p1] + g[p2] + ifelse(k %in% names(s), s[k], 0))
}
c(G1xG3 = pred_cross("G1", "G3"), G7xG8 = pred_cross("G7", "G8"))
```

```
## G1xG3 G7xG8
## 27.85 10.95
```

11.5 模型比较

母体效应和反交效应是否必要？用似然比比较嵌套模型：

```
di0 <- mlreml(day ~ year_f + year_f:block, random = ~ mm(female, male) + cross,
              data = dt, trace = FALSE)
lrt(di0, di, boundary = FALSE)
```

```
##   df LR.statistic p.value AIC0 AIC1 BIC0 BIC1
## 1  2         3.974  0.1371 1362 1362 1373 1380
```

由于同时检验两个位于边界上的方差，零分布是 χ^2_0、χ^2_1 和 χ^2_2 的混合；此处所示的 χ^2_2 检验是保守的。

通过改变所包含的项，同样的语法也适用于 North Carolina I 和 II 等交配设计、无反交的双列杂交（Griffing 方法 4）或顶交。如果亲本具有系谱或标记，本版本中 `mm()` 不能直接与 `vm()` 组合。解决方法是在杂交组合层面构建 GCA 协方差矩阵：若 $\mathbf{Z}_{mm}$ 是有序杂交组合的多成员矩阵，$\mathbf{K}$ 是亲本的亲缘关系矩阵，则杂交组合间的 $\mathrm{Var}(g_i + g_j)$ 为 $\sigma^2_{GCA}\,\mathbf{Z}_{mm}\mathbf{K}\mathbf{Z}_{mm}'$，该项写作 `vm(cross_ord, Kc)`，其中 `Kc` 等于该矩阵：

```
cr <- levels(dt$cross_ord)
p1 <- sub(">.*", "", cr); p2 <- sub(".*>", "", cr)
Zmm <- outer(p1, rownames(K), "==") + outer(p2, rownames(K), "==")
Kc <- Zmm %*% K %*% t(Zmm); dimnames(Kc) <- list(cr, cr)
mlreml(day ~ year_f + year_f:block, random = ~ vm(cross_ord, Kc) + cross, data
= dt)
```

12 实例 9：无重复的早代试验

12.1 数据

在育种计划的早期阶段，数百个新品系各只用一个小区进行评价，其间穿插有重复的对照品种，用于估计误差和空间变异。Cullis、Smith 和 Coombes（2006）表明，空间分析在这类试验中尤其有价值，因为在没有重复的情况下，没有其他办法将遗传优势与小区肥力区分开来。`cullis.earlygen` 数据（见 `agridat`）来自该研究：670 个小麦小区，排列为 67 行 × 10 列，共 532 个基因型。大多数基因型只出现一次；对照有重复。每个小区还记录了杂草评分。

```
data(cullis.earlygen)
eg <- cullis.earlygen
c(plots = nrow(eg), genotypes = nlevels(eg$gen), rows = max(eg$row), columns =
max(eg$col))
```

```
##     plots genotypes      rows   columns
##       670       532        67        10
```

```
rep_gen <- table(eg$gen)
table(replicates = rep_gen)
```

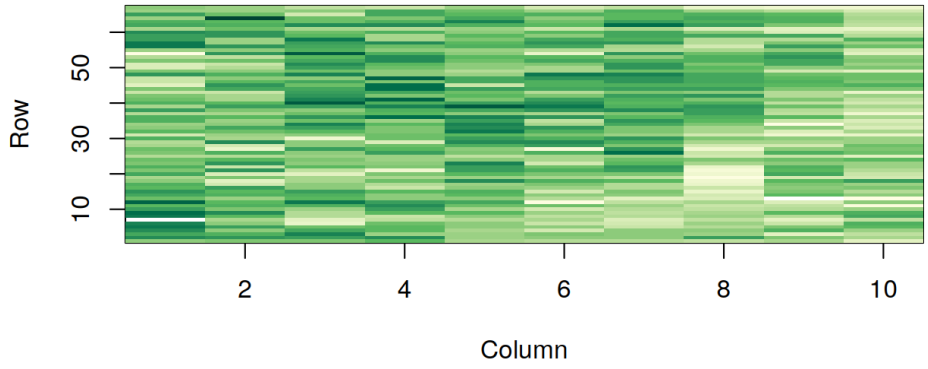
```
## replicates
##   1   3   4   5 121
## 525   1   4   1   1

head(sort(rep_gen, decreasing = TRUE), 6)

##
##    Kite   Banks  Hartog   K1056 Rosella  Vulcan
##     121       5       4       4       4       4

eg$check <- factor(ifelse(rep_gen[as.character(eg$gen)] > 1, "check", "line"))

Ym <- tapply(eg$yield, list(eg$col, eg$row), mean)
image(1:10, 1:67, Ym, col = hcl.colors(30, "YlGn", rev = TRUE), xlab = "Column",
 ylab = "Row")
```



670 个小区（67 行× 10 列）的观测产量。

12.2 模型

比较三个具有相同固定效应（均值、作为协变量的杂草评分以及对照与新品系之间的均值差）和随机遗传效应的模型：

1. 独立残差；
2. 可分离 AR1 × AR1 残差；
3. AR1 × AR1 残差加独立的块金效应。

```
e1 <- mlreml(yield ~ weed + check, random = ~ gen, data = eg, trace = FALSE)
e2 <- mlreml(yield ~ weed + check, random = ~ gen, residual = ~ ar1(row):ar1(co
l),
             data = eg, trace = FALSE)
e3 <- mlreml(yield ~ weed + check, random = ~ gen + units, residual = ~ ar1(ro
w):ar1(col),
             data = eg, trace = FALSE)
data.frame(model = c("independent", "AR1 x AR1", "AR1 x AR1 + nugget"),
           parameters = sapply(list(e1, e2, e3), function(f) sum(f$free)),
           logLik = sapply(list(e1, e2, e3), `[[`, "loglik"),
           AIC = sapply(list(e1, e2, e3), `[[`, "AIC"))
```

```
##                 model parameters logLik  AIC
## 1         independent          2  -4897 9798
## 2           AR1 x AR1          4  -4840 9688
## 3 AR1 x AR1 + nugget          5  -4833 9676
```

```
summary(e3)
```

```
## MLREML fit (AI-REML)
## Observations: 668   Fixed-effect columns: 3   Iterations: 7 (converged)
## REML log-likelihood: -4832.9955   AIC: 9675.99   BIC: 9698.49
##
## Variance parameters:
##                               estimate std.error z.ratio bound
## gen!sigma2                   7.237e+04 1.046e+04    6.92     P
## units!sigma2                 3.274e+04 7.974e+03    4.11     P
## R!ar1(row):ar1(col)!sigma2   5.704e+04 1.123e+04    5.08     P
## R!ar1(row):ar1(col)!row_cor 8.561e-01 3.998e-02   21.41     P
## R!ar1(row):ar1(col)!col_cor 4.027e-01 1.137e-01    3.54     P
##
## Bound codes: P positive/free, B at boundary, F fixed.
```

```
wald(e3)
```

```
##          term df  wald.inc     F.inc ddf.inc     p.inc  wald.con     F.con d
df.con
## 1 (Intercept)  1 3.521e+03 3.946e+03   10.93 2.480e-15 3.521e+03 3.946e+03
 10.93
## 2        weed  1 8.288e+01 7.938e+01  496.09 9.735e-18 8.289e+01 7.940e+01
495.97
## 3       check  1 1.743e-02 1.737e-02  164.50 8.953e-01 1.743e-02 1.737e-02
164.50
##       p.con   p.chisq
## 1 2.480e-15 0.000e+00
## 2 9.693e-18 8.656e-20
## 3 8.953e-01 8.950e-01
```

与独立残差模型相比，空间模型显著改善了似然。杂草效应显著且为负，这是一个外来变异的例子；当这类变异已被测量时，应使用协变量对其建模。

12.3 对选择的影响

早代试验的目的是选出最优的一部分品系。实际问题在于模型是否会改变入选的品系。我们比较新品系在独立模型和 AIC 所偏好的空间模型下的 BLUP：

```
b1 <- coef(e1, "random", "gen"); bb <- coef(eb, "random", "gen")
new_lines <- names(rep_gen)[rep_gen == 1]
u1 <- setNames(b1$blup, b1$level)[new_lines]
ub <- setNames(bb$blup, bb$level)[new_lines]
cor(u1, ub, method = "spearman")
```

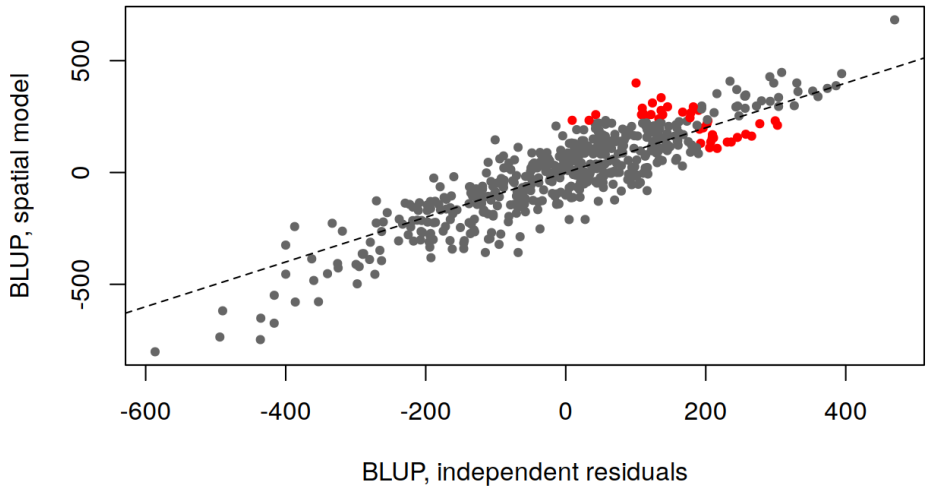
```
## [1] 0.8612
```

```
k <- round(0.1 * length(new_lines))
sel1 <- names(sort(u1, decreasing = TRUE))[1:k]
```

```
selb <- names(sort(ub, decreasing = TRUE))[1:k]
c(selected = k, in_common = length(intersect(sel1, selb)))

##  selected in_common
##        52        32

only_one <- setdiff(union(sel1, selb), intersect(sel1, selb))
plot(u1, ub, pch = 20, col = ifelse(new_lines %in% only_one, "red", "grey40"),
     xlab = "BLUP, independent residuals", ylab = "BLUP, spatial model")
abline(0, 1, lty = 2)
```



独立残差模型与空间模型下新品系 BLUP 的对比。红点表示仅被两个模型之一选中（前 10 %）的品系。

入选品系中有相当一部分随模型而变化。由于空间模型对数据的描述更好，其预测更为可靠，这也体现在 BLUP 的平均可靠性和广义遗传力上：

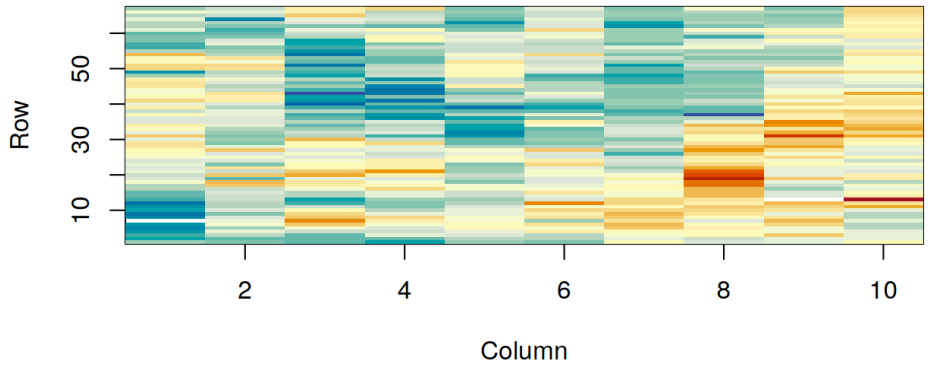
```
H2c <- function(f) {
  pr <- predict(f, "gen", sed = TRUE)
  1 - pr$avsed^2 / (2 * f$theta[1])
}
data.frame(model = c("independent", "spatial"),
           mean_reliability = c(mean(b1$reliability), mean(bb$reliability)),
           H2_Cullis = c(H2c(e1), H2c(eb)))

##         model mean_reliability H2_Cullis
## 1 independent           0.4025    0.4035
## 2     spatial           0.5767    0.5779
```

12.4 空间趋势和对照

估计的空间变异可以通过去除固定效应和遗传效应后模型的残差进行可视化。分布在整个试验中的重复对照使其可以被估计。

```
gefe <- bb$blup[match(as.character(eb$data$gen), bb$level)]
esp <- eb$y - eb$fixed_fitted - gefe
Em <- tapply(esp, list(eb$data$col, eb$data$row), mean)
image(1:10, 1:67, Em, col = hcl.colors(30, "RdYlBu"), xlab = "Column", ylab = "
Row")
```



估计的空间组分（产量减去固定效应和遗传效应）。

本例展示了 Cullis et al.（2006）为无重复试验推荐的工作流程：对空间变异和已测量的外来因素建模，将基因型视为随机效应，并以最佳拟合模型的 BLUP 作为选择依据。

13 高级用法和故障排除

本章汇集了不属于某一特定试验类型的技术：如何检查收敛性，如何使用初始值和固定参数，如何获得基于似然的置信区间，如何处理边界估计值和病态矩阵，以及如何减少内存使用。本章最后给出一个常见问题及其解决方法的表格。

13.1 迭代历史

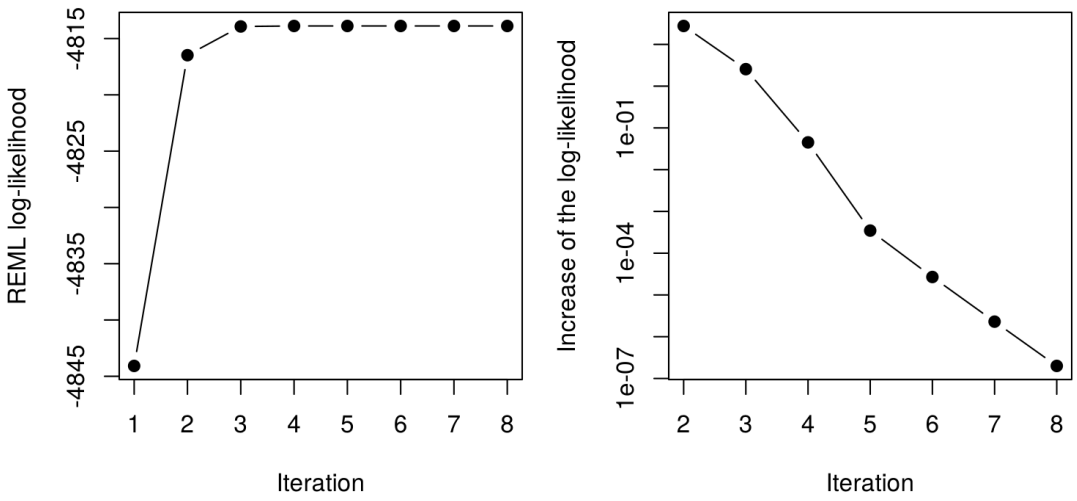
拟合对象的 `history` 元素存储了每次迭代的对数似然值以及所使用的阻尼因子 λ。λ 为零表示纯 AI 步；正值表示纯步无效或未能改善似然，因而必须缩短。

```
d <- agridat::besag.met
fh <- mlreml(yield ~ county, random = ~ county:rep + county:rep:block + fa(coun
ty, 1):id(gen),
             residual = ~ diag(county):units, data = d, trace = FALSE, maxit =
100)
head(fh$history, 12)
```

```
##   iteration loglik lambda
## 1         1  -4844      0
## 2         2  -4816      0
## 3         3  -4814      0
## 4         4  -4814      0
## 5         5  -4814      0
```

```
## 6         6  -4814      0
## 7         7  -4814      0
## 8         8  -4814      0

op <- par(mfrow = c(1, 2), mar = c(4, 4, 1, 1))
plot(fh$history$iteration, fh$history$loglik, type = "b", pch = 19,
     xlab = "Iteration", ylab = "REML log-likelihood")
inc <- diff(fh$history$loglik)
plot(seq_along(inc) + 1, pmax(inc, 1e-8), log = "y", type = "b", pch = 19,
     xlab = "Iteration", ylab = "Increase of the log-likelihood")
```



FA(1) 模型的 REML 对数似然历史（左）和每次迭代似然增量的对数尺度图（右）。

```
par(op)
```

在最优点附近，AI 算法几乎二次收敛：每次迭代的似然增量下降几个数量级。尽管该模型有三个特殊方差位于边界上，对边界的有效集处理（第 2.4.1 节）可防止它们阻碍联合步长，模型在 8 次迭代内无需阻尼即可收敛。增量缓慢而稳定的下降表明似然在某个方向上是平坦的。

13.2 初始值和重新开始

当一个复杂模型不收敛时，建议从上一次尝试的最终值或从一个更简单模型的估计值重新开始。初始值以命名向量的形式给出：

```
ini <- fh$theta                                  # FA(1) estimates
fh2 <- mlreml(yield ~ county, random = ~ county:rep + county:rep:block + fa(cou
nty, 1):id(gen),
              residual = ~ diag(county):units, data = d, trace = FALSE, start =
 ini)
c(iterations = fh2$iterations, logLik = fh2$loglik, converged = fh2$converged)

## iterations     logLik  converged
##          1      -4814          1
```

从最优点开始，算法在一到两次迭代内即可确认收敛。这也是验证拟合是否真正收敛的方法。

若要用简单模型作为复杂模型的起点，可复制共同的参数。例如，对角模型的方差可作为 FA 模型特殊方差的初始值：

```
fd <- mlreml(yield ~ county, random = ~ county:rep + county:rep:block + diag(co
unty):id(gen),
             residual = ~ diag(county):units, data = d, trace = FALSE)
vg <- fd$theta[grep("diag\\(county\\):id\\(gen\\)", names(fd$theta))]
names(vg) <- sub("diag\\(county\\):id\\(gen\\)!county_", "fa(county, 1):id(gen)!
county_var_", names(vg))
head(vg, 3)
```

```
## fa(county, 1):id(gen)!county_var_C1 fa(county, 1):id(gen)!county_var_C2
##                               57.41                               19.29
## fa(county, 1):id(gen)!county_var_C3
##                               94.35
```

该向量可以传给 `start`（只需包含需要初始化的参数；其余参数取默认值）。

13.3 固定参数和剖面似然

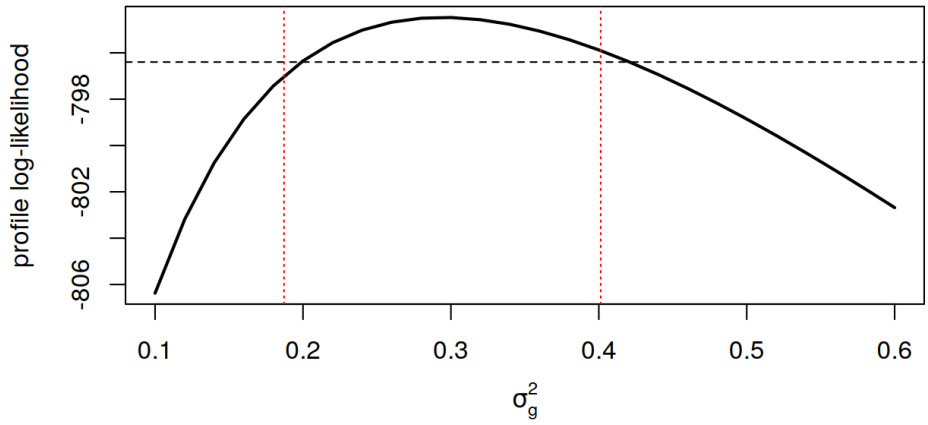
使用 `fix` 时，参数保持在其初始值上。一个重要的应用是**剖面似然**：将某个参数固定在一组网格值上，估计其他参数，并绘制所得的最大化似然。基于似然的 95 % 置信区间包含剖面对数似然与最大值相差在 $\chi^2_{1,0.95}/2 = 1.92$ 个单位以内的那些值。与 Wald 区间（估计值 ± 1.96 标准误）不同，它不一定对称，并且对于方差永远不会包含负值。

我们使用第 7 章的 GBLUP 模型来研究环境 E1 的遗传方差：

```
f0 <- mlreml(y ~ 1, random = ~ vm(gen, G), data = d1, trace = FALSE)
nm <- "vm(gen, G)!sigma2"
grid <- seq(0.10, 0.60, by = 0.02)
prof <- sapply(grid, function(s) {
  mlreml(y ~ 1, random = ~ vm(gen, G), data = d1, start = setNames(s, nm), fix
= nm,
         trace = FALSE, pev = FALSE)$loglik
})
lim <- range(grid[prof >= max(prof) - qchisq(0.95, 1) / 2])
est <- f0$theta[nm]; se <- f0$varcomp[nm, "std.error"]
rbind(profile = lim, wald = est + c(-1, 1) * 1.96 * se)
```

```
##           [,1]   [,2]
## profile 0.2000 0.4200
## wald    0.1872 0.4013
```

```
plot(grid, prof, type = "l", lwd = 2, xlab = expression(sigma[g]^2), ylab = "pr
ofile log-likelihood")
abline(h = max(prof) - qchisq(0.95, 1) / 2, lty = 2)
abline(v = est + c(-1, 1) * 1.96 * se, lty = 3, col = "red")
```



遗传方差的剖面对数似然（GBLUP，环境 E1）。水平线标出 95 % 区间的阈值；竖线标出 Wald 区间。

同样的过程适用于任何参数，包括遗传相关和自回归参数，也是为接近边界的参数获得区间的推荐方法。

13.4 已知方差组分

如果方差组分已知（例如在大型数据集中估计得到或已发表），可以将其全部固定，仅求 BLUE 和 BLUP。这样就可以用稳定的参数预测新的世代，而无需每次重新估计：

```
known_vc <- c("vm(gen, G)!sigma2" = 0.30, "R!units!sigma2" = 0.55)
fk <- mlreml(y ~ 1, random = ~ vm(gen, G), data = d1, start = known_vc,
             fix = names(known_vc), trace = FALSE)
summary(fk)$varcomp
```

```
##                    estimate std.error z.ratio bound
## vm(gen, G)!sigma2     0.30        NA      NA     F
## R!units!sigma2        0.55        NA      NA     F
```

```
cor(fk$blups[[1]]$blup, f0$blups[[1]]$blup)
```

```
## [1] 1
```

13.5 别名化（aliased）固定效应

固定效应矩阵中为其他列线性组合的列会被自动删除，类似于 ASReml 的 aliased 效应。例如，如果同一个因子以不同名称被包含两次，或包含一个是另一个因子函数的因子（此处为将重复分组为两块田），冗余的列会被舍弃：

```
ja <- agridat::john.alpha
ja$field <- factor(ifelse(ja$rep == "R1", "A", "B"))      # a function of rep
fa_alias <- mlreml(yield ~ rep + field, random = ~ gen, data = ja, trace = FALS
E)
```

```r
c(possible_columns = ncol(model.matrix(~ rep + field, ja)), estimable_columns =
 fa_alias$p)
```

```
##  possible_columns estimable_columns
##                 4                 3
```

```r
colnames(fa_alias$X)
```

```
## [1] "(Intercept)" "repR2"       "repR3"
```

13.6 位于边界上的参数

估计在其下限的方差（代码 B）意味着似然在参数空间的边缘取得最大值。常见原因是该效应确实很小、设计无法将其与其他效应分离，或者模型参数过多。在这些情况下：

1. 报告的标准误无效；
2. 似然比检验必须使用 χ^2 分布的混合（`lrt(..., boundary = TRUE)`）；
3. 考虑删除该项，或者用更简约的结构（fa、diag）替换复杂结构（us）。

位于边界上且得分为负的方差会被保持在边界上并从 AI 系统中移除（有效集），使其他参数在给定边界的条件下收敛到最优；收敛到奇异矩阵（相关为 ± 1）的非结构化矩阵在步长变得可以忽略时会以警告的方式终止算法。

在因子分析模型中，特殊方差为零（Heywood 情形）很常见，并不妨碍对模型的解释。

13.7 病态的亲缘关系矩阵

MLREML 的稠密引擎不对亲缘关系矩阵求逆，因此只要 $\mathbf{V}$ 是正定的，奇异矩阵也是可以接受的；稀疏引擎需要逆矩阵，因此需要正定矩阵。然而，具有负特征值的矩阵（例如用插补的缺失数据计算的 $\mathbf{G}$ 矩阵，或构建不当的 $\mathbf{H}$）不是有效的协方差矩阵。函数 `bend()` 通过替换较小或为负的特征值对其进行校正：

```r
set.seed(1)
Kbad <- cor(matrix(rnorm(30 * 20), 20))          # 30 x 30 with rank 20
Kbad[1, 2] <- Kbad[2, 1] <- 0.99                  # perturbation that makes it
indefinite
range(eigen(Kbad, only.values = TRUE)$values)
```

```
## [1] -0.7215  4.4667
```

```r
Kok <- bend(Kbad, tol = 1e-4)
range(eigen(Kok, only.values = TRUE)$values)
```

```
## [1] 0.0004467 4.4667035
```

```r
max(abs(Kok - Kbad))
```

```
## [1] 0.284
```

13.8 变量的尺度

理论上该算法具有尺度不变性，但实际上当响应变量的方差在 1 的数量级时，收敛更为稳健。在性状尺度差异很大的多变量模型中（例如以千克计的产奶量和以百分比计的乳蛋白率），建议对每个性状重新缩放，正如第 8 章中将产奶量以吨、乳脂量以百千克表示那样。原始尺度上的协方差可通过乘以尺度因子恢复。

13.9 内存和时间

- `engine = "sparse"`（第 2.12 节）完全避免了 $n \times n$ 矩阵；当记录超过 5,000 条且模型受支持时会自动选用。
- `pev = FALSE` 跳过预测误差方差的计算，当某一项具有大量水平时（例如系谱中的所有动物），这是拟合后计算量最大的部分。
- `store = FALSE` 不保留 `predict()` 以及 `wald()` 的 Kenward–Roger 调整所需的 $n \times n$ 矩阵（使用稀疏引擎时为 Cholesky 因子）；这会大大减小拟合对象的大小。
- 在耗时较长的分析中（交叉验证、模拟），删除不再需要的拟合对象并调用 `gc()`。

13.10 常见问题

常见问题及解决方法。

信息或症状	可能原因	解决方法
`levels of 'x' missing from the vm() matrix`	因子的某些水平不在矩阵的行名中。	检查标识符（空格、大小写、前缀）；使用 `setdiff()` 找出它们。
`the matrix given to vm() must have rownames`	亲缘关系矩阵没有名称。	指定 `dimnames(K) <- list(ids, ids)`。
`term ... has more than one variance-type component`	一个项中有两个方差结构，例如 `us(env):diag(gen)`。	只保留一个方差结构；另一个必须是相关结构（`id`、`vm`、`ar1`…）。
`AI-REML did not converge`	似然平坦、模型参数过多或初始值不佳。	增大 `maxit`，用 `start = fit$theta` 重新开始，简化模型。
`no improving step found`	算法找不到能增加似然的步，通常发生在边界上。	检查代码为 `B` 的参数；尝试其他初始值。
`AI-REML stopped because the steps became negligible although the score is not zero`	非结构化矩阵（`us`、`str()`）收敛到奇异矩阵。	检查相关（± 1）；使用 `fa`、`diag` 或 `str(..., `

信息或症状	可能原因	解决方法
		`cov = "diag"`）。
方差带有代码 `B` 且标准误极大	参数位于边界上。	解释为零；使用混合分布 LRT；考虑删除该项。
遗传相关等于 ± 1	`us` 矩阵位于半正定锥的边界上。	数据较少时属正常现象；可考虑使用 `fa` 模型。
`chol()` 出错或内存不足	n 太大，无法使用稠密矩阵。	使用 `engine = "sparse"`（第 2.12 节），或参见第 15 章中的策略。
`the sparse engine does not support this model (...)`	模型包含没有稀疏实现的结构（`cs`、`ar1`、`expc`、`sexp`、`fa`）或不受支持的残差。	使用 `engine = "dense"`，或受支持的结构。
`the relationship matrix is not positive definite; use bend() or give its inverse`	稀疏引擎与奇异的亲缘关系矩阵。	对矩阵进行弯曲或混合（第 13.7 节）、提供其逆矩阵，或使用稠密引擎。
`REML likelihoods are only comparable with identical fixed effects`	用 `lrt()` 比较了固定效应不同的模型。	只比较固定部分相同的模型；对固定效应使用 Wald 检验。

14 模拟研究：估计量的性质

与其他软件的比较（第 15 章）验证了 MLREML 能够正确计算似然及其最大值。另一个问题是，在实际使用的样本量下，REML 估计量、其标准误和检验的表现如何。本章通过两个小型模拟回答这一问题，读者可以重复并修改这些模拟。

14.1 随机基因型的完全区组设计

我们模拟 200 个试验，每个试验有 40 个基因型、3 个完全区组，其中 $\sigma_g^2 = 1$，$\sigma_e^2 = 2$，区组效应为固定效应。基于基因型均值的遗传力为 $H^2 = \sigma_g^2 / \left(\sigma_g^2 + \sigma_e^2/3\right) = 0.6$。

```
sim_rcbd <- function(seed, ngen = 40, nblk = 3, sg2 = 1, se2 = 2) {
  set.seed(seed)
```

```
  dd <- expand.grid(gen = factor(1:ngen), blk = factor(1:nblk))
  dd$y <- c(0, 0.5, -0.5)[dd$blk] + rnorm(ngen, sd = sqrt(sg2))[dd$gen] +
    rnorm(nrow(dd), sd = sqrt(se2))
  f <- mlreml(y ~ blk, random = ~ gen, data = dd, trace = FALSE, pev = FALSE, s
tore = FALSE)
  h <- vpredict(f, H2 ~ V1 / (V1 + V2 / 3))
  c(sg2 = f$theta[[1]], se2 = f$theta[[2]], se_sg2 = f$varcomp$std.error[1],
    H2 = h$estimate, se_H2 = h$std.error, bound = f$varcomp$bound[1] == "B",
    conv = f$converged)
}
res1 <- as.data.frame(t(sapply(1:200, sim_rcbd)))
c(converged = mean(res1$conv), on_boundary = mean(res1$bound))

##   converged on_boundary
##           1           0

truth <- c(sg2 = 1, se2 = 2, H2 = 0.6)
tab1 <- data.frame(parameter = names(truth), true = truth,
                   mean = colMeans(res1[names(truth)]),
                   relative_bias_pct = 100 * (colMeans(res1[names(truth)]) - tr
uth) / truth,
                   empirical_sd = sapply(res1[names(truth)], sd))
tab1$mean_se <- c(mean(res1$se_sg2), NA, mean(res1$se_H2))
knitr::kable(tab1, digits = 3, row.names = FALSE,
             caption = "Simulation of 200 complete block experiments: mean, bia
s and variability of the REML estimators.")
```

200 个完全区组试验的模拟：REML 估计量的均值、偏差和变异性。

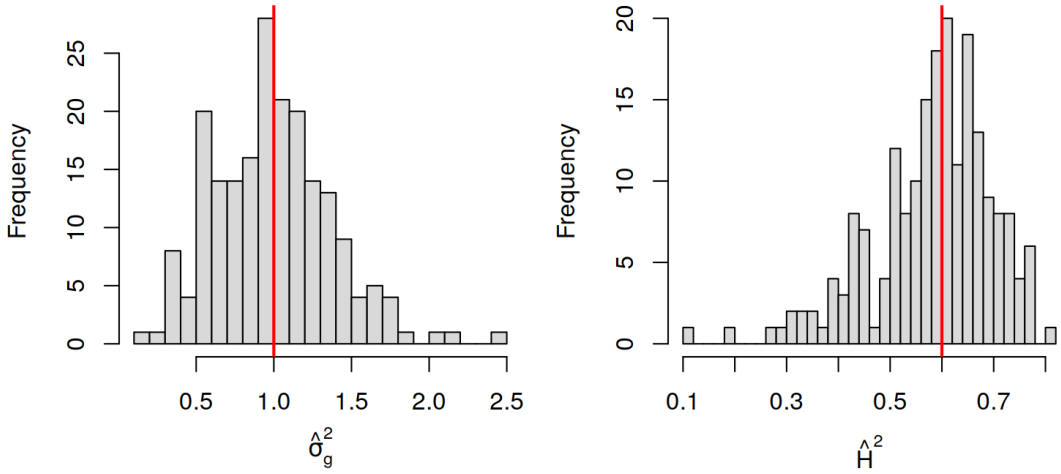
parameter	true	mean	relative_bias_pct	empirical_sd	mean_se
sg2	1.0	0.997	-0.292	0.378	0.392
se2	2.0	1.990	-0.511	0.326	NA
H2	0.6	0.582	-3.061	0.116	0.116

```
cov95 <- function(est, se, v) mean(est - 1.96 * se <= v & v <= est + 1.96 * se)
c(coverage_sg2 = cov95(res1$sg2, res1$se_sg2, 1), coverage_H2 = cov95(res1$H2,
res1$se_H2, 0.6))

## coverage_sg2  coverage_H2
##         0.95         0.94
```

REML 估计量的偏差很小，由平均信息矩阵得到的平均标准误接近估计值的经验标准差，表明在 40 个基因型的情况下渐近近似是合理的。Wald 区间的覆盖率接近名义上的 95 %。$\hat{\sigma}_g^2$ 的分布呈右偏，这对于方差估计量而言是预料之中的：

```
op <- par(mfrow = c(1, 2), mar = c(4, 4, 1, 1))
hist(res1$sg2, breaks = 25, col = "grey85", main = "", xlab = expression(hat(si
gma)[g]^2))
abline(v = 1, col = "red", lwd = 2)
hist(res1$H2, breaks = 25, col = "grey85", main = "", xlab = expression(hat(H)^
2))
abline(v = 0.6, col = "red", lwd = 2)
```



200 个模拟试验中遗传方差（左）和遗传力（右）的 REML 估计值分布。竖线标出真实值。

```
par(op)
```

14.2 边界上似然比检验的检验水平

为了检验 `lrt()` 的边界校正，我们模拟 200 个**不含**遗传方差（$\sigma^2_g = 0$）的试验，并记录在 5 % 水平下拒绝 $H_0: \sigma^2_g = 0$ 的比例，分别使用朴素的 χ^2_1 和 50:50 混合分布。

```
sim_null <- function(seed) {
  set.seed(seed)
  dd <- expand.grid(gen = factor(1:40), blk = factor(1:3))
  dd$y <- rnorm(nrow(dd), sd = sqrt(2))
  f1 <- mlreml(y ~ blk, random = ~ gen, data = dd, trace = FALSE, pev = FALSE,
store = FALSE)
  f0 <- mlreml(y ~ blk, data = dd, trace = FALSE, pev = FALSE, store = FALSE)
  c(mixture = lrt(f0, f1, boundary = TRUE)$p.value, naive = lrt(f0, f1, boundar
y = FALSE)$p.value,
    boundary = f1$varcomp$bound[1] == "B")
}
pv <- as.data.frame(t(sapply(1:200, sim_null)))
colMeans(pv[c("mixture", "naive")] < 0.05)

## mixture   naive
##   0.020   0.015

mean(pv$boundary)

## [1] 0.49
```

在 49 % 的模拟中，遗传方差被估计在边界上，接近渐近理论预测的一半。在这些模拟中统计量为零，因此在此样本量下两种检验都是保守的：朴素的 χ^2_1 在 1.5 % 的情况下拒绝，50:50 混合分布在 2 % 的情况下拒绝，更接近名义水平 5 %。混合分布是正确的渐近近似；当随机因子的水平较少时，检验仍然略显保守，因此显著的 p 值是存在遗传方差的可靠证据。

14.3 空间模型

第二个模拟在 16 行 × 12 列的网格上评价 AR1 × AR1 模型，共 48 个基因型、4 次重复，其中 $\rho_r = 0.7$，$\rho_c = 0.4$，空间方差为 1，遗传方差为 0.5，块金为 0.2。

```
sim_sp <- function(seed, rr = 0.7, rc = 0.4) {
  set.seed(seed)
  dd <- expand.grid(row = 1:16, col = 1:12)
  dd$rep <- factor((dd$col - 1) %/% 3 + 1)
  dd$gen <- factor(unlist(lapply(1:4, function(r) sample(1:48))))
  Rr <- rr^abs(outer(1:16, 1:16, "-")); Rc <- rc^abs(outer(1:12, 1:12, "-"))
  xi <- drop(t(chol(kronecker(Rc, Rr))) %*% rnorm(192))       # rows vary faste
st
  dd$y <- rnorm(48, sd = sqrt(0.5))[dd$gen] + xi + rnorm(192, sd = sqrt(0.2))
  f <- mlreml(y ~ rep, random = ~ gen + units, residual = ~ ar1(row):ar1(col),
              data = dd, trace = FALSE, pev = FALSE, store = FALSE)
  c(f$theta, conv = f$converged)
}
res3 <- as.data.frame(t(sapply(1:40, sim_sp)))
names(res3) <- c("sg2", "nugget", "s2_spatial", "rho_row", "rho_col", "conv")
truth3 <- c(sg2 = 0.5, nugget = 0.2, s2_spatial = 1, rho_row = 0.7, rho_col = 0.
4)
data.frame(true = truth3, median = sapply(res3[names(truth3)], median),
           mean = colMeans(res3[names(truth3)]), sd = sapply(res3[names(truth
3)], sd))
```

```
##             true median   mean      sd
## sg2          0.5 0.5232 0.5091 0.12644
## nugget       0.2 0.1568 0.1723 0.11259
## s2_spatial   1.0 1.0209 1.0445 0.28329
## rho_row      0.7 0.6573 0.6636 0.09491
## rho_col      0.4 0.3723 0.4015 0.14507
## [1] 0.95
```

```
mean(res3$conv)
```

```
## [1] 0.95
```

95 % 的拟合实现了收敛。自回归参数和遗传方差得到了很好的恢复，偏差很小。正如地统计学中众所周知的那样，将块金与空间方差分离更为困难：在这种大小的网格上，两个组分都有相当大的抽样变异，而它们的和比各自单独的估计要精确得多。

```
c(mean_sum = mean(res3$nugget + res3$s2_spatial), sd_sum = sd(res3$nugget + res
3$s2_spatial))
```

```
## mean_sum   sd_sum
##    1.217    0.290
```

这些模拟有意设计得较小，以便在几分钟内完成运行。若要进行正式研究，请将重复次数增加到 1,000 次或更多，并探索感兴趣的试验规模和参数值。

15 数值验证、性能和局限性

15.1 与其他软件的比较

当估计程序与成熟软件拟合同一模型时，二者必须给出相同的结果。下表比较了本指南中所有 `lme4` 和 `nlme` 能够拟合的模型在 MLREML 与这些软件包之间的 REML 对数似然，以及函数 `gblup()` 与通用引擎之间的比较。每次检查软件包时，软件包的自动测试（`tests/testthat`）都会重复这些比较。

```
library(lme4); library(nlme)
v <- list()
d <- agridat::john.alpha
f <- mlreml(yield ~ rep, random = ~ gen + rep:block, data = d, trace = FALSE)
v[[1]] <- c("Alpha lattice, two variances", "lme4", f$loglik,
            logLik(lmer(yield ~ rep + (1 | gen) + (1 | rep:block), data = d)))
f <- mlreml(Reaction ~ Days, random = ~ us(pol(Days, 1)):id(Subject), data = sl
eepstudy, trace = FALSE)
v[[2]] <- c("Random regression (us)", "lme4", f$loglik,
            logLik(lmer(Reaction ~ Days + (Days | Subject), sleepstudy)))
f <- mlreml(distance ~ age * Sex, random = ~ Subject, residual = ~ diag(Sex):un
its, data = ort,
            trace = FALSE)
v[[3]] <- c("Heterogeneous residual (diag)", "nlme::lme", f$loglik,
            logLik(lme(distance ~ age * Sex, random = ~ 1 | Subject,
                       weights = varIdent(form = ~ 1 | Sex), data = ort)))
f <- mlreml(distance ~ age * Sex, residual = ~ ar1(age):id(Subject), data = ort,
 trace = FALSE)
v[[4]] <- c("Autoregressive residual (ar1)", "nlme::gls", f$loglik,
            logLik(gls(distance ~ age * Sex, correlation = corExp(form = ~ age
| Subject), data = ort)))
f <- mlreml(distance ~ age * Sex, residual = ~ us(age):id(Subject), data = ort,
 trace = FALSE)
v[[5]] <- c("Unstructured residual (us)", "nlme::gls", f$loglik,
            logLik(gls(distance ~ age * Sex, correlation = corSymm(form = ~ 1 |
 Subject),
                       weights = varIdent(form = ~ 1 | age), data = ort)))
v[[6]] <- c("GBLUP (vm)", "spectral gblup()", f1$loglik, g1$loglik)
tab <- as.data.frame(do.call(rbind, v))
names(tab) <- c("model", "reference", "logLik_MLREML", "logLik_reference")
tab$logLik_MLREML <- as.numeric(tab$logLik_MLREML)
tab$logLik_reference <- as.numeric(tab$logLik_reference)
tab$difference <- signif(tab$logLik_MLREML - tab$logLik_reference, 2)
knitr::kable(tab, digits = 4, caption = "REML log-likelihood of MLREML and of o
ther software.")
```

MLREML 与其他软件的 REML 对数似然。

model	reference	logLik_MLREML	logLik_reference	difference
α-格子，两个方差	lme4	-46.6	-46.6	0
随机回归（us）	lme4	-871.8	-871.8	0

model	reference	logLik_MLREML	logLik_reference	difference
异质残差（diag）	nlme::lme	-207.6	-207.6	0
自回归残差（ar1）	nlme::gls	-222.3	-222.3	0
非结构化残差（us）	nlme::gls	-212.3	-212.3	0
GBLUP（vm）	谱分解 gblup()	-794.5	-794.5	0

差异在收敛容差的量级上。方差组分、固定效应、BLUP 和 SED 也一致（第 4 章和第 10 章）。对于没有任何通用 R 软件包能够拟合的结构（带块金的 AR1 × AR1、因子分析、环境间为非结构化结构的遗传项），自动测试会验证所找到的点是最大值：扰动任何参数都会使似然减小。

系谱工具与 `pedigreemm` 进行比较：

```
Fp <- pedigreemm::inbreeding(pedCowsR)
c(max_diff_inbreeding = max(abs(Fp - Fi[p@label])))

## max_diff_inbreeding
##                   0

s <- sample(p@label, 300)
A <- Amatrix(pp)
Ap <- as.matrix(pedigreemm::getA(pedCowsR))[s, s]
c(max_diff_A = max(abs(Ap - A[s, s])))

## max_diff_A
##   1.11e-16

rm(A); invisible(gc())
```

其他比较。以下代码检验其他功能：(1) 距离小于 1 的指数相关与 `nlme::gls()` 的比较，MLREML 达到了相同的最大值；(2) `wald()` 所检验假设的 Kenward–Roger F 统计量和分母自由度与 `pbkrtest` 的比较；(3) 稀疏引擎与稠密引擎的比较。

```
## 1. exponential correlation with distances smaller than one
set.seed(7)
dx <- data.frame(t = rep(c(0, 0.3, 0.7, 1.2, 2), 20), id = factor(rep(1:20, eac
h = 5)))
dx$y <- 0.5 * dx$t + unlist(lapply(1:20, function(i) cumsum(rnorm(5)) / 2))
fx <- mlreml(y ~ t, residual = ~ expc(t):id(id), data = dx, trace = FALSE)
gx <- gls(y ~ t, correlation = corExp(form = ~ t | id), data = dx)
c(MLREML = fx$loglik, nlme = as.numeric(logLik(gx)))

## MLREML   nlme
## -84.21 -84.21

c(rho_MLREML = unname(fx$theta[2]), rho_nlme = unname(exp(-1 / coef(gx$modelStr
uct$corStruct, FALSE))))

## rho_MLREML   rho_nlme
##     0.7511     0.7511
```

```r
## 2. Kenward-Roger F tests against pbkrtest
kr_row <- function(label, f, l, term) {
  j <- which(f$assign == match(term, attr(f$terms_fixed, "term.labels")))
  L <- chol(solve(vcov(f)))[j, , drop = FALSE]        # incremental hypothesis
of wald()
  w <- wald(f, ddf = "KR"); w <- w[w$term == term, ]
  pk <- KRmodcomp(l, L)$stats
  data.frame(model = label, term = term, F_MLREML = w$F.inc, F_pbkrtest = pk$Fs
tat,
             ddf_MLREML = w$ddf.inc, ddf_pbkrtest = pk$ddf)
}
ja <- agridat::john.alpha
oats <- as.data.frame(nlme::Oats)
oats$nitro <- factor(oats$nitro)
oats$Block <- factor(as.character(oats$Block)); oats$Variety <- factor(as.chara
cter(oats$Variety))
f1 <- mlreml(yield ~ rep + gen, random = ~ rep:block, data = ja, trace = FALSE,
 tol = 1e-10)
l1 <- lmer(yield ~ rep + gen + (1 | rep:block), data = ja)
f2 <- mlreml(Reaction ~ Days, random = ~ us(pol(Days, 1)):id(Subject), data = s
leepstudy,
             trace = FALSE, tol = 1e-10)
l2 <- lmer(Reaction ~ Days + (Days | Subject), sleepstudy)
f3 <- mlreml(yield ~ Variety * nitro, random = ~ Block + Block:Variety, data =
oats,
             trace = FALSE, tol = 1e-10)
l3 <- lmer(yield ~ Variety * nitro + (1 | Block) + (1 | Block:Variety), oats)
kr <- rbind(kr_row("Alpha lattice", f1, l1, "rep"), kr_row("Alpha lattice", f1,
 l1, "gen"),
            kr_row("Random regression", f2, l2, "Days"),
            kr_row("Split plot (Oats)", f3, l3, "Variety"), kr_row("Split plot
(Oats)", f3, l3, "nitro"),
            kr_row("Split plot (Oats)", f3, l3, "Variety:nitro"))
knitr::kable(kr, digits = 4, row.names = FALSE,
             caption = "Kenward-Roger F statistics and denominator degrees of f
reedom of MLREML and pbkrtest.")
```

MLREML 和 pbkrtest 的 Kenward-Roger F 统计量和分母自由度。

模型	term	F_MLREML	F_pbkrtest	ddf_MLREML	ddf_pbkrtest
α-格子	rep	9.2124	9.2124	11.52	11.52
α-格子	gen	5.3628	5.3628	35.50	35.50
随机回归	Days	45.8530	45.8530	17.00	17.00
裂区（Oats）	Variety	1.4853	1.4853	10.00	10.00
裂区（Oats）	nitro	37.6856	37.6857	45.00	45.00
裂区（Oats）	Variety:nitro	0.3028	0.3028	45.00	45.00

F 统计量和分母自由度与 pbkrtest 在五位或更多有效数字上一致。在裂区设计中，该方法重现了主区误差（10）和副区误差（45）的经典自由度，且 $\lambda = 1$。

```
## 3. sparse engine against the dense engine
both <- function(label, ...) {
  fd <- mlreml(..., trace = FALSE, engine = "dense")
  fs <- mlreml(..., trace = FALSE, engine = "sparse")
  bd <- do.call(rbind, fd$blups); bs <- do.call(rbind, fs$blups)
  f <- function(x) sprintf("%.1e", x)
  data.frame(model = label, logLik = round(fd$loglik, 2), logLik_diff = f(fd$lo
glik - fs$loglik),
             theta_reldiff = f(max(abs(fd$theta - fs$theta) / pmax(abs(fd$thet
a), 1e-8))),
             blup_diff = f(max(abs(bd$blup - bs$blup))), pev_diff = f(max(abs(b
d$pev - bs$pev))))
}
sp <- rbind(
  both("Alpha lattice (two variances)", yield ~ rep, random = ~ gen + rep:block,
 data = ja),
  both("Random regression us(leg)", Reaction ~ Days, random = ~ us(leg(Days,
1)):id(Subject),
       data = sleepstudy),
  both("Heterogeneous residual diag(Sex):units", distance ~ age * Sex, random =
 ~ Subject,
       residual = ~ diag(Sex):units, data = ort),
  both("Split plot (two variances)", yield ~ Variety * nitro, random = ~ Block
+ Block:Variety,
       data = oats))
knitr::kable(sp, row.names = FALSE, align = "lrrrrr",
             caption = "Differences between the dense and the sparse engines (l
og-likelihood, maximum relative difference of the variance parameters, maximum
absolute differences of BLUPs and PEVs).")
```

稠密引擎与稀疏引擎之间的差异（对数似然、方差参数的最大相对差异、BLUP 和 PEV 的最大绝对差异）。

模型	logLik	logLik_diff	theta_reldiff	blup_diff	pev_diff
α-格子（两个方差）	-46.6	-1.8e-12	2.8e-15	6.7e-15	8.3e-17
随机回归 us(leg)	-871.8	3.0e-12	1.3e-14	4.0e-13	3.7e-12
异质残差 diag(Sex):units	-207.6	6.2e-12	6.8e-15	1.8e-13	5.9e-15
裂区（两个方差）	-264.5	-1.3e-12	1.2e-14	6.3e-13	7.1e-13

两个引擎给出的结果在舍入误差范围内相同。此外，直接–母体项已通过对似然 (2.6) 的直接最大化进行了验证，其中 $\mathbf{V}$ 由 (2.18) 构建（估计值在优化器精度内一致，BLUP 和 PEV 在 10^{-13} 内一致）；软件包的自动测试还验证了当协方差固定为零时，它能重现含两个独立项 `vm(animal, A) + vm(dam, A)` 的模型。

15.2 计算时间和内存

MLREML 稠密引擎的成本主要由对稠密 $n \times n$ 矩阵 $\mathbf{V}$ 的运算决定。为了测量这一成本，在同一台计算机上（单核，OpenBLAS）对不同规模的模拟数据拟合了 GBLUP 模型：

```
times <- do.call(rbind, lapply(c(500, 1000, 2000, 3000), function(n) {
  set.seed(n)
  Msim <- matrix(rbinom(n * 1000, 2, 0.3), n); rownames(Msim) <- paste0("i", 1:
n)
  Ks <- Gmatrix(Msim) + diag(1e-3, n)
  ds <- data.frame(id = rownames(Msim), y = drop(Msim %*% rnorm(1000, 0, 0.05))
 + rnorm(n))
  t1 <- system.time(fs <- mlreml(y ~ 1, random = ~ vm(id, Ks), data = ds, trace
 = FALSE))[3]
  t2 <- system.time(gblup(setNames(ds$y, ds$id), Ks))[3]
  data.frame(n = n, iterations = fs$iterations, sec_mlreml = t1,
             sec_per_iteration = t1 / (fs$iterations + 2), sec_gblup = t2,
             memory_V_GB = round(3 * 8 * n^2 / 1e9, 2))
}))
knitr::kable(times, digits = 2, row.names = FALSE,
             caption = "Fitting time of a GBLUP model by number of observations.
")
```

按观测数划分的 GBLUP 模型拟合时间。

n	iterations	sec_mlreml	sec_per_iteration	sec_gblup	memory_V_GB
500	4	0.12	0.02	0.04	0.01
1000	3	0.53	0.11	0.24	0.02
2000	4	4.05	0.68	1.47	0.10
3000	3	9.25	1.85	17.63	0.22

每次迭代的时间大约随 n^3 增长，内存随 n^2 增长（内存列估计的是三个双精度 $n \times n$ 矩阵：**V**、**P** 和一个工作矩阵）。在 8 GB 内存下，MLREML 可以舒适地拟合约 6,000 条记录的模型；在 16 GB 下约为 9,000 条。在只有一个随机项的模型中，AI 算法只需很少的迭代即可收敛，因此 `mlreml()` 与 `gblup()` 一样快甚至更快。`gblup()` 的成本主要由谱分解决定，而谱分解比 Cholesky 分解贵好几倍；当通用模型需要许多次迭代或者分解可以重复使用时，它的优势才会显现。

参数个数的影响是线性的：每个参数都需要构建其导数矩阵并计算一个迹，成本为 $O(n^2)$。参数较多的模型（环境较多的 `us`、包含多个因子的 `fa`）也需要更多次迭代。

稀疏引擎。为了测量稀疏引擎，模拟了奶牛类型的群体：十个重叠世代、跨牛群使用的人工授精公牛、牛群内的母牛、所有已知父母的动物都有记录，以及按牛群和年份定义的同期组（固定效应，每组约 20 条记录）。在与上文相同的计算机上（单核、OpenBLAS、8 GB 内存）拟合了加性动物模型 `y ~ hy`、`random = ~ vm(id, Ai)`，以及使用 `random = ~ str(id, dam, K = Ai)` 的直接-母体模型，另外还拟合了一个不含系谱的模型，用于牛群中奶牛的重复记录，`y ~ year`、`random = ~ herd + cow`，每头奶牛四条记录。代码随软件包一起安装：`system.file("scale", "sparse_scale.R", package = "MLREML")`。

稀疏引擎：问题规模、计算时间和内存（因子在超节点存储中的元素个数，包括超节点中显式存储的零）。

模型	记录数	动物或奶牛数	方程数	因子元素（百万）	迭代次数	时间（秒）	峰值内存（GB）
动物模型	23,750	25,000	26,234	1.5	4	3.6	0.34
动物模型	47,500	50,000	52,468	3.8	4	12.3	0.65
动物模型	95,000	100,000	104,908	10.7	4	20.1	0.77
动物模型	237,500	250,000	262,287	49.4	5	125.1	2.36
直接–母体	23,750	25,000	51,234	4.0	8	20.0	0.54
直接–母体	47,500	50,000	102,468	11.1	5	48.6	1.19
直接–母体	95,000	100,000	204,908	34.4	8	134.5	2.15
重复记录	1,000,000	250,000	250,358	3.0	5	26.5	1.43
重复记录	2,000,000	500,000	500,691	6.0	7	63.2	2.56

在所有情况下估计值都接近模拟值（例如，在 100,000 条记录的动物模型中，加性方差和残差方差的估计值为 0.304 和 0.644，模拟值为 0.30 和 0.60，另加一个加性模型未包含的母体组分；在一百万条记录的模型中，牛群、奶牛和残差方差的估计值为 2.00、1.00 和 2.99，模拟值为 2、1 和 3）。时间和内存取决于混合模型方程 Cholesky 因子的非零元素个数，而不是记录数。在动物模型中，系谱和同期组将许多动物联系在一起，因子会发生填充：从 100,000 条记录增至 250,000 条记录时，其规模扩大了 4.6 倍，时间增加了 6 倍。在 8 GB 内存下，以这种群体结构能够拟合的最大动物模型是 250,000 条记录的加性模型和 100,000 条记录的直接–母体模型；下一个尝试的规模（500,000 条和 250,000 条记录）超出了内存。随机效应为嵌套结构的模型（例如牛群内奶牛的重复记录）的因子非零元素很少，稀疏引擎在约一分钟内就拟合了一百万条和两百万条记录。因此，包含数百万条记录的动物模型需要

内存比此处所用计算机大数倍的计算机，或者对于常规的全国评估，需要使用带迭代求解器的专业程序（第 15.4 节）。

15.3 大型数据集的策略

- **稀疏引擎。**对于其支持的结构，`engine = "sparse"` 可一步分析所有记录（第 2.12 节）；对于系谱亲缘关系请使用 `Ainverse()`，并请注意其成本取决于 Cholesky 因子的填充程度，而填充程度随记录所连接的固定效应和随机效应数量的增加而增加。
- **两阶段分析。**先分别拟合每个试验或环境，然后对调整均值（BLUE）及其权重进行分析（Smith et al., 2001; Piepho et al., 2012）。均值将观测数减少为每个基因型和环境一个。
- **数据压缩。**将个体汇总为组（例如按表型的分位数），并对各组均值拟合加权模型。
- **用子样本估计方差。**在一个有代表性的子样本上估计组分，然后将其固定（`start` 和 `fix`），用 `gblup()` 预测完整数据集。
- **更多内存和并行 BLAS。**使用多线程的 OpenBLAS 或 MKL，每次迭代的时间几乎与核心数成比例地减少。

15.4 版本 1.0.0 的局限性

1. **规模。**稠密引擎仅限于几千条记录。在 8 GB 内存的计算机上，稀疏引擎可拟合包含几十万条记录的动物模型，以及包含数百万条记录的嵌套随机效应模型（第 15.2 节），因为其内存随 Cholesky 因子的填充而增长；它并不打算取代用于包含数千万条记录的全国评估、数据迭代求解器或包含数十万头基因分型动物的一步法基因组模型的专业程序（ASReml、BLUPF90、DMU、WOMBAT）。带相关参数的结构（`cs`、`ar1`、`expc`、`sexp`）和因子分析结构仅在稠密引擎中可用。
2. **项之间的协方差。**两个随机项只能通过 `str()` 相关，这要求它们的因子共享同一矩阵 **K** 的水平（例如直接和母体遗传效应）；不支持使用不同亲缘关系矩阵或不同基的项之间的相关。截距和斜率在单个随机回归项内相关。
3. **自由度。**稠密引擎可使用 Kenward–Roger 自由度；稀疏引擎使用 $n - p$，尚未实现 Satterthwaite 近似。
4. **分布。**只能拟合正态响应变量；不支持广义线性混合模型。
5. **结构。**某些 ASReml 特有的结构尚不可用，例如具有独立方差的 `corgh`、ARMA、随机三次样条或用于条件项的 `at()`，不过 `diag()` 和 `us()` 涵盖了 `at()` 的大多数用途。使用 `diag(env):ar1(row):ar1(col)` 时，空间模型的相关对所有环境是共同的。
6. **边界上的标准误。**与 ASReml 一样，位于界限上的参数的标准误无效。

这些局限性是未来版本的开发重点，特别是将稀疏引擎扩展到带相关参数的结构和因子分析模型，以及为稀疏引擎实现 Kenward–Roger 调整。

16 函数汇总

下表汇总了所有导出的函数。每个函数的完整文档（包括其参数、返回值和示例）见本文档末尾作为附录的参考手册，也可以在 R 中通过 `?function_name` 查看。

MLREML 函数。

函数	用途
`mlreml()`	用 AI-REML 拟合线性混合模型（稠密或稀疏引擎）。
`summary()`, `print()`	方差组分、似然、AIC 和 BIC；带标准误的固定效应。
`coef()`	固定效应（`type = "fixed"`）或带 PEV、标准误和可靠性的 BLUP（`type = "random"`）。
`fitted()`, `residuals()`, `vcov()`, `logLik()`	标准的 R 方法。
`wald()`	固定项的递增和条件 Wald 检验，使用 Kenward–Roger 或残差分母自由度。
`predict()`	某一分类的预测均值、标准误和 SED 矩阵。
`vpredict()`	方差参数的函数及其 delta 方法标准误。
`lrt()`	似然比检验，含边界校正。
`vc_matrix()`	`diag`、`us` 或 `fa` 组分或 `str()` 项的协方差和相关矩阵；载荷和特殊方差。
`variogram()`	田间试验残差的样本变异函数。
`plot()`	诊断图和收敛图。
`pedigree_prepare()`	清理、补全并排序系谱。
`inbreeding_coef()`	近交系数（Meuwissen and Luo, 1992）。
`Amatrix()`	稠密加性亲缘关系矩阵（表格法）。
`Ainverse()`	**A** 的稀疏逆矩阵（考虑近交的 Henderson 规则），可直接用于 `vm()` 和 `str()`。
`snp_qc()`	标记质量控制（MAF、每个标记和每个个体的检出率）。
`Gmatrix()`	基因组亲缘关系矩阵（VanRaden、Yang 或缩放型）。
`align_G()`	将 **G** 与 $\mathbf{A}_{22}$ 对齐。

函数	用途
`Hmatrix()`	一步法矩阵 **H** 或其逆矩阵。
`bend()`	将对称矩阵转换为正定矩阵。
`gblup()`	基于谱旋转的 GBLUP。
`cv_gblup()`	GBLUP 的 k 折交叉验证。

16.1 与 ASReml-R 的语法对应关系

对于 ASReml-R 用户，下表翻译了最常用的语法结构。

ASReml-R 语法的对应翻译。

ASReml-R（版本 4）	MLREML
`asreml(fixed = y ~ rep, random = ~ gen, data = d)`	`mlreml(y ~ rep, random = ~ gen, data = d)`
`random = ~ vm(animal, ainv)`	`random = ~ vm(animal, A)`（矩阵 **A**）或 `random = ~ vm(animal, Ainverse(ped))`
`random = ~ fa(env, 2):id(gen)`	相同
`random = ~ us(env):vm(gen, Ginv)`	`random = ~ us(env):vm(gen, G)`
`residual = ~ dsum(~ units | env)`	`residual = ~ diag(env):units`
`residual = ~ ar1(row):ar1(col)`	相同
`random = ~ str(~ animal + dam, ~ us(2):vm(animal, ainv))`	`random = ~ str(animal, dam, K = A)`
`random = ~ leg(age, 2):id(animal)` 配合 `us()`	`random = ~ us(leg(age, 2)):id(animal)`
`random = ~ and(male)` 与 `female` 一起使用	`random = ~ mm(female, male)`
`fixed = cbind(y1, y2) ~ trait, residual = ~ id(units):us(trait)`	`cbind(y1, y2) ~ trait, residual = ~ us(trait):units`
`summary(fit)$varcomp`	`summary(fit)$varcomp`
`wald(fit)`	`wald(fit)`（默认使用 Kenward–Roger 分母自由度）
`predict(fit, classify = "gen")`	`predict(fit, classify = "gen")`
`vpredict(fit, h2 ~ V1/(V1+V2))`	相同
`lrt(fit0, fit1)`	相同

最重要的区别在于 vm() 接收的是亲缘关系矩阵本身，因为 MLREML 的稠密引擎处理的是模型的边际形式；当逆矩阵带有属性 INVERSE = TRUE 时（如 Ainverse() 的结果），也可以提供其逆矩阵。使用稠密引擎时这些矩阵可以是奇异的；稀疏引擎则需要它们是正定的。

16.2 模型快速指南

以下模板涵盖了最常见的分析。变量名仅作示例。

```
## Complete blocks, random genotypes
mlreml(y ~ rep, random = ~ gen, data = d)

## Alpha lattice or incomplete blocks, fixed genotypes
mlreml(y ~ rep + gen, random = ~ rep:block, data = d)

## Row x column spatial analysis with nugget and linear trend
mlreml(y ~ rep + row_num, random = ~ gen + units,
       residual = ~ ar1(row):ar1(column), data = d)

## Irregular spatial data (coordinates)
mlreml(y ~ 1, random = ~ gen + units, residual = ~ sexp(x, y), data = d)

## MET: genetic and residual variances by environment
mlreml(y ~ env, random = ~ env:rep + diag(env):id(gen),
       residual = ~ diag(env):units, data = d)

## MET: two-factor factor analytic model
mlreml(y ~ env, random = ~ env:rep + fa(env, 2):id(gen),
       residual = ~ diag(env):units, data = d, maxit = 200)

## GBLUP and multi-environment GBLUP
mlreml(y ~ 1, random = ~ vm(gen, G), data = d)
mlreml(y ~ env, random = ~ us(env):vm(gen, G), residual = ~ diag(env):units, da
ta = d)

## Pedigree + markers (two kernels)
mlreml(y ~ 1, random = ~ vm(gen, A) + vm(gen, G), data = d)

## Single-step
H <- Hmatrix(A, G); mlreml(y ~ 1, random = ~ vm(id, H), data = d)

## Animal model, repeatability and maternal effect
mlreml(y ~ herd + sex, random = ~ vm(animal, A), data = d)
mlreml(y ~ herd + parity, random = ~ vm(animal, A) + id(animal), data = d)
mlreml(y ~ herd, random = ~ vm(animal, A) + id(dam), data = d)

## Direct-maternal animal model with maternal permanent environment
mlreml(y ~ herd + sex, random = ~ str(animal, dam, K = A) + id(dam), data = d)

## Bivariate with genetic and residual correlations
mlreml(cbind(y1, y2) ~ trait + trait:herd, random = ~ us(trait):vm(animal, A),
       residual = ~ us(trait):units, data = d)

## Repeated measures with autoregressive residual
mlreml(y ~ trt * time, random = ~ subject, residual = ~ ar1(time):id(subject),
data = d)

## Random regression
```

```
mlreml(y ~ group + age, random = ~ us(leg(age, 2)):vm(animal, A) +
       us(leg(age, 2)):id(animal), residual = ~ diag(age_class):units, data = d)

## Diallel (GCA, SCA, maternal, reciprocal)
mlreml(y ~ block, random = ~ mm(female, male) + cross + female + cross_ord, dat
a = d)

## Known variance components (BLUE and BLUP only)
mlreml(y ~ 1, random = ~ vm(gen, G), data = d,
       start = c("vm(gen, G)!sigma2" = 0.3, "R!units!sigma2" = 0.6),
       fix = c("vm(gen, G)!sigma2", "R!units!sigma2"))

## Large data set: sparse engine with the inverse of A
Ai <- Ainverse(ped)
mlreml(y ~ hys + sex, random = ~ vm(animal, Ai) + id(animal), data = d, engine
= "sparse")
```

16.3 拟合后函数

```
summary(fit)                              # variance components
coef(fit, "random", "vm(gen, G)")         # BLUP, PEV, reliability
wald(fit, ddf = "KR")                     # tests of fixed effects (Kenward-Roger)
predict(fit, classify = "env:gen")        # predicted means and SED
vpredict(fit, h2 ~ V1 / (V1 + V2))        # functions of components
vc_matrix(fit, "us(env):vm(gen, G)")      # covariance and correlation matrices
lrt(fit0, fit1)                           # likelihood ratio
variogram(fit, "row", "column")           # sample variogram
plot(fit)                                 # diagnostics
```

参考文献

Baker, R.J. (1978). Issues in diallel analysis. *Crop Science* 18, 533–536.

Bates, D., Mächler, M., Bolker, B., Walker, S. (2015). Fitting linear mixed-effects models using lme4. *Journal of Statistical Software* 67(1), 1–48.

Belenky, G. et al. (2003). Patterns of performance degradation and restoration during sleep restriction and subsequent recovery. *Journal of Sleep Research* 12, 1–12.

Besag, J., Higdon, D. (1999). Bayesian analysis of agricultural field experiments. *Journal of the Royal Statistical Society B* 61, 691–746.

Burgueño, J., de los Campos, G., Weigel, K., Crossa, J. (2012). Genomic prediction of breeding values when modeling genotype × environment interaction using pedigree and dense molecular markers. *Crop Science* 52, 707–719.

Butler, D.G., Cullis, B.R., Gilmour, A.R., Gogel, B.J., Thompson, R. (2017). *ASReml-R Reference Manual Version 4*. VSN International, Hemel Hempstead.

Chen, Y., Davis, T.A., Hager, W.W., Rajamanickam, S. (2008). Algorithm 887: CHOLMOD, supernodal sparse Cholesky factorization and update/downdate. *ACM Transactions on Mathematical Software* 35(3), 22.

Christensen, O.F., Lund, M.S. (2010). Genomic prediction when some animals are not genotyped. *Genetics Selection Evolution* 42, 2.

Christensen, O.F., Madsen, P., Nielsen, B., Ostersen, T., Su, G. (2012). Single-step methods for genomic evaluation in pigs. *Animal* 6, 1565–1571.

Cockerham, C.C., Weir, B.S. (1977). Quadratic analyses of reciprocal crosses. *Biometrics* 33, 187–203.

Crossa, J. et al. (2010). Prediction of genetic values of quantitative traits in plant breeding using pedigree and molecular markers. *Genetics* 186, 713–724.

Crowder, M.J., Hand, D.J. (1990). *Analysis of Repeated Measures*. Chapman and Hall, London.

Cullis, B.R., Smith, A.B., Coombes, N.E. (2006). On the design of early generation variety trials with correlated data. *Journal of Agricultural, Biological and Environmental Statistics* 11, 381–393.

Erisman, A.M., Tinney, W.F. (1975). On computing certain elements of the inverse of a sparse matrix. *Communications of the ACM* 18, 177–179.

Gilmour, A.R., Cullis, B.R., Verbyla, A.P. (1997). Accounting for natural and extraneous variation in the analysis of field experiments. *Journal of Agricultural, Biological and Environmental Statistics* 2, 269–293.

Gilmour, A.R., Gogel, B.J., Cullis, B.R., Welham, S.J., Thompson, R. (2015). *ASReml User Guide Release 4.1*. VSN International, Hemel Hempstead.

Gilmour, A.R., Thompson, R., Cullis, B.R. (1995). Average information REML: an efficient algorithm for variance parameter estimation in linear mixed models. *Biometrics* 51, 1440–1450.

Griffing, B. (1956). Concept of general and specific combining ability in relation to diallel crossing systems. *Australian Journal of Biological Sciences* 9, 463–493.

Halekoh, U., Højsgaard, S. (2014). A Kenward–Roger approximation and parametric bootstrap methods for tests in linear mixed models — the R package pbkrtest. *Journal of Statistical Software* 59(9).

Hayman, B.I. (1954). The analysis of variance of diallel tables. *Biometrics* 10, 235–244.

Henderson, C.R. (1975). Best linear unbiased estimation and prediction under a selection model. *Biometrics* 31, 423–447.

Henderson, C.R. (1976). A simple method for computing the inverse of a numerator relationship matrix used in prediction of breeding values. *Biometrics* 32, 69–83.

Henderson, C.R. (1984). *Applications of Linear Models in Animal Breeding*. University of Guelph.

John, J.A., Williams, E.R. (1995). *Cyclic and Computer Generated Designs*. Chapman and Hall, London.

Johnson, D.L., Thompson, R. (1995). Restricted maximum likelihood estimation of variance components for univariate animal models using sparse matrix techniques and average information. *Journal of Dairy Science* 78, 449–456.

Kang, H.M. et al. (2008). Efficient control of population structure in model organism association mapping. *Genetics* 178, 1709–1723.

Kenward, M.G., Roger, J.H. (1997). Small sample inference for fixed effects from restricted maximum likelihood. *Biometrics* 53, 983–997.

Kirkpatrick, M., Lofsvold, D., Bulmer, M. (1990). Analysis of the inheritance, selection and evolution of growth trajectories. *Genetics* 124, 979–993.

Legarra, A., Aguilar, I., Misztal, I. (2009). A relationship matrix including full pedigree and genomic information. *Journal of Dairy Science* 92, 4656–4663.

Lin, L., Yang, C., Meza, J.C., Lu, J., Ying, L., E, W. (2011). SelInv — an algorithm for selected inversion of a sparse symmetric matrix. *ACM Transactions on Mathematical Software* 37(4), 40.

Meuwissen, T.H.E., Hayes, B.J., Goddard, M.E. (2001). Prediction of total genetic value using genome-wide dense marker maps. *Genetics* 157, 1819–1829.

Meuwissen, T.H.E., Luo, Z. (1992). Computing inbreeding coefficients in large populations. *Genetics Selection Evolution* 24, 305–313.

Meyer, K. (1992). Variance components due to direct and maternal effects for growth traits of Australian beef cattle. *Livestock Production Science* 31, 179–204.

Misztal, I., Legarra, A., Aguilar, I. (2014). Using recursion to compute the inverse of the genomic relationship matrix. *Journal of Dairy Science* 97, 3943–3952.

Misztal, I., Perez-Enciso, M. (1993). Sparse matrix inversion for restricted maximum likelihood estimation of variance components by expectation-maximization. *Journal of Dairy Science* 76, 1479–1483.

Patterson, H.D., Thompson, R. (1971). Recovery of inter-block information when block sizes are unequal. *Biometrika* 58, 545–554.

Pérez, P., de los Campos, G. (2014). Genome-wide regression and prediction with the BGLR statistical package. *Genetics* 198, 483–495.

Piepho, H.P., Möhring, J., Schulz-Streeck, T., Ogutu, J.O. (2012). A stage-wise approach for the analysis of multi-environment trials. *Biometrical Journal* 54, 844–860.

Pinheiro, J.C., Bates, D.M. (2000). *Mixed-Effects Models in S and S-PLUS*. Springer, New York.

Potthoff, R.F., Roy, S.N. (1964). A generalized multivariate analysis of variance model useful especially for growth curve problems. *Biometrika* 51, 313–326.

Quaas, R.L. (1976). Computing the diagonal elements and inverse of a large numerator relationship matrix. *Biometrics* 32, 949–953.

Schaeffer, L.R. (2004). Application of random regression models in animal breeding. *Livestock Production Science* 86, 35–45.

Self, S.G., Liang, K.Y. (1987). Asymptotic properties of maximum likelihood estimators and likelihood ratio tests under nonstandard conditions. *Journal of the American Statistical Association* 82, 605–610.

Smith, A.B., Cullis, B.R. (2018). Plant breeding selection tools built on factor analytic mixed models for multi-environment trial data. *Euphytica* 214, 143.

Smith, A.B., Cullis, B.R., Thompson, R. (2001). Analyzing variety by environment data using multiplicative mixed models and adjustments for spatial field trend. *Biometrics* 57, 1138–1147.

Smith, A.B., Cullis, B.R., Thompson, R. (2005). The analysis of crop cultivar breeding and evaluation trials: an overview of current mixed model approaches. *Journal of Agricultural Science* 143, 449–462.

Stram, D.O., Lee, J.W. (1994). Variance components testing in the longitudinal mixed effects model. *Biometrics* 50, 1171–1177.

Takahashi, K., Fagan, J., Chen, M.S. (1973). Formation of a sparse bus impedance matrix and its application to short circuit study. *Proceedings of the 8th Power Industry Computer Applications (PICA) Conference*, Minneapolis, 63–69.

VanRaden, P.M. (2008). Efficient methods to compute genomic predictions. *Journal of Dairy Science* 91, 4414–4423.

Vazquez, A.I., Bates, D.M., Rosa, G.J.M., Gianola, D., Weigel, K.A. (2010). Technical note: an R package for fitting generalized linear mixed models in animal breeding. *Journal of Animal Science* 88, 497–504.

Welham, S., Cullis, B., Gogel, B., Gilmour, A., Thompson, R. (2004). Prediction in linear mixed models. *Australian and New Zealand Journal of Statistics* 46, 325–347.

Willham, R.L. (1963). The covariance between relatives for characters composed of components contributed by related individuals. *Biometrics* 19, 18–27.

Willham, R.L. (1972). The role of maternal effects in animal breeding: III. Biometrical aspects of maternal effects in animals. *Journal of Animal Science* 35, 1288–1293.

Wright, K. (2024). *agridat: Agricultural Datasets*. R package, CRAN.

附录：函数参考手册

本附录收录了软件包中每个函数的帮助页面。在 R 中，可通过 `?function_name` 查看。

16.4 `MLREML-package`：MLREML：平均信息 REML 线性混合模型

16.4.0.1 描述

MLREML 采用平均信息算法，通过限制性最大似然法为植物和动物育种拟合线性混合模型。主函数为 `mlreml`。本软件包提供两个计算引擎：基于观测值方差矩阵的稠密引擎，支持所有方差结构；以及基于混合模型方程、稀疏 Cholesky 分解和 Takahashi 稀疏逆的稀疏引擎，适用于包含数十万至数百万条记录的数据集。英文版和西班牙文版用户指南（包含理论和使用真实数据的实例）随软件包一起安装：`system.file("doc", "MLREML-guide-en.pdf", package = "MLREML")` 和 `system.file("doc", "MLREML-guide-es.pdf", package = "MLREML")`。

16.4.0.2 详细信息

主要函数：

`mlreml`：模型拟合（包括使用 `str()` 项的直接-母体模型以及稀疏引擎）。

`summary.mlreml`、`wald`（使用 Kenward-Roger 分母自由度）、`predict.mlreml`、`vpredict`、`lrt`、`vc_matrix`、`variogram`：推断。

`pedigree_prepare`、`Amatrix`、`Ainverse`、`inbreeding_coef`、`snp_qc`、`Gmatrix`、`align_G`、`Hmatrix`、`bend`：亲缘关系矩阵。

`gblup`、`cv_gblup`：快速 GBLUP。

16.4.0.3 作者

维护者：Osval A. Montesinos-Lopez maintainer@example.org

16.5 `mlreml`：用平均信息 REML 拟合线性混合模型

16.5.0.1 描述

`mlreml` 拟合线性混合模型

$$y = X\beta + \sum_k Z_k\, u_k + e, \quad u_k \sim N(0, G_k), \quad e \sim N(0, R)$$

采用平均信息（AI）算法的限制性最大似然法（REML）。协方差矩阵 G_k 和 R 以类似 ASReml 的语法指定，表示为方差结构的直积（Kronecker 积）。

16.5.0.2 用法

```
mlreml(
  fixed,
  random = NULL,
  residual = NULL,
  data,
  start = NULL,
  fix = NULL,
  maxit = 50,
  tol = 1e-06,
  pev = TRUE,
  trace = TRUE,
  store = TRUE,
  engine = c("auto", "dense", "sparse")
)
```

16.5.0.3 参数

参数	描述
`fixed`	固定效应的双侧公式。
`random`	包含随机项的单侧公式，或 `NULL`。

参数	描述
residual	残差结构的单侧公式。
data	数据框。
start	可选的初始值命名向量（名称与 summary(fit)$varcomp 中相同）。
fix	字符向量，包含固定在其初始值上的方差参数的名称。
maxit	AI 最大迭代次数。
tol	REML 对数似然变化的收敛容差。
pev	逻辑值；计算 BLUP 的预测误差方差。
trace	逻辑值；打印迭代历史。
store	逻辑值；保留 predict.mlreml 以及 wald 的 Kenward-Roger 调整所需的矩阵。
engine	"auto"、"dense" 或 "sparse"（参见关于计算引擎的部分）。

16.5.0.4 返回值

类为 "mlreml" 的对象。

16.5.0.5 指定随机项和残差

每个随机项是由 : 分隔的若干组分的乘积。每个组分是作用于一个因子、一个协变量的多项式基或一个多成员因子的结构函数：

id(f) 或 f
独立效应，单位矩阵。

vm(f, K)
按已知矩阵 K（系谱 A、基因组 G、一步法 H、亲缘矩阵）相关的效应。K 必须具有包含 f 所有水平的行名；它可以包含额外的水平（无记录的个体），这些水平的 BLUP 也会被返回。K 也可以通过其逆矩阵给出，并以属性 INVERSE = TRUE 标记（如 Ainverse 的返回值）；此时稀疏引擎直接使用它。

diag(f)
f 的每个水平具有不同方差的独立效应。

us(f)
非结构化（完全参数化）协方差矩阵。

fa(f, k)
具有 k 个因子的因子分析结构，$\Lambda\Lambda' + \Psi$。

cs(f)
复合对称相关。

ar1(f)
一阶自回归相关；若 f 的水平为数值型，则使用实际距离，因此允许存在间隔。

expc(x)
用于不规则间隔数值协变量的指数相关 $\rho^{|x_i - x_j|}$。

sexp(x, y)
二维坐标上的各向同性指数相关 $\rho^{d_{ij}}$（不规则空间数据）。

pol(x, k),leg(x, k)
k 阶原始多项式基和标准化 Legendre 多项式基（随机回归）；通常与 us() 或 diag() 组合使用。

mm(f1, f2)
多成员因子（例如双列杂交中两个亲本的一般配合力）。

units
观测单元（每条记录一个水平）。

所有组分均为相关结构（id、vm、cs、ar1、expc、sexp）的项会获得一个尺度方差。每个项最多允许一个方差结构（diag、us、fa），由它承载尺度。

residual 公式使用相同的语法；默认为 ~ units（具有共同方差的独立残差），多变量模型默认为 ~ us(trait):units。

16.5.0.6 多个因子的相关效应（直接-母体模型）

项 str(f1, f2, ..., K = A, cov = "us") 定义 $m \geq 2$ 个共享矩阵 K 的水平且彼此相关的随机效应：令 $u = (u_1', \ldots, u_m')'$ 且 $Z = [Z_1, \ldots, Z_m]$，

$$Var(u) = \Sigma \otimes K,$$

其中 Σ 是非结构化（cov = "us"）或对角（cov = "diag"）的 $m \times m$ 矩阵。通常的应用是直接-母体动物模型 str(animal, dam, K = A)，其中 Z_1 将每条记录与该动物相连，Z_2 将其与该动物的母亲相连，Σ 包含直接和母体遗传方差及其协方差。str() 中某个因子的缺失值（例如母亲未知）表示该记录不从该因子获得效应；这些记录会被保留。若省略 K，则各水平相互独立（$K = I$）。

16.5.0.7 计算引擎

"dense" 引擎处理 $n \times n$ 矩阵 $V = Var(y)$，支持所有结构；其成本随 n^3 增长，内存随 n^2 增长，因此适用于最多几千条记录。"sparse" 引擎使用 Henderson 混合模型方程、稀疏

Cholesky 分解（CHOLMOD，通过 Matrix 软件包）和稀疏（Takahashi）逆，因此其成本取决于非零元素个数而不是 n^2；它可以处理数十万至数百万条记录。它支持由 `id`、`vm`、`diag` 和 `us` 组分构成的随机项（使用因子、`pol`、`leg` 或 `mm` 基）以及 `str()` 项，并支持残差结构 `units`、`diag(f):units`，以及在多变量模型中的 `us(trait):units`。`engine = "auto"`（默认）在记录超过 5000 条且模型受支持时使用稀疏引擎，否则使用稠密引擎。两个引擎给出的估计值、BLUP 和预测误差方差在数值精度范围内相同。

16.5.0.8 多变量模型

如果 `fixed` 的左侧为 `cbind(y1, y2, ...)`，数据会在内部被堆叠，创建因子 `trait`，并由 `units` 标识原始记录，因此 `us(trait):units` 是同一记录上所测性状之间的残差协方差矩阵。存在部分性状缺失的记录仍会保留其已观测的性状。

16.5.0.9 参考文献

Gilmour, A.R., Thompson, R., Cullis, B.R. (1995). Average information REML: an efficient algorithm for variance parameter estimation in linear mixed models. *Biometrics* 51, 1440-1450.

Johnson, D.L., Thompson, R. (1995). Restricted maximum likelihood estimation of variance components for univariate animal models using sparse matrix techniques and average information. *J. Dairy Sci.* 78, 449-456.

Misztal, I., Perez-Enciso, M. (1993). Sparse matrix inversion for restricted maximum likelihood estimation of variance components by expectation-maximization. *J. Dairy Sci.* 76, 1479-1483.

Willham, R.L. (1963). The covariance between relatives for characters composed of components contributed by related individuals. *Biometrics* 19, 18-27.

16.5.0.10 示例

```
set.seed(1)
d <- data.frame(block = factor(rep(1:4, each = 30)),
                gen = factor(rep(1:30, 4)))
d$y <- 10 + rnorm(4)[d$block] + rnorm(30, sd = 1.5)[d$gen] + rnorm(120)
fit <- mlreml(y ~ block, random = ~ id(gen), data = d)
summary(fit)
```

16.6 `summary.mlreml`：mlreml 拟合结果的 print 和 summary 方法

16.6.0.1 描述

mlreml 拟合结果的 print 和 summary 方法

16.6.0.2 用法

```
## S3 method for class 'mlreml'
summary(object, ...)

## S3 method for class 'summary.mlreml'
print(x, ...)
```

```r
## S3 method for class 'mlreml'
print(x, ...)

## S3 method for class 'mlreml'
fitted(object, ...)

## S3 method for class 'mlreml'
residuals(object, ...)

## S3 method for class 'mlreml'
vcov(object, ...)

## S3 method for class 'mlreml'
logLik(object, ...)
```

16.6.0.3 参数

参数	描述
object、x	类为 "mlreml" 的对象。
...	其他参数（忽略）。

16.6.0.4 返回值

summary 返回一个列表，包含方差组分（varcomp）、带标准误的固定效应（coef.fixed）、对数似然和信息准则。

16.7 coef.mlreml：提取固定效应和随机效应

16.7.0.1 描述

提取固定效应和随机效应

16.7.0.2 用法

```r
## S3 method for class 'mlreml'
coef(object, type = c("fixed", "random"), term = NULL, ...)

ranef_mlreml(object, term = NULL)

fixef_mlreml(object)
```

16.7.0.3 参数

参数	描述
object	一个 "mlreml" 拟合结果。
type	"fixed" 或 "random"。
term	对于随机效应，为随机项的标签（与 names(object$blups) 中相同）；NULL 返回所有项。

参数	描述
···	忽略。

16.7.0.4 返回值

命名向量（固定效应）或数据框（带预测误差方差、标准误和可靠性的 BLUP）。

16.8 `wald`：固定效应的 Wald 检验

16.8.0.1 描述

对固定效应公式中的每一项计算递增和条件 Wald 统计量，并给出 F 检验，其分母自由度由 Kenward 和 Roger（1997）的方法求得，或者作为大样本近似，取残差自由度 $n - rank(X)$。

16.8.0.2 用法

```
wald(object, ddf = c("auto", "KR", "residual"))
```

16.8.0.3 参数

参数	描述
`object`	一个 `"mlreml"` 拟合结果。
`ddf`	`"auto"`（对以 `store = TRUE` 保存的稠密引擎拟合使用 Kenward-Roger，否则使用残差自由度）、`"KR"` 或 `"residual"`。

16.8.0.4 详细信息

某一项的递增统计量检验的是对固定效应公式中位于其前面的项进行调整后的该项（序贯检验，“I 型”检验）。条件统计量检验的是对所有不包含该项的其他项进行调整后的该项，与 ASReml 一样遵循边际性原则（相当于“II 型”检验）：在 `y ~ A * B` 中，主效应 `A` 对 `B` 进行调整，但不对 `A:B` 调整。两种统计量都由固定效应协方差矩阵之逆的 Cholesky 因子计算，对于条件统计量需重新排列各列（该项位于不包含它的项之后、包含它的项之前）。

采用 Kenward-Roger 方法时，每个假设 $L\beta = 0$ 的统计量为 $F = \lambda(L\hat{\beta})'(L\Phi_A L')^{-1}(L\hat{\beta})/q$，其中 Φ_A 是针对估计方差参数的不确定性调整后的固定效应协方差矩阵，分母自由度 m 和尺度 λ 通过使 F 的矩与 $F(q,m)$ 分布的矩相匹配而得到。使用期望信息矩阵；对于关于参数非线性的结构（`ar1`、`expc`、`sexp`、`fa`、带参数组分的乘积），纳入 V 的二阶导数。固定的或位于参数空间边界上的方差参数视为已知。

16.8.0.5 返回值

每个固定项一行的数据框：分子自由度（`df`）；递增 Wald 统计量、F 统计量、分母自由度和 p 值（`wald.inc`、`F.inc`、`ddf.inc`、`p.inc`）；条件检验的相应结果（`wald.con`、`F.con`、

ddf.con、p.con）；以及按卡方分布计算的条件 Wald 统计量的 p 值（p.chisq）。属性 "ddf" 给出所用的方法。

16.8.0.6 参考文献

Kenward, M.G., Roger, J.H. (1997). Small sample inference for fixed effects from restricted maximum likelihood. *Biometrics* 53, 983-997.

Halekoh, U., Hojsgaard, S. (2014). A Kenward-Roger approximation and parametric bootstrap methods for tests in linear mixed models - the R package pbkrtest. *J. Stat. Softw.* 59(9).

16.8.0.7 示例

```
set.seed(2)
d <- data.frame(trt = gl(3, 20), blk = gl(4, 5, 60))
d$y <- c(0, 1, 2)[d$trt] + rnorm(4)[d$blk] + rnorm(60)
fit <- mlreml(y ~ trt, random = ~ blk, data = d, trace = FALSE)
wald(fit)
wald(fit, ddf = "residual")
```

16.9 predict.mlreml：带标准误和差值标准误的预测均值

16.9.0.1 描述

为一个或多个因子（classify）的各水平构建预测，在其他固定因子的各水平上对固定效应取平均（简单平均），并在协变量的均值处取值。其因子全部包含在 classify 中的随机项以 BLUP 的形式纳入；其余随机项被忽略（其期望为零）。标准误和差值标准误（SED）矩阵根据固定效应和随机效应的联合预测误差方差计算，遵循 Welham et al.（2004）的方法。

16.9.0.2 用法

```
## S3 method for class 'mlreml'
predict(object, classify, sed = TRUE, ...)
```

16.9.0.3 参数

参数	描述
object	一个 "mlreml" 拟合结果（使用 store = TRUE 拟合）。
classify	字符型，例如 "gen" 或 "env:gen"。
sed	逻辑值；返回 SED 矩阵。
...	忽略。

16.9.0.4 返回值

一个列表，包含 pvals（预测值和标准误）、sed（矩阵）和 avsed（平均 SED）。

16.9.0.5 参考文献

Welham, S., Cullis, B., Gogel, B., Gilmour, A., Thompson, R. (2004). Prediction in linear mixed models. *Aust. N. Z. J. Stat.* 46, 325-347.

16.10 vpredict：方差参数的函数及其 delta 方法标准误

16.10.0.1 描述

计算方差参数的函数（例如遗传力或遗传相关）及其由平均信息矩阵的逆得到的近似标准误，与 ASReml-R 的 vpredict 函数相同。参数按 summary(fit)$varcomp 中的顺序称为 V1、V2、…。

16.10.0.2 用法

```
vpredict(object, formula)
```

16.10.0.3 参数

参数	描述
object	一个 "mlreml" 拟合结果。
formula	一个公式，例如 h2 ~ V2 / (V2 + V3)。

16.10.0.4 返回值

包含估计值及其标准误的数据框。

16.10.0.5 示例

```
set.seed(3)
d <- data.frame(fam = gl(40, 5))
d$y <- rnorm(40, sd = 1)[d$fam] + rnorm(200, sd = 2)
fit <- mlreml(y ~ 1, random = ~ fam, data = d, trace = FALSE)
vpredict(fit, h2 ~ 4 * V1 / (V1 + V2))
```

16.11 lrt：嵌套模型之间的似然比检验

16.11.0.1 描述

比较两个固定效应相同、方差结构不同的模型。使用 boundary = TRUE 时，p 值采用卡方分布的 50:50 混合，适用于在参数空间边界上检验单个方差参数的情形。

16.11.0.2 用法

```
lrt(fit0, fit1, boundary = TRUE)
```

16.11.0.3 参数

参数	描述

参数	描述
fit0	简化模型。
fit1	完整模型。
boundary	逻辑值；使用混合分布。

16.11.0.4 返回值

包含统计量、自由度和 p 值的数据框。

16.12 vc_matrix：结构化组分的估计协方差矩阵和相关矩阵

16.12.0.1 描述

返回 us、diag 或 fa 组分的估计协方差矩阵（例如环境间或性状间的遗传协方差矩阵）、其相关矩阵，对于 fa 还返回载荷和特殊方差。

16.12.0.2 用法

```
vc_matrix(object, term)
```

16.12.0.3 参数

参数	描述
object	一个 "mlreml" 拟合结果。
term	项的标签（与 object$varcomp$term 中相同），或 "residual"。

16.12.0.4 返回值

包含 cov 和 cor 的列表（对于因子分析结构还包含 loadings、psi）。

16.13 variogram：田间试验残差的样本变异函数

16.13.0.1 描述

按行和列的绝对位移计算残差的经验半变异函数，这是空间分析的标准诊断方法（Gilmour, Cullis and Verbyla, 1997）。

16.13.0.2 用法

```
variogram(object, row, col, plot = TRUE, resid = NULL)
```

16.13.0.3 参数

参数	描述
object	一个 "mlreml" 拟合结果。

参数	描述
row、col	数据中数值型行变量和列变量的名称。
plot	逻辑值；绘制透视图。
resid	可选的残差向量（默认：条件残差）。

16.13.0.4 返回值

包含行滞后、列滞后、半方差和点对数的数据框。

16.13.0.5 参考文献

Gilmour, A.R., Cullis, B.R., Verbyla, A.P. (1997). Accounting for natural and extraneous variation in the analysis of field experiments. *JABES* 2, 269-293.

16.14 plot.mlreml：诊断图

16.14.0.1 描述

残差对拟合值图、残差的正态分位数图和直方图，以及 REML 对数似然的历史。

16.14.0.2 用法

```
## S3 method for class 'mlreml'
plot(x, ...)
```

16.14.0.3 参数

参数	描述
x	一个 "mlreml" 拟合结果。
...	传递给 plot。

16.15 pedigree_prepare：准备系谱

16.15.0.1 描述

对未知亲本重新编码，将未作为个体出现的亲本（作为奠基者）加入，检查错误，并对系谱排序，使亲本位于其后代之前。

16.15.0.2 用法

```
pedigree_prepare(ped)
```

16.15.0.3 参数

参数	描述

参数	描述
ped	数据框，其前三列为个体、父本（sire）和母本（dam）。未知亲本可编码为 NA、0、"0"、"-" 或 ""。

16.15.0.4 返回值

一个数据框，包含列 id、sire、dam（字符型，未知时为 NA）、sire_i、dam_i（整数位置，未知时为 0）以及 gen（世代号）。

16.15.0.5 示例

```
ped <- data.frame(id = c("A3", "A4", "A5"), sire = c("A1", "A1", "A3"),
                  dam = c("A2", "A2", "A4"))
pedigree_prepare(ped)
```

16.16 inbreeding_coef：近交系数（Meuwissen and Luo, 1992）

16.16.0.1 描述

近交系数（Meuwissen and Luo, 1992）

16.16.0.2 用法

```
inbreeding_coef(ped)
```

16.16.0.3 参数

参数	描述
ped	由 pedigree_prepare 返回的系谱，或该函数所接受的任何数据框。

16.16.0.4 返回值

近交系数的命名向量。

16.16.0.5 参考文献

Meuwissen, T.H.E., Luo, Z. (1992). Computing inbreeding coefficients in large populations. *Genet. Sel. Evol.* 24, 305-313.

16.17 Amatrix：分子（加性）亲缘关系矩阵

16.17.0.1 描述

用表格法构建稠密加性亲缘关系矩阵 A。适用于约 15,000 个以内的个体；对于更大的系谱，请使用稀疏逆矩阵 Ainverse。

16.17.0.2 用法

```
Amatrix(ped)
```

16.17.0.3 参数

参数	描述
ped	系谱（参见 pedigree_prepare）。

16.17.0.4 返回值

以个体名称作为 dimnames 的对称矩阵。

16.17.0.5 示例

```
ped <- data.frame(id = c("A3", "A4", "A5"), sire = c("A1", "A1", "A3"),
                  dam = c("A2", "A2", "A4"))
Amatrix(ped)
```

16.18 Ainverse：加性亲缘关系矩阵的稀疏逆矩阵

16.18.0.1 描述

考虑近交的 Henderson 规则（Quaas, 1976），使用 Meuwissen 和 Luo（1992）的近交系数。

16.18.0.2 用法

```
Ainverse(ped)
```

16.18.0.3 参数

参数	描述
ped	系谱（参见 pedigree_prepare）。

16.18.0.4 返回值

稀疏对称矩阵（Matrix 软件包），带有属性 INVERSE = TRUE，因此可以直接在 mlreml 中提供给 vm() 或 str()（稀疏引擎直接使用；稠密引擎对其求逆）。

16.19 snp_qc：SNP 矩阵的质量控制

16.19.0.1 描述

SNP 矩阵的质量控制

16.19.0.2 用法

```
snp_qc(M, maf = 0.05, callrate = 0.9, ind_callrate = 0.9)
```

16.19.0.3 参数

参数	描述
M	基因型矩阵（个体为行），编码为 0/1/2 或 -1/0/1；缺失值为 NA。
maf	最小次等位基因频率。
callrate	每个标记的最小检出率。
ind_callrate	每个个体的最小检出率。

16.19.0.4 返回值

一个列表，包含过滤后的矩阵（M，编码为 0/1/2）、等位基因频率以及被删除的标记和个体的报告。

16.20 Gmatrix：基因组亲缘关系矩阵

16.20.0.1 描述

基因组亲缘关系矩阵

16.20.0.2 用法

```
Gmatrix(M, method = c("VanRaden", "Yang", "scaled"), p = NULL)
```

16.20.0.3 参数

参数	描述
M	基因型矩阵（个体为行），编码为 0/1/2 或 -1/0/1。缺失值用标记均值替代。
method	"VanRaden"（VanRaden 2008，方法 1）、"Yang"（标准化标记，VanRaden 方法 2）或 "scaled"（中心化并缩放后的标记除以标记数，ZZ'/p，即作为岭回归的 GBLUP 的核）。
p	可选的基础等位基因频率向量。

16.20.0.4 返回值

具有 M 行名的对称矩阵。

16.20.0.5 参考文献

VanRaden, P.M. (2008). Efficient methods to compute genomic predictions. *J. Dairy Sci.* 91, 4414-4423.

16.21 align_G：将基因组矩阵与系谱矩阵对齐

16.21.0.1 描述

将 G 重新缩放为 $\alpha + \beta G$，使其对角线均值和所有元素均值等于 A22 的相应均值（Christensen et al., 2012）。

16.21.0.2 用法

```
align_G(G, A22)
```

16.21.0.3 参数

参数	描述
G	基因组亲缘关系矩阵。
A22	已基因分型个体的系谱亲缘关系。

16.21.0.4 返回值

对齐后的矩阵，带有属性 alpha 和 beta。

16.22 Hmatrix：一步法亲缘关系矩阵 H 及其逆矩阵

16.22.0.1 描述

将所有个体的系谱矩阵 A 与已基因分型个体的基因组矩阵 G 合并（Legarra et al., 2009; Aguilar et al., 2010）。合并之前，可选择将 G 与 A22 混合并与之对齐。

16.22.0.2 用法

```
Hmatrix(A, G, blend = 0.05, align = TRUE, tau = 1, omega = 1, inverse = FALSE)
```

16.22.0.3 参数

参数	描述
A	所有个体的系谱亲缘关系矩阵（稠密）。
G	已基因分型个体的基因组亲缘关系矩阵；其行名必须在 rownames(A) 中。
blend	$(1-w)G + wA_{22}$ 中 A22 的权重。
align	逻辑值；用 align_G 将 G 与 A22 对齐。
tau、omega	逆矩阵中 G^{-1} 和 A_{22}^{-1} 的缩放因子。
inverse	逻辑值；返回 H^{-1} 而非 H。

16.22.0.4 返回值

具有 A 的 dimnames 的 H（或其逆矩阵）。

16.22.0.5 参考文献

Legarra, A., Aguilar, I., Misztal, I. (2009). A relationship matrix including full pedigree and genomic information. *J. Dairy Sci.* 92, 4656-4663.

16.23 `bend`：使对称矩阵正定（弯曲法）

16.23.0.1 描述

使对称矩阵正定（弯曲法）

16.23.0.2 用法

```
bend(K, tol = 1e-04)
```

16.23.0.3 参数

参数	描述
K	对称矩阵。
tol	弯曲后的最小特征值（相对于最大特征值）。

16.23.0.4 返回值

弯曲后的矩阵。

16.24 `gblup`：基于谱分解的快速 GBLUP

16.24.0.1 描述

利用已测表型个体亲缘关系矩阵的特征分解（Kang et al., 2008），以精确 REML 拟合 $y = X\beta + g + e$、$g \sim N(0, K\sigma_g^2)$、$e \sim N(0, I\sigma_e^2)$，将 REML 化为一维优化问题。对 `K` 中的每个个体（无论是否有表型）都返回预测值（GEBV）。结果与 `mlreml(y ~ ..., random = ~ vm(id, K))` 完全相同，但速度快得多。

16.24.0.2 用法

```
gblup(y, K, X = NULL, id = names(y))
```

16.24.0.3 参数

参数	描述
y	表型的数值向量，以个体命名，或其个体标识符在 `id` 中给出。
K	带有行名的亲缘关系矩阵。

参数	描述
X	可选的固定效应设计矩阵（默认：截距）。
id	y 的可选字符型标识符向量。

16.24.0.4 返回值

一个列表，包含 varcomp（σ_g^2、σ_e^2、h^2）、beta、gebv（K 中所有个体的命名向量）和 loglik。

16.24.0.5 参考文献

Kang, H.M. et al. (2008). Efficient control of population structure in model organism association mapping. *Genetics* 178, 1709-1723.

16.25 cv_gblup：GBLUP 的 K 折交叉验证

16.25.0.1 描述

将已测表型的个体随机划分为 folds 组，用 gblup 根据其他组预测每一组，并报告预测值与观测值之间的 Pearson 相关。

16.25.0.2 用法

```
cv_gblup(y, K, folds = 5, reps = 1, seed = 1)
```

16.25.0.3 参数

参数	描述
y	表型的命名向量。
K	亲缘关系矩阵。
folds	折数。
reps	随机划分的重复次数。
seed	随机种子。

16.25.0.4 返回值

每次重复和每一折各占一行的数据框。